

РЕФЕРАТ

Выпускная квалификационная работа содержит 139 с., 4 гл., 29 рис., 20 табл., 57 источников, 1 прил.

КЛЮЧЕВАЯ СТАВКА, ЦЕНТРАЛЬНЫЙ БАНК, ПРОГНОЗИРОВАНИЕ ВРЕМЕННЫХ РЯДОВ, МАШИННОЕ ОБУЧЕНИЕ, FOUNDATION MODELS, КРИВАЯ БЕСКУПОННОЙ ДОХОДНОСТИ, ТЕСТ ДИБОЛДА–МАРИАНО, SHAP-ЗНАЧЕНИЯ

Объект исследования – макроэкономические временные ряды РФ: ключевая ставка Банка России (сентябрь 2013 – март 2026), кривая бескупонной доходности ОФЗ, ставки RUONIA и ROISfix, 33 макроэкономических индикатора.

Цель – сравнение 16 моделей прогнозирования ключевой ставки четырёх классов и оценка информативности кривой бескупонной доходности как предиктора.

Методы: расширяющееся окно кросс-валидации, тест Диболда–Мариано, пять методов оценки важности признаков (SHAP, permutation importance и др.), ablation study, квантильная регрессия.

При горизонте $h = 1$ случайное блуждание значительно превосходит все 15 альтернатив; TimeGPT в режиме zero-shot превзошёл все обученные модели. Кривая бескупонной доходности – главный предиктор, однако при $h = 1$ её информация дублируется лагом целевой переменной. Результаты подтверждены на данных НБРК (Казахстан).

Область применения: прогнозирование ставок, управление процентным риском, ценообразование кредитных продуктов.

СОДЕРЖАНИЕ

РЕФЕРАТ	2
ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ	6
ВВЕДЕНИЕ	9
1 МАТЕМАТИЧЕСКИЕ МЕТОДЫ ПРОГНОЗИРОВАНИЯ ВРЕМЕННЫХ РЯДОВ	13
1.1 Постановка задачи прогнозирования	13
1.2 Параметрические модели пространства состояний.....	17
1.2.1 ARIMA: авторегрессия, интегрирование, скользящее среднее	17
1.2.2 ETS: экспоненциальное сглаживание в форме пространства состояний.....	21
1.2.3 CES: комплексное экспоненциальное сглаживание	24
1.2.4 Метод Theta	26
1.2.5 Квантильная регрессия и интервальные прогнозы.....	28
1.3 Непараметрические и ансамблевые методы	29
1.3.1 Переход от временного ряда к задаче регрессии.....	29
1.3.2 Градиентный бустинг: LightGBM и XGBoost.....	31
1.3.3 Prophet: аддитивная декомпозиция с кусочно-линейным трендом ..	36
1.4 Нейросетевые архитектуры для временных рядов.....	38
1.4.1 N-BEATS: нейросетевая декомпозиция на базисные функции	38
1.4.2 N-HiTS: иерархическая интерполяция и мультимасштабное моделирование	41
1.4.3 PatchTST: адаптация механизма внимания к подпоследовательностям ряда.....	43
1.5 Foundation Models: предобученные трансформеры для временных рядов	46
1.5.1 TimeGPT, Chronos-Bolt, TimesFM: архитектура, токенизация и zero- shot прогнозирование	46
1.5.2 Проблема интерпретируемости и применимость моделей «чёрного ящика»	49

1.6 Обзор существующих исследований по прогнозированию процентных ставок	50
2 ДАННЫЕ, ПРИЗНАКОВОЕ ПРОСТРАНСТВО И СХЕМА ЭКСПЕРИМЕНТА	54
2.1 Описание предметной области: ключевая ставка ЦБ РФ как целевой процесс.....	54
2.2 Формирование набора данных	56
2.2.1 Целевая переменная и блок экзогенных регрессоров	56
2.2.2 Кривая бескупонной доходности ОФЗ.....	58
2.2.3 RUONIA и ROISfix.....	60
2.2.4 Предобработка.....	61
2.3 Разведочный анализ временных рядов	61
2.3.1 Тестирование стационарности: ADF, KPSS.....	61
2.3.2 Автокорреляционная структура	64
2.3.3 STL-декомпозиция	68
2.4 Метрики качества прогнозов и схема валидации	70
2.4.1 MAE, RMSE, MAPE: математические свойства	70
2.4.2 Временная кросс-валидация: expanding window	71
2.4.3 Тест Diebold-Mariano.....	72
2.5 Описание моделей, гиперпараметров и программного инструментария	74
3 ВЫЧИСЛИТЕЛЬНЫЙ ЭКСПЕРИМЕНТ	77
3.1 Базовые модели (baseline)	77
3.2 Статистические модели: StatsForecast.....	81
3.3 Prophet с экзогенными регрессорами	85
3.4 Ансамблевые модели: LightGBM и XGBoost	89
3.4.1 Конструирование признаков.....	89
3.4.2 Комплексная оценка информативности признаков.....	91
3.4.3 Ablation study: вклад КБД в точность прогноза.....	96
3.4.4 Интервальные оценки LightGBM	97
3.5 Нейросетевые модели: N-BEATS, N-HiTS, PatchTST	98

3.6 Foundation Models: TimeGPT (zero-shot)	104
3.7 Сводное сравнение моделей	107
3.7.1 Таблица метрик и интервальные оценки	107
3.7.2 Тест Diebold-Mariano.....	109
3.7.3 Анализ вычислительной сложности.....	111
3.7.4 Прогнозирование на горизонтах $h = 3$ и $h = 6$	113
3.8 Интерпретация результатов в контексте предметной области	115
3.9 Обратная задача: прогнозирование реакции рынка на ставку ЦБ РФ..	118
4 ПРОВЕРКА РОБАСТНОСТИ: ТЕСТИРОВАНИЕ НА ДАННЫХ КАЗАХСТАНА.....	124
4.1 Описание данных: базовая ставка НБРК	124
4.2 Прогон моделей без переобучения.....	126
4.3 Анализ устойчивости	128
ЗАКЛЮЧЕНИЕ	129
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	133
ПРИЛОЖЕНИЕ А	139
Папка на диске с полным текстом программ, датасетом, графиками	139

ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ

В настоящей выпускной квалификационной работе применяются следующие русскоязычные сокращения:

ВВП – валовой внутренний продукт

ВКР – выпускная квалификационная работа

ДКП – денежно-кредитная политика

ИПП – индекс промышленного производства

ИПЦ – индекс потребительских цен

КБД – кривая бескупонной доходности

НБРК – Национальный банк Республики Казахстан

НФА – Национальная финансовая ассоциация

ОФЗ – облигации федерального займа

ПАО – публичное акционерное общество

СРО – саморегулируемая организация

ЦБ РФ – Центральный банк Российской Федерации

Англоязычные сокращения:

ACF – autocorrelation function (автокорреляционная функция)

ADF – augmented Dickey-Fuller test (расширенный тест Дики–Фуллера)

AIC – Akaike information criterion (информационный критерий Акаике)

API – application programming interface (программный интерфейс приложения)

AR – autoregressive model (авторегрессионная модель)

ARIMA – autoregressive integrated moving average (авторегрессионная интегрированная модель скользящего среднего)

BIS – Bank for International Settlements (Банк международных расчётов)

CCF – Cross-Correlation Function (кросс-корреляционная функция)

CES – complex exponential smoothing (комплексное экспоненциальное сглаживание)

CPU – central processing unit (центральный процессор)

DM – Diebold-Mariano (test) (тест Диболда–Мариано)

ETS – Error, Trend, Seasonality (модель пространства состояний с компонентами «ошибка, тренд, сезонность», где A – аддитивная компонента, N – отсутствует, Z – автоматический подбор)

FRA – forward rate agreement (соглашение о будущей процентной ставке)

GELU – Gaussian Error Linear Unit (гауссова линейная единица ошибки)

GOSS – gradient-based one-side sampling (выборка на основе градиента, метод LightGBM)

GPU – graphics processing unit (графический процессор)

HAC – heteroskedasticity and autocorrelation consistent (оценка дисперсии, устойчивая к гетероскедастичности и автокорреляции)
 HMM – hidden Markov model (скрытая марковская модель)
 IRS – interest rate swap (процентный своп)
 KPSS – Kwiatkowski-Phillips-Schmidt-Shin test (тест Квятковского-Филлипса–Шмидта–Шина)
 LightGBM – light gradient boosting machine (лёгкий градиентный бустинг)
 LLM – large language model (большая языковая модель)
 MA – moving average (скользящее среднее)
 MAE – mean absolute error (средняя абсолютная ошибка)
 MAP – maximum a posteriori (максимум апостериорной вероятности)
 MAPE – mean absolute percentage error (средняя абсолютная процентная ошибка)
 MASE – mean absolute scaled error (нормированная средняя абсолютная ошибка)
 ML – machine learning (машинное обучение)
 MSE – mean squared error (среднеквадратичная ошибка)
 N-BEATS – Neural Basis Expansion Analysis for Time Series (нейросетевая архитектура для прогнозирования временных рядов)
 N-HiTS – Neural Hierarchical Interpolation for Time Series (нейросетевая архитектура с иерархической интерполяцией)
 NLP – natural language processing (обработка естественного языка)
 OIS – overnight indexed swap (однодневный индексированный своп)
 PACF – partial autocorrelation function (частичная автокорреляционная функция)
 PatchTST – Patch Time Series Transformer (трансформер для временных рядов на основе патчинга)
 PT – pass-through (коэффициент трансмиссии денежно-кредитной политики)
 RMSE – root mean squared error (корень из среднеквадратичной ошибки)
 ROISfix – Ruble Overnight Interest Rate Swap Fixing (индикативная ставка процентного свопа на RUONIA)
 RUONIA – Ruble OverNight Index Average (средневзвешенная ставка однодневного рублёвого межбанковского кредитования)
 SES – simple exponential smoothing (простое экспоненциальное сглаживание)
 SHAP – SHapley Additive exPlanations (метод интерпретации моделей на основе аксиоматики Шепли)
 TreeSHAP – Tree SHapley Additive exPlanations (деревья SHAP)
 STL – Seasonal and Trend decomposition using Loess (декомпозиция ряда на тренд, сезонность и остаток методом локальной полиномиальной регрессии)

TimeGPT – Time series Generative Pre-trained Transformer (предобученный трансформер для прогнозирования временных рядов, Garza et al., 2024)
TimesFM – Time Series Foundation Model (предобученная модель Google для временных рядов)
VAR – vector autoregression (векторная авторегрессия)
VECM – vector error correction model (векторная модель коррекции ошибок)
XGBoost – eXtreme Gradient Boosting (экстремальный градиентный бустинг)
ZZZ – автоматический выбор типа модели ETS (авторежим Zero/Zero/Zero, где каждый ноль заменяется наилучшим подобранным компонентом)

Термины иноязычного происхождения, используемые без перевода:

ablation study – исследование методом абляции: анализ вклада группы признаков путём их удаления из модели

backcast – ретроспективный прогноз (реконструкция входного сигнала в N-BEATS)

changepoint – точка излома тренда в модели Prophet

coverage – покрытие предсказательного интервала: доля фактических значений, попавших в интервал

data leakage – утечка данных: доступ модели к информации из тестового периода в ходе обучения

expanding window – расширяющееся окно кросс-валидации: обучающая выборка расширяется на каждом шаге валидации

fine-tuning – дообучение предобученной модели на целевых данных

foundation model – предобученная модель большого масштаба, способная работать в режиме zero-shot без дообучения на целевых данных

oracle – сценарий с использованием истинных будущих значений экзогенных переменных (верхняя граница точности, на практике недостижимая, поскольку эти значения при прогнозировании неизвестны)

pass-through – коэффициент трансмиссии: изменение рыночной ставки при изменении ключевой ставки на 1 п.п. (обозначается PT в тексте)

patching – разбиение временного ряда на перекрывающиеся подпоследовательности (патчи) для подачи на вход трансформера

pinball loss – функция потерь квантильной регрессии (асимметричная абсолютная ошибка)

residual stack – механизм остаточных подключений между блоками в N-BEATS / N-HiTS

sliding window – скользящее окно фиксированной длины (альтернатива expanding window)

tokenization – преобразование значений временного ряда в дискретные токены

ВВЕДЕНИЕ

Актуальность исследования. Ключевая ставка Банка России – основной инструмент денежно-кредитной политики, определяющий стоимость заёмных средств в экономике. Решения Совета директоров ЦБ РФ по ставке напрямую влияют на межбанковские ставки (RUONIA), стоимость кредитования, доходность облигаций и валютный курс. Для участников финансового рынка – банков, управляющих компаний, корпоративных казначейств – точный прогноз будущей ставки необходим при ценообразовании кредитных продуктов, управлении процентным риском и оценке портфелей долговых инструментов.

Связь ключевой ставки с макроэкономическими переменными (инфляция, выпуск, валютный курс) формализована правилом Тейлора [1], согласно которому центральный банк устанавливает ставку как функцию отклонения инфляции от целевого уровня и разрыва выпуска. Однако на практике решения ЦБ РФ определяются не только макропоказателями, но и дискреционной компонентой: оценкой рисков, коммуникационной стратегией и экспертным суждением членов Совета директоров. Абдурахманов [2] оценивает эту компоненту: по его расчётам, доля неожиданных для рынка решений Банка России в 2021–2023 гг. составляет 33%, что близко к более ранней оценке непредсказуемости в 35% за 2015–2018 гг. [2]. Среди заседаний, на которых ставка фактически менялась, доля неожиданных решений возрастает до 45% [2]. Иными словами, в момент разворота ДКП значительная часть информации о решении не отражена ни в макроиндикаторах, ни в рыночных ставках – задача прогнозирования остаётся трудной даже при полных данных.

За 2023–2025 годы в области прогнозирования временных рядов произошёл качественный сдвиг: появились foundation models – предобученные трансформеры (TimeGPT, Chronos, TimesFM), способные прогнозировать новый ряд без дообучения (zero-shot) [3]. Одновременно продолжали

развиваться нейросетевые архитектуры, специализированные для временных рядов (N-BEATS, N-HiTS, PatchTST), и ансамблевые методы (LightGBM, XGBoost). Систематическое сравнение моделей столь различной природы на задаче прогнозирования ключевой ставки ЦБ РФ до настоящего времени не проводилось.

Актуальность работы определяется потребностью финансового сектора в количественных оценках будущей ставки и неопределённости прогноза, а также отсутствием ответа на вопрос, оправдана ли сложность современных ML- и нейросетевых моделей для прогнозирования дискретно изменяющегося процесса, управляемого решениями регулятора.

Проблема. Существующие исследования по прогнозированию ставки ЦБ РФ [2, 4, 5] ограничены классическими эконометрическими методами (VAR, VECM) и не включают нейросети, ансамблевые модели и foundation models. Работы по применению ML к макроэкономическим рядам [6] фокусируются на инфляции и ВВП развитых стран. М-competitions [7, 8] проводятся на гетерогенных выборках рядов и не учитывают специфику дискретно управляемых процессов. Отсутствует систематическое сравнение моделей различной математической природы на единой схеме валидации с формальным статистическим тестированием.

Объект исследования – макроэкономические временные ряды Российской Федерации (ключевая ставка ЦБ РФ, кривая бескупонной доходности ОФЗ, ставки денежного рынка, макроэкономические индикаторы).

Предмет исследования – методы прогнозирования нестационарных временных рядов с экзогенными зависимостями.

Цель работы – построение наиболее точной модели прогнозирования ключевой ставки ЦБ РФ и количественная оценка информативности кривой бескупонной доходности ОФЗ как предиктора.

Задачи исследования:

- формирование набора данных: сбор и предобработка целевой переменной (ключевая ставка, 151 месяц) и 33 экзогенных переменных (КБД ОФЗ, RUONIA, ROISfix, макроиндикаторы);
- реализация и сравнение 16 моделей четырёх классов (параметрические, ансамблевые, нейросетевые, предобученные) на единой схеме валидации (expanding window, 91 шаг);
- количественная оценка информативности признаков через пять методов (built-in importance, SHAP, корреляции Пирсона/Спирмена, permutation importance) и ablation study;
- формальное статистическое сравнение моделей через тест Diebold-Mariano (78 пар) с HAC-оценкой дисперсии;
- исследование горизонтов $h = 3$ и $h = 6$: оценка цены ошибки прогноза экзогенных переменных и роли рыночных ожиданий (ROISfix);
- проверка робастности на данных Казахстана (базовая ставка НБРК, 127 месяцев).
- оценка коэффициента трансмиссии ключевой ставки в RUONIA и ROISfix 3М на горизонтах $h = 1, 3$ и 6 месяцев через сценарный анализ LightGBM; – выявление асимметрии реакции рынка на ужесточение и смягчение денежно-кредитной политики.

Научная новизна:

- проведено первое сравнение 16 моделей, включая foundation models 2024–2025 года (TimeGPT), на задаче прогнозирования ключевой ставки ЦБ РФ. Установлено, что наивный прогноз (случайное блуждание) значительно превосходит все альтернативы при $h = 1$ (тест Diebold-Mariano, $p < 0.05$ для всех пар), что обусловлено дискретной природой ставки;
- количественно оценена роль кривой бескупонной доходности ОФЗ как предиктора ключевой ставки. Пять методов оценки важности согласованно указывают на КБД как на TOP-1 предиктор (7 из 10 наиболее информативных признаков), однако ablation study показал, что при $h = 1$ информация КБД

дублируется лагом целевой переменной ($r = 0.959$). На горизонтах $h = 3$ и $h = 6$ КБД (через ROISfix) вдвое точнее двухстадийного прогноза экзогенных;

– применено формальное статистическое тестирование (DM-тест, 78 пар), разделившее 16 моделей на три группы: лидер (Naive), середина (параметрические модели и TimeGPT, статистически неразличимы) и аутсайдеры (ML и нейросети, статистически неразличимы). Результат устойчив: проверка на базовой ставке НБРК (Казахстан) подтвердила первенство Naive.

Методы исследования: математическая статистика (тесты ADF, KPSS, Diebold-Mariano), модели пространства состояний (ARIMA, ETS, CES, Theta), градиентный бустинг (LightGBM, XGBoost), глубокое обучение (N-BEATS, N-HiTS, PatchTST), предобученные трансформеры (TimeGPT), аксиоматика Шепли (SHAP-значения), квантильная регрессия.

Практическая значимость. Результаты работы могут использоваться при построении систем прогнозирования процентных ставок в банковском секторе. Количественные оценки РТ (0.50 при $h = 1$, затухание до 0.09 при $h = 6$) и асимметрия реакции рынка на ужесточение/смягчение ДКП применимы при моделировании влияния решений ЦБ РФ на стоимость фондирования. Код эксперимента опубликован на диске (Приложение А).

Структура работы. Работа состоит из введения, четырёх глав, заключения, списка литературы и приложения. Глава 1 содержит математическое описание 16 моделей прогнозирования. Глава 2 описывает данные, признаковое пространство и схему эксперимента. Глава 3 представляет результаты вычислительного эксперимента. Глава 4 проверяет робастность на данных Казахстана. Общий объём работы – 128 страниц, включая 57 источников литературы.

1 МАТЕМАТИЧЕСКИЕ МЕТОДЫ ПРОГНОЗИРОВАНИЯ ВРЕМЕННЫХ РЯДОВ

1.1 Постановка задачи прогнозирования

Пусть $\{y_t\}_{t=1}^T$ – наблюдаемая реализация стохастического процесса Y_t , где t – дискретное время (в настоящей работе – месяц). Информационное множество $F_T = \sigma(Y_1, \dots, Y_T)$ – σ -алгебра, порождённая наблюдениями до момента T [9].

Дано: реализация $\{y_1, \dots, y_T\}$ и, возможно, набор экзогенных переменных $\{x_t^{(j)}\}_{j=1}^p, t = 1, \dots, T$

Требуется: построить прогнозную функцию $\hat{f}: F_T \rightarrow R$, минимизирующую ожидаемые потери на горизонте $h \geq 1$:

$$\hat{f} = \operatorname{argmin}_f E[L(Y_{T+h}, f(F_T))], \quad (1.1)$$

где $L(y, \hat{y})$ – функция потерь, определяющая штраф за отклонение прогноза $\hat{y}$ от реализации y [10].

Горизонт прогнозирования h задаёт число шагов вперёд. При $h = 1$ прогнозируется ближайшее будущее значение; при $h > 1$ – значение через h периодов. В настоящей работе основной горизонт $h = 1$ (месяц), дополнительно исследуются $h = 3$ и $h = 6$ (раздел 3.7.4).

Оптимальный прогноз и функция потерь. Вид оптимального прогноза определяется выбором функции потерь $L(y, \hat{y})$. Рассмотрим два основных случая [11].

Квадратичная функция потерь $L(y, \hat{y}) = (y - \hat{y})^2$. Оптимальный прогноз – условное математическое ожидание. Доказательство: градиент ожидаемых потерь по $\hat{y}$ равен:

$$\frac{\partial}{\partial \hat{y}} E[(Y - \hat{y})^2 | F_T] = -2 * E[Y - \hat{y} | F_T] = -2 \cdot (E[Y | F_T] - \hat{y}) \quad (1.2)$$

Приравнивая к нулю, получаем $\hat{y}^* = E[Y_{T+h} | F_T]$. Вторая производная равна $2 > 0$, что подтверждает минимум. Соответствующая метрика качества – среднеквадратичная ошибка:

$$\text{MSE} = \left(\frac{1}{n}\right) \cdot \sum_{t=1}^n (y_t - \hat{y}_t)^2, \text{RMSE} = \sqrt{\text{MSE}}. \quad (1.3)$$

Абсолютная функция потерь $L(y, \hat{y}) = |y - \hat{y}|$. Оптимальный прогноз – условная медиана распределения $Y_{T+h} | F_T$ [11]. Доказательство через субградиент: функция $L(y, \hat{y}) = |y - \hat{y}|$ не дифференцируема при $y = \hat{y}$, но имеет субградиент

$$\frac{\partial L}{\partial \hat{y}} \in \{-\text{sign}(y - \hat{y})\} = \left\{ \begin{array}{l} -1, \text{ если } y > \hat{y}; \\ [-1, 1], \text{ если } y = \hat{y}; \\ +1, \text{ если } y < \hat{y} \end{array} \right\}. \quad (1.4)$$

Условие оптимальности $E \left[\frac{\partial L}{\partial \hat{y}} | F_T \right] \ni 0$ выполняется при

$$E[-\text{sign}(Y - \hat{y}) | F_T] = P(Y < \hat{y} | F_T) - P(Y > \hat{y} | F_T) = 0, \quad (1.5)$$

то есть $P(Y < \hat{y} | F_T) = P(Y > \hat{y} | F_T) = 0.5$, что и есть определение медианы [11]. Соответствующая метрика:

$$\text{MAE} = \left(\frac{1}{n}\right) \cdot \sum_{t=1}^n |y_t - \hat{y}_t|. \quad (1.6)$$

Различие между условным средним и условной медианой существенно при асимметричном распределении ошибок. Для ключевой ставки, подверженной кризисным выбросам (подраздел 2.1), распределение ошибок имеет тяжёлые правые хвосты, и MAE-оптимальный прогноз отличается от

MSE-оптимального. Это объясняет расхождения в ранжировании моделей по MAE и RMSE, наблюдаемые в разделе 3.7.

Помимо MAE и RMSE, в литературе используются процентные метрики [12]. Средняя абсолютная процентная ошибка:

$$\text{MAPE} = \left(\frac{100}{n} \right) \cdot \sum_{t=1}^n \frac{|y_t - \hat{y}_t|}{|y_t|}. \quad (1.7)$$

MAPE не определена при $y_t = 0$, несимметрична (занижение штрафует слабее завышения) и зависит от масштаба ряда. Хайндман и Кёлер [12] показали, что MAPE непригодна для сравнения моделей на рядах с различным масштабом и предложили MASE (Mean Absolute Scaled Error):

$$\text{MASE} = \frac{\text{MAE}}{\text{MAE}_{\text{naive}}}, \quad (1.8)$$

где $\text{MAE}_{\text{naive}} = \left(\frac{1}{T-1} \right) \cdot \sum_{t=2}^T |y_t - y_{t-1}|$ – MAE наивного прогноза на обучающей выборке. $\text{MASE} < 1$ означает, что модель лучше Naive; $\text{MASE} > 1$ – хуже. В настоящей работе основной метрикой выбрана MAE в абсолютных единицах (процентные пункты ставки), поскольку все модели сравниваются на одном ряде и масштабирование не требуется. Формальное сравнение проводится через тест Diebold-Mariano (подраздел 2.4.3).

Классификация моделей прогнозирования. Модели, применяемые в настоящей работе, группируются по способу задания прогнозной функции $\hat{f}$ [10, 9].

Параметрические модели пространства состояний задают $\hat{f}$ через конечномерный вектор параметров $\theta \in R^k$, оцениваемый по обучающей выборке. Модель определяет вероятностную структуру процесса: ARIMA – через характеристический полином (подраздел 1.2.1), ETS – через рекуррентные уравнения пространства состояний (подраздел 1.2.2). Число параметров k фиксировано и мало (от 2 до 10). Прогноз строится аналитически как условное ожидание или медиана.

Непараметрические и ансамблевые модели задают $\hat{f}$ как композицию слабых моделей (деревьев решений) без явных предположений о распределении данных. Градиентный бустинг (подраздел 1.3.2) аппроксимирует $\hat{f}$ в функциональном пространстве последовательным добавлением деревьев. Число параметров велико (порядка $d \cdot T$, где d – глубина дерева, T – число деревьев) и зависит от данных. Прогноз строится как сумма выходов деревьев.

Нейросетевые модели (подраздел 1.4) параметризуют $\hat{f}$ многослойной нейронной сетью с обучаемыми весами. Число параметров может достигать миллионов (N-BEATS: 2.4M), что создаёт риск переобучения на коротких рядах. Архитектура определяет индуктивное смещение: N-BEATS декомпозирует ряд на базисные функции, PatchTST использует механизм внимания между подпоследовательностями.

Foundation models (подраздел 1.5) – предобученные трансформеры, обученные на миллионах рядов и применяемые к новому ряду без дообучения (zero-shot). Прогнозная функция $\hat{f}$ фиксирована; адаптация к конкретному ряду происходит через контекстное окно (prompt), а не через обучение параметров.

Классификация определяет компромисс «смещение–дисперсия» (bias-variance tradeoff) [10]. Параметрические модели имеют высокое смещение (жёсткие предположения о структуре ряда), но низкую дисперсию (мало параметров). Нейросети – низкое смещение (гибкая аппроксимация), но высокую дисперсию (много параметров). Foundation models занимают промежуточную позицию: дисперсия снижена за счёт предобучения, смещение – за счёт общности архитектуры. Для короткого ряда (151 наблюдение) баланс смещается в сторону моделей с низкой дисперсией, что объясняет превосходство параметрических моделей в эксперименте (глава 3).

1.2 Параметрические модели пространства состояний

1.2.1 ARIMA: авторегрессия, интегрирование, скользящее среднее

Класс моделей ARIMA(p, d, q), систематизированный Боксом и Дженкинсом [13], объединяет три генерирующих механизма. Авторегрессионная составляющая порядка p задаёт линейную зависимость текущего значения от p предшествующих; составляющая скользящего среднего порядка q вводит в модель прошлые ошибки прогноза; оператор дифференцирования кратности d переводит нестационарный ряд в стационарный. В операторных обозначениях:

$$\Phi(B)(1 - B)^d \cdot y_t = \theta(B) \cdot \varepsilon_t, \quad (1.9)$$

где B – оператор обратного сдвига ($By_t = y_{t-1}$), d – порядок дифференцирования,

$$\Phi(B) = 1 - \varphi_1 B - \varphi_2 B^2 - \dots - \varphi_p B^p \quad (1.10)$$

– авторегрессионный полином порядка p,

$$\theta(B) = 1 + \theta_1 B + \theta_2 B^2 + \dots + \theta_q B^q \quad (1.11)$$

– полином скользящего среднего порядка q, $\varepsilon_t \sim WN(0, \sigma^2)$ – белый шум (последовательность некоррелированных случайных величин с нулевым средним и постоянной дисперсией σ^2).

Раскрывая операторную запись для ARIMA(p, d, q), получаем уравнение в разностях:

$$w_t = \varphi_1 w_{t-1} + \dots + \varphi_p w_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}, \quad (1.12)$$

где $w_t = (1 - B)^d \cdot y_t$ – ряд после d-кратного дифференцирования. При d = 0 модель сводится к стационарной ARMA(p, q); при p = 0 – к IMA(d, q); при q = 0 – к ARI(p, d).

Условия стационарности и обратимости. Процесс ARMA(p, q) (то есть w_t) стационарен тогда и только тогда, когда все корни характеристического уравнения

$$\Phi(z) = 1 - \varphi_1 z - \varphi_2 z^2 - \dots - \varphi_p z^p = 0 \quad (1.13)$$

лежат строго вне единичного круга на комплексной плоскости: $|z_i| > 1$ для всех $i = 1, \dots, p$ [13]. Если хотя бы один корень $|z_i| = 1$, процесс содержит единичный корень и нестационарен, что требует дифференцирования ($d \geq 1$). Если $|z_i| < 1$, процесс взрывной и непригоден для моделирования.

Аналогично, МА-компонента обратима (представима в виде бесконечного AR-процесса) тогда и только тогда, когда все корни уравнения

$$\theta(z) = 1 + \theta_1 z + \theta_2 z^2 + \dots + \theta_q z^q = 0 \quad (1.14)$$

лежат строго вне единичного круга [13]. Обратимость обеспечивает единственность МА-представления и устойчивость оценок параметров.

Тестирование стационарности. Порядок дифференцирования d определяется до оценки параметров φ и θ . Для этого применяются тесты единичного корня.

Расширенный тест Дики–Фуллера (ADF), разработанный в работе [14], использует следующую вспомогательную регрессию:

$$\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + \sum_{i=1}^p \delta_i \Delta y_{t-i} + \varepsilon_t, \quad (1.15)$$

Лагированные разности Δy_{t-i} введены в правую часть для устранения серийной корреляции остатков; число лагов p подбирается по информационному критерию AIC [15]. Нулевая гипотеза $H_0: \gamma = 0$ отвечает наличию единичного корня, альтернатива $H_1: \gamma < 0$ – стационарности. Тестовая статистика $\hat{\gamma} / SE(\hat{\gamma})$ не имеет стандартного нормального предельного

распределения: табличные критические значения, зависящие от набора детерминированных регрессоров (константа, тренд), получены Дики и Фуллером методом статистического моделирования [14].

Тест KPSS (Квятковский, Филлипс, Шмидт, Шин) [16] проверяет противоположную гипотезу: H_0 : ряд стационарен (вокруг детерминированного тренда), H_1 : ряд нестационарен. Тестовая статистика основана на кумулятивных суммах остатков регрессии y_t на константу и тренд:

$$KPSS = \left(\frac{1}{T^2} \right) \cdot \sum_{t=1}^T \frac{S_t^2}{\hat{\sigma}_\varepsilon^2}, \quad (1.16)$$

где $S_t = \sum_{i=1}^t \hat{\varepsilon}_i$ – частичная сумма остатков, $\hat{\sigma}_\varepsilon^2$ – состоятельная оценка долгосрочной дисперсии. Совместное применение ADF и KPSS повышает надёжность вывода (подраздел 2.3.1).

Идентификация порядков p и q . После определения d (и перехода к стационарному ряду $w_t = \Delta^d y_t$) порядки p и q идентифицируются по структуре автокорреляционной (ACF) и частичной автокорреляционной (PACF) функций [13].

Для процесса AR(p): PACF обрывается после лага p ($PACF(k) = 0$ при $k > p$), ACF затухает экспоненциально или осциллирует. Для процесса MA(q): ACF обрывается после лага q ($ACF(k) = 0$ при $k > q$), PACF затухает. Для смешанного ARMA(p, q): обе функции затухают без резкого обрыва, и идентификация по ACF/PACF затруднена.

На практике перебор комбинаций (p, q) выполняется автоматически с использованием информационного критерия Акаике [15]:

$$AIC = 2k - 2 \ln \hat{L}, \quad (1.17)$$

где $k = p + q + 1$ (число оцениваемых параметров плюс σ^2), $\hat{L}$ – максимум функции правдоподобия. AIC штрафует за увеличение числа параметров (слагаемое $2k$) и поощряет лучшее приближение к данным (слагаемое $-2 \ln \hat{L}$). Модель с минимальным AIC выбирается как оптимальная.

Функция правдоподобия. При предположении нормальности $\varepsilon_t \sim N(0, \sigma^2)$ логарифм функции правдоподобия для ARIMA(p,d,q) записывается как:

$$\ln L(\varphi, \theta, \sigma^2 | w) = -\left(\frac{T}{2}\right) \ln(2\pi) - \left(\frac{T}{2}\right) \ln \sigma^2 - \left(\frac{1}{2\sigma^2}\right) \sum_{t=1}^T \varepsilon_t^2(\varphi, \theta), \quad (1.18)$$

где $\varepsilon_t(\varphi, \theta) = w_t - \varphi_1 w_{t-1} - \dots - \varphi_p w_{t-p} - \theta_1 \varepsilon_{t-1} - \dots - \theta_q \varepsilon_{t-q}$ – ошибки, вычисляемые рекурсивно (при известных начальных значениях). Максимизация $\ln L$ по $(\varphi, \theta, \sigma^2)$ выполняется численно; оценка $\hat{\sigma}^2$ при фиксированных $\hat{\varphi}, \hat{\theta}$ равна $\hat{\sigma}^2 = \left(\frac{1}{T}\right) \sum \hat{\varepsilon}_t^2$.

Процедура AutoARIMA. Автоматический подбор ARIMA(p,d,q) реализован в библиотеках pmdarima и StatsForecast через пошаговый алгоритм Хайндмана-Хандакара [10]. Алгоритм: (1) определить d по тесту KPSS; (2) оценить стартовую модель ARIMA(2,d,2); (3) варьировать p и q на ± 1 , выбирая модель с минимальным AIC; (4) повторять до сходимости. Пошаговый поиск (stepwise = True) требует $O(p_{max} + q_{max})$ оценок модели вместо $O(p_{max} * q_{max})$ при полном переборе.

В вычислительном эксперименте (раздел 3.1) AutoARIMA на 91 шаге expanding window чаще всего выбирал спецификацию ARIMA(0,1,1) (29% шагов), ARIMA(1,0,3) (21%) и ARIMA(1,0,1) (19%). Преобладание d = 1 согласуется с результатами тестов ADF/KPSS (подраздел 2.3.1), показавших нестационарность ключевой ставки в уровнях. Нестабильность выбранной спецификации отражает изменение автокорреляционной структуры ряда по мере расширения обучающего окна.

Прогноз. Оптимальный h-шаговый прогноз ARIMA строится рекурсивно. Для ARIMA(0,1,1) при h = 1:

$$\hat{y}_{T+1} = y_T + \hat{\theta}_1 \cdot \hat{\varepsilon}_T, \quad (1.19)$$

где $\hat{\varepsilon}_T = y_T - \hat{y}_T$ – оценка последней ошибки. При $|\hat{\theta}_1| < 1$ прогноз представляет собой экспоненциально взвешенное скользящее среднее

прошлых значений, что объясняет близость ARIMA(0,1,1) к методу простого экспоненциального сглаживания [10].

1.2.2 ETS: экспоненциальное сглаживание в форме пространства состояний

Семейство методов экспоненциального сглаживания основано на принципе убывания информативности: каждое прошлое наблюдение входит в прогноз с весом, экспоненциально уменьшающимся по мере удаления в прошлое. В монографии [17] показано, что большинство таких методов допускает единую формализацию в виде модели пространства состояний ETS, где аббревиатура расшифровывается по трём компонентам. Компонента E (error, ошибка) принимает одно из двух значений: аддитивная (A) или мультипликативная (M). Компонента T (trend, тренд) описывает динамику уровня: тренд отсутствует (N), линейный (A) или затухающий (Ad). Компонента S (seasonality, сезонность) характеризует периодическую составляющую: отсутствует (N), аддитивная (A) или мультипликативная (M).

Комбинация типов определяет конкретную модель. Например, ETS(A,A,N) – аддитивная ошибка, аддитивный тренд, без сезонности (модель Хольта). Всего возможно $2 \times 3 \times 3 = 18$ моделей; при `season_length = 1` (отсутствие сезонности, как в настоящей работе) пространство сокращается до $2 \times 3 = 6$ моделей.

Модель пространства состояний. Запишем уравнения для модели ETS(A,A,N) – аддитивная ошибка, аддитивный тренд, без сезонности [17, 10]:

Уравнение наблюдения:

$$y_t = l_{t-1} + b_{t-1} + \varepsilon_t \quad (1.20)$$

Уравнения состояния:

$$l_t = l_{t-1} + b_{t-1} + \alpha \cdot \varepsilon_t, \quad (1.21)$$

$$b_t = b_{t-1} + \beta \cdot \varepsilon_t, \quad (1.22)$$

где l_t – уровень ряда в момент t , b_t – наклон тренда, $\alpha \in (0, 1)$ – параметр сглаживания уровня, $\beta \in (0, 1)$ – параметр сглаживания тренда, ε_t – ошибка прогноза (инновация). Уравнение (1.20) определяет наблюдение как сумму предыдущего уровня, предыдущего тренда и ошибки. Уравнения (1.21)–(1.22) обновляют ненаблюдаемые состояния l_t и b_t после поступления нового наблюдения y_t .

Смысл параметра α : при $\alpha \rightarrow 0$ уровень l_t обновляется медленно и прогноз определяется далёкой историей; при $\alpha \rightarrow 1$ прогноз реагирует почти исключительно на последнее наблюдение. Параметр β аналогично управляет адаптивностью тренда.

При включении затухающего тренда (A_d) уравнение тренда модифицируется:

$$b_t = \varphi \cdot b_{t-1} + \beta \cdot \varepsilon_t, \quad (1.23)$$

где $\varphi \in (0, 1)$ – параметр затухания. При $\varphi < 1$ тренд экспоненциально затухает к нулю с ростом горизонта, что предотвращает неограниченную экстраполяцию линейного тренда. h -шаговый прогноз для модели с затухающим трендом:

$$\hat{y}_{T+h|T} = l_T + (\varphi + \varphi^2 + \dots + \varphi^h)b_T = l_T + \varphi \frac{(1 - \varphi^h)}{1 - \varphi} b_T \quad (1.24)$$

При $h \rightarrow \infty$ прогноз сходится к $l_T + \varphi/(1 - \varphi) \cdot b_T$ – горизонтальной асимптоте, а не расходится. Для ключевой ставки, где тренд нестабилен (подраздел 2.1), затухающая модель предпочтительнее линейной.

Модель с сезонностью. При наличии сезонной компоненты с периодом m уравнения дополняются состоянием s_t . Для аддитивной сезонности ETS(A,A,A):

$$y_t = l_{t-1} + b_{t-1} + s_{t-m} + \varepsilon_t, \quad (1.25)$$

$$l_t = l_{t-1} + b_{t-1} + \alpha \cdot \varepsilon_t, \quad (1.26)$$

$$b_t = b_{t-1} + \beta \cdot \varepsilon_t, \quad (1.27)$$

$$s_t = s_{t-m} + \gamma \cdot \varepsilon_t, \quad (1.28)$$

где $\gamma \in (0,1)$ – параметр сглаживания сезонности, s_t – сезонный компонент. Для мультипликативной сезонности ETS(A,A,M) операция сложения с s_{t-m} заменяется умножением. В настоящей работе `season_length = 1`, что отключает сезонную компоненту и исключает уравнение (1.28) из модели.

Функция правдоподобия и оценивание параметров. Для модели с аддитивной ошибкой при $\varepsilon_t \sim N(0, \sigma^2)$ логарифм функции правдоподобия:

$$\begin{aligned} \ln L(\alpha, \beta, l_0, b_0, \sigma^2 | y) = & -\left(\frac{T}{2}\right) \ln(2\pi) - \left(\frac{T}{2}\right) \ln \sigma^2 - \\ & - \left(\frac{1}{2\sigma^2}\right) \sum_{t=1}^T \varepsilon_t^2, \end{aligned} \quad (1.29)$$

где $\varepsilon_t = y_t - l_{t-1} - b_{t-1}$ вычисляются рекурсивно из (1.20)–(1.22) при заданных начальных состояниях (l_0, b_0) . Для мультипликативной ошибки $\left(\varepsilon_t = \frac{y_t - \mu_t}{\mu_t}, \text{ где } \mu_t = l_{t-1} + b_{t-1}\right)$ правдоподобие содержит дополнительный якобиан: $\ln L$ включает слагаемое $-\sum \ln|\mu_t|$ [17].

Параметры $(\alpha, \beta, l_0, b_0)$ оцениваются численной максимизацией $\ln L$. Число оцениваемых параметров невелико: 2 параметра сглаживания + 2 начальных состояния = 4 (при отсутствии сезонности); для модели с сезонностью добавляются γ и m начальных сезонных коэффициентов.

Автоматический выбор модели (ZZZ). Режим `AutoETS(model='ZZZ')` перебирает все допустимые комбинации типов (E, T, S) и выбирает модель с минимальным AIC [17]:

$$\text{AIC} = -2 \ln \hat{L} + 2k, \quad (1.30)$$

где k – число оцениваемых параметров (сглаживания + начальные состояния). При `season_length = 1` перебираются 6 моделей: (A,N,N), (A,A,N), (A,A_d,N), (M,N,N), (M,A,N), (M,A_d,N). Мультипликативная ошибка (M) допустима только при $y_t > 0$, что выполняется для ключевой ставки (минимум 4.25%).

Связь с ARIMA. Модель ETS(A,N,N) (простое экспоненциальное сглаживание) эквивалентна ARIMA(0,1,1) с $\theta_1 = \alpha - 1$ [10]. Модель ETS(A,A,N) (линейный метод Хольта) эквивалентна ARIMA(0,2,2). Эквивалентность означает, что точечные прогнозы совпадают, хотя предсказательные интервалы могут различаться из-за разных предположений о структуре ошибок. Преобладание ARIMA(0,1,1) в эксперименте (подраздел 1.2.1) согласуется с тем, что AutoETS часто выбирает модель ETS(A,N,N) или ETS(A, A_d ,N) с сильным затуханием тренда.

В вычислительном эксперименте (раздел 3.2) AutoETS показал MAE = 0.661 п.п., уступив AutoTheta (0.582) и Naive (0.569), но превзойдя AutoARIMA (0.717). Покрытие 95%-го предсказательного интервала составило 96.7% – наиболее консервативная калибровка среди четырёх моделей StatsForecast.

1.2.3 CES: комплексное экспоненциальное сглаживание

Метод CES, введённый Светунковым, Курентзесом и Ордом [18], расширяет классическое экспоненциальное сглаживание на область комплексных чисел. Авторы опираются на то, что умножение вектора на комплексное число единичной нормы равносильно повороту на фиксированный угол, а последовательность поворотов порождает периодическую (тригонометрическую) функцию. Благодаря этому одно рекуррентное уравнение с двумя параметрами одновременно описывает и уровень ряда, и его сезонную составляющую.

Рекуррентное уравнение CES записывается в комплекснозначной форме [18]:

$$\tilde{y}_t = (\alpha_0 + i\alpha_1) \cdot \tilde{y}_{t-1} + (1 - \alpha_0 - i\alpha_1) \cdot y_t, \quad (1.31)$$

где $\tilde{y}_t \in \mathbb{C}$ – комплекснозначное сглаженное состояние, $y_t \in \mathbb{R}$ – наблюдение (вещественное), $\alpha_0, \alpha_1 \in \mathbb{R}$ – параметры сглаживания, $i = \sqrt{-1}$. Прогноз формируется как вещественная часть $\tilde{y}_t$:

$$\hat{y}_{t+1} = \text{Re}(\tilde{y}_t). \quad (1.32)$$

Разделяя вещественную и мнимую части $\tilde{y}_t = a_t + i b_t$, получаем систему:

$$a_t = \alpha_0 \cdot a_{t-1} - \alpha_1 \cdot b_{t-1} + (1 - \alpha_0) \cdot y_t, \quad (1.33)$$

$$b_t = \alpha_1 \cdot a_{t-1} + \alpha_0 \cdot b_{t-1} - \alpha_1 \cdot y_t. \quad (1.34)$$

Вещественная часть a_t играет роль уровня (аналог l_t в ETS), а мнимая часть b_t моделирует фазовый сдвиг. Произведение комплексных чисел $(\alpha_0 + i\alpha_1) \cdot (a_{t-1} + ib_{t-1})$ включает вращение на угол $\varphi = \arctan\left(\frac{\alpha_1}{\alpha_0}\right)$ и масштабирование на $|\alpha_0 + i\alpha_1| = \sqrt{(\alpha_0^2 + \alpha_1^2)}$. Если $|\alpha_0 + i\alpha_1| < 1$, состояние затухает; если $\alpha_1 \neq 0$, возникает осциллирующая компонента с периодом $\frac{2\pi}{\varphi}$.

Связь с тригонометрическими функциями следует из полярного представления. Пусть $\alpha_0 + i\alpha_1 = r \cdot e^{i\varphi}$, где $r = \sqrt{(\alpha_0^2 + \alpha_1^2)}$, $\varphi = \arctan\left(\frac{\alpha_1}{\alpha_0}\right)$. Тогда k -кратное применение оператора сглаживания к начальному состоянию $\tilde{y}_0$ порождает компоненту $r^k \cdot (\cos(k\varphi) + i \sin(k\varphi)) \cdot \tilde{y}_0$, то есть затухающую синусоиду. Для ряда с выраженной сезонностью периода m оптимальное φ стремится к $\frac{2\pi}{m}$, и CES воспроизводит сезонный паттерн через вращение. Для ряда без сезонности (как ключевая ставка) оптимальное α_1 стремится к нулю, и CES вырождается в классическое простое экспоненциальное сглаживание.

Оценивание параметров. Параметры α_0 , α_1 и начальные состояния (a_0, b_0) оцениваются максимизацией функции правдоподобия, аналогичной (1.29), с ограничением устойчивости: $|\alpha_0 + i\alpha_1| < 1$. Число оцениваемых параметров – 4, что сопоставимо с ETS(A,A,N). Автоматический подбор в StatsForecast (AutoCES) выполняет оптимизацию численно.

Преимущества и ограничения. CES обладает двумя математическими свойствами, отличающими его от классического ETS [18]. Одним уравнением

(1.31) с двумя параметрами CES моделирует и уровень, и сезонность, тогда как ETS(A,A,A) требует трёх уравнений и трёх параметров (α , β , γ). Кроме того, CES допускает нецелочисленные периоды сезонности (частота вращения ϕ не привязана к целому m), что полезно для рядов с плавающей сезонностью. Для рядов без сезонности оба преимущества нерелевантны: при $\alpha_1 \approx 0$ CES сводится к простому экспоненциальному сглаживанию и не может превзойти ETS, обладающий бóльшим пространством моделей (6 спецификаций при $\text{season_length} = 1$ против 1 у CES).

В вычислительном эксперименте (раздел 3.2) CES показал MAE = 0.728 п.п., худший среди четырёх моделей StatsForecast. Результат согласуется с теоретическим ожиданием: для ряда, где сезонная компонента составляет 0.9% дисперсии (подраздел 2.3.3), механизм комплексного вращения не задействован, а дополнительная параметризация (α_1, b_0) не оправдана.

1.2.4 Метод Theta

Метод Theta, разработанный Ассимакопулосом и Николопулосом [19], строит прогноз через попарное сравнение специально сконструированных трансформаций исходного ряда – так называемых θ -линий, различающихся степенью усиления или сглаживания кривизны. На M3-competition [20], охватившем 3003 ряда различной природы и длины, метод обошёл все конкурирующие подходы.

θ -трансформация. Для заданного параметра $\theta \geq 0$ определяется θ -линия:

$$Z_{\theta}(t) = \theta \cdot y_t + (1 - \theta) \cdot L_t, \quad (1.35)$$

где y_t – исходный ряд, L_t – линейный тренд, оценённый методом наименьших квадратов по $\{y_1, \dots, y_T\}$. Параметр θ управляет кривизной θ -линии. При $\theta = 0$ получаем $Z_0(t) = L_t$ – чистый линейный тренд. При $\theta = 1$ получаем $Z_1(t) = y_t$ – исходный ряд без изменений. При $\theta = 2$ кривизна исходного ряда удваивается: $Z_2(t) = 2y_t - L_t$, что усиливает локальные колебания.

Связь с вторыми разностями: θ -трансформация модифицирует вторую производную ряда. Если $\Delta^2 y_t = y_t - 2y_{t-1} + y_{t-2}$, то $\Delta^2 Z_\theta(t) = \theta \cdot \Delta^2 y_t$, поскольку $\Delta^2 L_t = 0$ для линейного тренда [19]. При $\theta > 1$ колебания усиливаются, при $\theta < 1$ – сглаживаются.

Оригинальный метод (M3-competition). В варианте, победившем в M3-competition [19, 20], используются две θ -линии: $\theta = 0$ (линейный тренд) и $\theta = 2$ (усиленная кривизна). Прогноз строится в три шага:

1. Линия $Z_0(t) = L_t$ прогнозируется экстраполяцией линейного тренда: $\hat{Z}_0(T+h) = \hat{a} + \hat{b} \cdot (T+h)$.

2. Линия $Z_2(t) = 2y_t - L_t$ прогнозируется методом простого экспоненциального сглаживания (SES): $\hat{Z}_2(T+h) = SES_h(Z_2)$.

3. Итоговый прогноз – среднее арифметическое:

$$\hat{y}_{T+h} = \left(\frac{1}{2}\right) \cdot (\hat{Z}_0(T+h) + \hat{Z}_2(T+h)). \quad (1.36)$$

Хайндман и Биллах показали, что при $\theta = 2$ и равных весах метод Theta эквивалентен простому экспоненциальному сглаживанию с линейным дрейфом, то есть частному случаю ETS(A, A_d, N) при определённых значениях параметров [10]. Эта эквивалентность объясняет, почему Theta и ETS показывают близкие результаты на многих рядах.

AutoTheta. Обобщённая версия AutoTheta, реализованная в StatsForecast [52], расширяет оригинальный метод: оптимальное значение θ и параметр сглаживания α подбираются по данным (через минимизацию ошибки на обучающей выборке), а не фиксируются. Кроме того, AutoTheta автоматически определяет необходимость дифференцирования (аналогично выбору d в ARIMA) и применяет мультипликативную или аддитивную декомпозицию в зависимости от характера ряда.

Число оцениваемых параметров AutoTheta невелико: 2–3 (θ , α и, возможно, параметр тренда). Это делает метод устойчивым к переобучению

на коротких рядах. Вычислительная сложность сопоставима с SES: $O(n)$ для одного прогноза.

В вычислительном эксперименте (раздел 3.2) AutoTheta показал MAE = 0.582 п.п. – лучший результат среди всех параметрических моделей и ближайший к Naive (0.569). Разница в 0.014 п.п. статистически значима по тесту Diebold-Mariano ($p = 0.0005$, раздел 3.7.2), но по абсолютной величине минимальна. Успех AutoTheta на ключевой ставке объясняется сочетанием двух свойств: адаптивный тренд (через SES-компоненту) и консервативная экстраполяция (через линейную компоненту). Для кусочно-постоянного ряда, где тренд периодически обнуляется, такая комбинация ближе к Naive, чем полноценная ARIMA с оцениваемыми AR/MA-коэффициентами.

1.2.5 Квантильная регрессия и интервальные прогнозы

Стандартные модели временных рядов минимизируют MSE и выдают точечный прогноз условного среднего $E[y_{T+h}|F_T]$. Для построения интервальных прогнозов нужны условные квантили распределения прогнозируемой величины.

Квантильная регрессия [21] ищет функцию $q_\tau(x)$, минимизирующую ожидаемые потери по асимметричной функции pinball:

$$L_{\tau}(y, \hat{y}) = \tau \cdot (y - \hat{y}) \cdot \mathbb{1}[y \geq \hat{y}] + (1 - \tau) \cdot (\hat{y} - y) \cdot \mathbb{1}[y < \hat{y}], \quad (1.37)$$

где $\tau \in (0, 1)$ – целевой уровень квантиля, $\mathbb{1}[\cdot]$ – индикаторная функция. При $\tau = 0.5$ функция потерь совпадает с MAE с точностью до константы, и оценка обращается в условную медиану. Интервал с номинальным покрытием $(1 - \alpha)$ строится как разность прогнозов квантилей $\tau = \frac{\alpha}{2}$ и $\tau = 1 - \frac{\alpha}{2}$.

В градиентном бустинге квантильная регрессия получается заменой стандартной функции потерь на pinball при фиксированном τ . В данной работе этот подход на базе LightGBM используется для построения 90%- и 95%-интервалов прогноза ключевой ставки (подраздел 3.4.4).

1.3 Непараметрические и ансамблевые методы

1.3.1 Переход от временного ряда к задаче регрессии

Параметрические модели (ARIMA, ETS, CES, Theta) работают непосредственно с временным рядом $\{y_t\}$ и строят прогноз на основе внутренней структуры ряда (автокорреляции, тренда, сезонности). Непараметрические методы, такие как градиентный бустинг, решают задачу прогнозирования как стандартную задачу регрессии: на вход подаётся вектор признаков $x_t \in R^d$, на выход – скаляр y_{t+h} [10, 22]. Это требует явного конструирования признакового пространства (feature engineering) из исходного ряда и экзогенных переменных.

Формально: задача прогнозирования y_{T+h} по информации F_T переформулируется как

$$y_{T+h} = f(x_T) + \varepsilon, \quad (1.38)$$

где $x_T = (x_T^{(1)}, x_T^{(2)}, \dots, x_T^{(d)})^T$ – вектор признаков, вычисленных из доступной на момент T информации, $f: R^d \rightarrow R$ – неизвестная функция, ε – ошибка. Задача модели – аппроксимировать f по обучающей выборке $\{(x_t, y_{t+h})\}_{t=1}^{T-h}$.

Признаки группируются в пять блоков [10]: Лаги целевой переменной. Значения ряда в прошлые моменты времени: $x_T^{(k)} = y_{T-k+1}$ для $k = 1, 2, 3, 6, 12$. Лаг 1 несёт максимум информации для авторегрессионных процессов; лаги 6 и 12 улавливают полугодовую и годовую динамику. Лаги – ближайший аналог AR-компоненты ARIMA: модель $AR(p)$ эквивалентна линейной регрессии на лагах 1, ..., p. Отличие непараметрических моделей в том, что зависимость $f(x)$ от лагов не обязана быть линейной.

Скользящие статистики. Агрегированные характеристики ряда на скользящем окне длины W:

$$\text{rolling_mean_W}(T) = \left(\frac{1}{W}\right) \cdot \sum_{k=1}^W y_{T-k}, \quad (1.39)$$

$$\text{rolling_std_W}(T) = \sqrt{\left(\frac{1}{W-1}\right) \cdot \sum_{k=1}^W \left(y_{T-k} - \text{rolling_mean_W}(T)\right)^2}. \quad (1.40)$$

Скользящее среднее характеризует текущий уровень ряда (аналог l_t в ETS), стандартное отклонение – волатильность (аналог масштаба инноваций σ). В настоящей работе использованы окна $W \in \{3, 6, 12\}$. Все статистики вычисляются со сдвигом на 1 (суммирование по $y_{T-1}, \dots, y_{T-W}$), чтобы не включать текущее значение y_T и предотвратить утечку информации из будущего.

Разности. Изменения ряда за различные периоды:

$$\text{diff}_k(T) = y_{T-1} - y_{T-1-k}, k \in \{1, 3, 6\}. \quad (1.41)$$

Разности характеризуют направление и скорость изменения ряда. diff_1 соответствует первой разности Δy_{T-1} (аналог $d = 1$ в ARIMA), diff_6 – полугодовому изменению. Для дискретно изменяющейся ставки разности принимают значения из ограниченного множества $(0, \pm 0.25, \pm 0.50, \dots)$, что создаёт естественную дискретизацию признака.

Лагированные экзогенные переменные. Для каждой экзогенной переменной $x_t^{(j)}$ (CPI, M2, USD/RUB, Brent, точки КБД, RUONIA, спреды) вычисляются значения с лагами 1 и 3:

$$x_T^{(j, \text{lag}_k)} = x_{T-k}^{(j)}, k \in \{1, 3\}. \quad (1.42)$$

Лег 1 обеспечивает доступность значения на момент прогнозирования: при прогнозировании y_{T+1} экзогенная переменная $x_T^{(j)}$ может быть ещё недоступна (публикуется с задержкой), тогда как $x_{T-1}^{(j)}$ заведомо известна. Лег 3 позволяет уловить запаздывающие зависимости, выявленные кросс-корреляционным анализом (подраздел 2.3.2): например, Brent максимально коррелирован с ключевой ставкой при лаге 12, USD/RUB – при лаге 1.

Календарные признаки. Номер месяца (1–12) и квартала (1–4). Хотя STL-декомпозиция не выявила сезонности в самой ставке (подраздел 2.3.3), заседания Совета директоров ЦБ РФ проводятся по фиксированному графику, и календарные признаки могут уловить эту структуру через пороговые разбиения дерева.

Предотвращение data leakage. При конструировании признаков для прогнозирования y_{T+h} каждый признак $x_T^{(k)}$ должен быть вычислим исключительно из данных, доступных на момент T [10, 22]. Нарушение этого условия (data leakage) приводит к завышению точности на валидации и невоспроизводимости результатов на реальных данных. В настоящей работе data leakage предотвращается на двух уровнях:

- на уровне целевой переменной: лаги и скользящие статистики вычисляются с минимальным сдвигом 1 (y_{T-1} , а не y_T);
- на уровне экзогенных переменных: используются лаги 1 и 3, а не текущие значения $x_T^{(j)}$;
- на уровне валидации: expanding window (подраздел 2.4.2) гарантирует, что модель на шаге T обучается только на $\{y_1, \dots, y_T\}$ и не имеет доступа к будущим данным.

Итого в настоящей работе сконструировано 34 признака: 5 лагов, 6 скользящих статистик, 3 разности, 18 лагированных экзогенных (9 переменных $\times$ 2 лага) и 2 календарных. После удаления строк с пропусками (из-за лага 12) остаётся 137 наблюдений. Подробный состав признаков и результаты их оценки приведены в подразделах 3.4.1 и 3.4.2.

1.3.2 Градиентный бустинг: LightGBM и XGBoost

Градиентный бустинг (Gradient Boosting) [23] – метод построения ансамбля моделей путём последовательной аппроксимации функционала потерь в функциональном пространстве. В отличие от параметрических моделей (ARIMA, ETS), которые задают аналитическую форму зависимости y

от прошлых значений, градиентный бустинг аппроксимирует произвольную нелинейную функцию $f(x)$ композицией слабых моделей (деревьев решений).

Общая схема. Пусть задана обучающая выборка $\{(x_i, y_i)\}_{i=1}^n$ и дифференцируемая функция потерь $L(y, \hat{y})$. Градиентный бустинг строит ансамбль из M деревьев решений итеративно [23]:

$$F_0(x) = \operatorname{argmin}_c \sum_{i=1}^n L(y_i, c), \quad (1.43)$$

$$F_m(x) = F_{m-1}(x) + \eta \cdot h_m(x), m = 1, \dots, M, \quad (1.44)$$

где $F_m(x)$ – прогноз ансамбля после m -й итерации, $h_m(x)$ – дерево решений, обученное на m -м шаге, $\eta \in (0, 1]$ – скорость обучения (learning rate), контролирующая вклад каждого нового дерева.

На каждом шаге m дерево h_m обучается предсказывать антиградиент (псевдо-остатки) функции потерь:

$$r_{im} = -\frac{\partial L(y_i, \hat{y})}{\partial \hat{y}} \Big|_{\hat{y}=F_{m-1}(x_i)}, i = 1, \dots, n. \quad (1.45)$$

Для квадратичной функции потерь $L(y, \hat{y}) = (y - \hat{y})^2$ антиградиент равен $r_{im} = y_i - F_{m-1}(x_i)$, то есть остаткам текущего ансамбля. Для абсолютной функции потерь $L(y, \hat{y}) = |y - \hat{y}|$ антиградиент равен $r_{im} = \operatorname{sign}(y_i - F_{m-1}(x_i))$. Каждое новое дерево, таким образом, обучается предсказывать ошибки предыдущего ансамбля.

XGBoost. В работе [24] функционал стандартного градиентного бустинга расширен: к функции потерь добавлен явный штраф, ограничивающий структурную сложность каждого дерева ансамбля. Целевая функция на шаге m :

$$\operatorname{Obj}^{(m)} = \sum_{i=1}^n L(y_i, F_{m-1}(x_i) + h_m(x_i)) + \Omega(h_m), \quad (1.46)$$

где $\Omega(h_m) = \gamma \cdot J + \left(\frac{1}{2}\right) \cdot \lambda \cdot \sum_{j=1}^J w_j^2$ – штраф за сложность: J – число листьев дерева h_m , w_j – вес (выход) j -го листа, γ – штраф за число листьев (L1-

регуляризация структуры), λ – штраф за величину весов (L2-регуляризация). Дополнительно может применяться L1-штраф $\alpha \cdot \sum |w_j|$.

Для аналитической разрешимости задачи оптимизации Чен и Гестрин [24] заменяют точную функцию потерь её квадратичным приближением через разложение Тейлора второго порядка:

$$L(y_i, F_{m-1} + h_m) \approx L(y_i, F_{m-1}) + g_i \cdot h_m(x_i) + \left(\frac{1}{2}\right) \cdot h_i \cdot h_m^2(x_i), \quad (1.47)$$

где $g_i = \frac{\partial L}{\partial \hat{y}}|_{\{\hat{y}=F_{m-1}\}}$ – градиент, $h_i = \frac{\partial^2 L}{\partial \hat{y}^2}|_{\{\hat{y}=F_{m-1}\}}$ – гессиан. После подстановки (1.46) в (1.45) и группировки наблюдений по листьям (I_j – множество индексов, попавших в лист j) оптимальный вес листа:

$$w_j^* = -\frac{\left(\sum_{i \in I_j} g_i\right)}{\left(\sum_{i \in I_j} h_i + \lambda\right)}, \quad (1.48)$$

а оптимальное значение целевой функции:

$$Obj^* = -\left(\frac{1}{2}\right) \cdot \sum_{j=1}^J \frac{\left(\sum_{i \in I_j} g_i\right)^2}{\sum_{i \in I_j} h_i + \lambda} + \gamma J. \quad (1.49)$$

Формула (1.48) используется как критерий качества при выборе разбиений (сплитов) дерева. Для каждого потенциального сплита вычисляется выигрыш (gain):

$$Gain = \left(\frac{1}{2}\right) \cdot \left[\left(\frac{G_L^2}{H_L + \lambda}\right) + \left(\frac{G_R^2}{H_R + \lambda}\right) - \left(\frac{(G_L + G_R)^2}{H_L + H_R + \lambda}\right) \right] - \gamma, \quad (1.50)$$

где $G_L = \sum_{i \in I_L} g_i$, $H_L = \sum_{i \in I_L} h_i$ – суммы градиентов и гессианов в левом поддереве, аналогично для правого. Сплит принимается, если $Gain > 0$; штраф γ предотвращает создание малоинформативных листьев.

XGBoost строит деревья level-wise: на каждом уровне разбиваются все листы одновременно. Это обеспечивает сбалансированные деревья, но может приводить к лишним разбиениям в неинформативных ветвях.

LightGBM. Ке и др. [25] предложили три модификации, ускоряющие обучение:

Leaf-wise рост дерева. Вместо одновременного разбиения всех листов (level-wise) LightGBM на каждом шаге разбивает только тот лист, который даёт максимальный Gain. Это приводит к несбалансированным деревьям, которые при одинаковом числе листьев достигают меньшей ошибки, чем level-wise деревья [25]. Ограничение max_depth предотвращает чрезмерную глубину.

Гистограммная аппроксимация. Вместо перебора всех n возможных порогов разбиения для непрерывного признака LightGBM дискретизирует значения признаков в B бинов (по умолчанию $B = 255$) и ищет оптимальный сплит среди B порогов. Сложность поиска сплита снижается с $O(n \cdot d)$ до $O(B \cdot d)$, где d – число признаков [25].

GOSS (Gradient-based One-Side Sampling). Наблюдения с малыми градиентами $|g_i|$ вносят малый вклад в Gain и могут быть подвыбраны. GOSS сохраняет все наблюдения с $|g_i|$ выше порога и случайную подвыборку из остальных, что ускоряет обучение без потери точности [25].

Функционал оптимизации LightGBM аналогичен XGBoost (формулы 1.45–1.49), но без обязательного вычисления гессиана: для функций потерь с постоянным гессианом (MSE: $h_i = 2$, MAE: h_i не определён) LightGBM использует специализированные алгоритмы.

Гиперпараметры. Оба метода контролируются набором гиперпараметров: число деревьев M (n_estimators), максимальная глубина (max_depth), скорость обучения η (learning_rate), доля наблюдений на дерево (subsample), доля признаков на дерево (colsample_bytree), регуляризация (reg_alpha, reg_lambda). В настоящей работе гиперпараметры зафиксированы:

$M = 200$, $\max_depth = 5$, $\eta = 0.05$, $subsample = 0.8$, $colsample_bytree = 0.8$, $L1 = L2 = 0.1$. Обоснование отказа от подбора на сетке приведено в подразделе 2.5.

Вычислительная сложность. Обучение одного дерева глубины d на n наблюдениях с p признаками: $O(n \cdot p \cdot d)$ для LightGBM (гистограммная аппроксимация), $O(n \cdot p \cdot d \cdot \log n)$ для XGBoost (сортировка значений признаков). Обучение ансамбля из M деревьев: $O(M \cdot n \cdot p \cdot d)$ и $O(M \cdot n \cdot p \cdot d \cdot \log n)$ соответственно. При $n = 60\text{--}137$, $p = 34$, $d = 5$, $M = 200$ обучение занимает 4–6 секунд на 77 шагов expanding window (подраздел 3.7.3).

В вычислительном эксперименте (раздел 3.4) LightGBM показал MAE = 1.081 п.п., XGBoost – 1.121 п.п. Обе модели уступили Naïve (0.569) и параметрическим моделям (0.582–0.728), что объясняется переобучением на коротком ряде (137 наблюдений при 34 признаках) и мультиколлинеарностью лагов с экзогенными переменными (подраздел 3.4.3).

Методы интерпретации ансамблевых моделей. Нелинейность и высокая Built-in importance суммирует прирост целевой функции (gain) по всем разбиениям дерева для каждого признака [25]. Метод быстр, но смещён в пользу признаков с большим числом уникальных значений.

Permutation importance [26] измеряет деградацию метрики при случайном перемешивании значений признака в тестовой выборке. Метод модельно-независим и работает с любым алгоритмом.

SHAP [27] распределяет вклад каждого признака в отдельный прогноз на основе аксиоматики Шепли [28]. Для деревьев значения вычисляются точно за полиномиальное время алгоритмом TreeSHAP; метод удовлетворяет аксиомам эффективности (сумма вкладов равна отклонению прогноза от среднего), симметрии и нулевого игрока.

Корреляции Пирсона, Спирмена и Кендалла служат независимым от модели базисом для проверки согласованности ранжирования: признак, попавший в TOP-10 по всем пяти методам, можно считать устойчиво информативным.

В данной работе все четыре подхода используются совместно (подраздел 3.4.2).

1.3.3 Prophet: аддитивная декомпозиция с кусочно-линейным трендом

В работе [29] предложена модель Prophet, ориентированная на практиков, которым требуется автоматически строить прогнозы для большого числа разнородных временных рядов. В отличие от ARIMA и ETS, Prophet не использует авторегрессионную структуру: вместо зависимости текущего значения от прошлых ряд представляется суммой содержательно интерпретируемых слагаемых:

$$y(t) = g(t) + s(t) + \sum_{j=1}^p \beta_j \cdot x_j(t) + \varepsilon(t), \quad (1.51)$$

где $g(t)$ – тренд, $s(t)$ – сезонная компонента, $x_j(t)$ – экзогенные регрессоры с коэффициентами β_j , $\varepsilon(t)$ – ошибка. Компоненты оцениваются совместно методом MAP (максимум апостериорной вероятности) через Stan.

Кусочно-линейный тренд. Трендовая компонента $g(t)$ строится как функция с переменным наклоном: в K заранее размещённых точках – changepoints $s_1, \dots, s_K$ – наклон может скачкообразно изменяться:

$$g(t) = (k + a(t)^T \delta) \cdot t + (m + a(t)^T \gamma), \quad (1.52)$$

где k – начальный наклон (rate), m – начальный уровень (offset), $\delta \in \mathbb{R}^K$ – вектор изменений наклона в точках излома, $a(t) \in \{0, 1\}^K$ – вектор индикаторов: $a_j(t) = 1$ при $t \geq s_j$, $\gamma \in \mathbb{R}^K$ – вектор поправок на непрерывность, определяемый из условия $g(s_j -) = g(s_j +)$:

$$\gamma_j = -s_j \cdot \delta_j. \quad (1.53)$$

Текущий наклон тренда в момент t равен $k + \sum_{j: s_j < t} \delta_j$. Если $\delta_j > 0$, наклон увеличивается в точке s_j ; если $\delta_j < 0$ – уменьшается. Changepoints определяются автоматически: равномерно размещаются на первых 80% обучающей выборки, а ненулевые δ_j отбираются через регуляризацию.

Регуляризация точек излома выполняется через априорное распределение Лапласа:

$$\delta_j \sim \text{Laplace}(0, \tau), \quad (1.54)$$

где $\tau > 0$ – параметр гибкости тренда (changepoint_prior_scale). При $\tau \rightarrow 0$ все $\delta_j \rightarrow 0$, тренд сводится к линейному. При большом τ changepoints определяются свободно, и тренд точно следует за данными. Распределение Лапласа (в отличие от нормального) порождает разреженные решения: большая часть δ_j обращается в нуль, и лишь несколько changepoints оказываются ненулевыми. Это аналогично L1-регуляризации (Lasso) в линейной регрессии.

Сезонная компонента. Сезонность моделируется рядами Фурье [29]:

$$s(t) = \sum_{n=1}^N \left(a_n \cdot \cos\left(\frac{2\pi nt}{P}\right) + b_n \cdot \sin\left(\frac{2\pi nt}{P}\right) \right), \quad (1.55)$$

где P – период ($P = 365.25$ для годовой, $P = 7$ для недельной сезонности), N – число гармоник, a_n, b_n – коэффициенты Фурье. Увеличение N позволяет моделировать более сложные сезонные паттерны, но повышает риск переобучения. В настоящей работе сезонная компонента отключена (yearly_seasonality = False, weekly_seasonality = False, daily_seasonality = False), что обосновано отсутствием сезонности в ключевой ставке (подраздел 2.3.3).

Экзогенные регрессоры. Prophet допускает включение внешних переменных $x_j(t)$ с линейными коэффициентами β_j . Коэффициенты оцениваются совместно с остальными параметрами при максимизации апостериорной вероятности. Линейность связи $y(t)$ с $x_j(t)$ – ограничение модели: пороговые эффекты и взаимодействия между регрессорами не улавливаются. Градиентный бустинг (подраздел 1.3.2) свободен от этого ограничения.

МАР-оценка. Параметры модели ($k, m, \delta, a_n, b_n, \beta_j, \sigma$) оцениваются максимизацией логарифма апостериорной вероятности:

$$\hat{\theta} = \operatorname{argmax}_{\theta} [\ln p(y | \theta) + \ln p(\theta)], \quad (1.56)$$

где $p(y | \theta)$ – функция правдоподобия (предполагается нормальное распределение ошибок), $p(\theta)$ – априорное распределение (распределение Лапласа для δ , нормальное распределение на β_j). MAP-оценка эквивалентна штрафной максимизации правдоподобия, где штраф определяется априорными распределениями. Оптимизация выполняется через L-BFGS в Stan.

Прогноз. h -шаговый прогноз строится подстановкой $t = T + h$ в (1.50)–(1.54). Тренд $g(T+h)$ экстраполируется с последним наклоном $k + \Sigma \delta_j$ (точки излома при $t > T$ не добавляются). Сезонная компонента, если включена, периодически продолжается. Для экзогенных регрессоров необходимы значения $x_j(T+h)$, что при $h > 1$ требует либо их прогнозирования, либо использования рыночных индикаторов (ROISfix, подраздел 3.7.4).

Предсказательные интервалы строятся через Монте-Карло симуляцию: генерируются случайные будущие changepoints из модели (1.53) и случайные ошибки, прогноз вычисляется для каждой реализации, и из полученного распределения берутся квантили.

В вычислительном эксперименте (раздел 3.3) Prophet-base (без регрессоров) показал MAE = 2.727 п.п., худший результат среди 16 моделей. Prophet-exog (с 8 регрессорами) – MAE = 0.905 п.п., улучшение на 67%. Разрыв между двумя конфигурациями количественно показывает, что экзогенные переменные содержат информацию, не заложенную в историю самого ряда (подраздел 3.8).

1.4 Нейросетевые архитектуры для временных рядов

1.4.1 N-BEATS: нейросетевая декомпозиция на базисные функции

Архитектура N-BEATS, предложенная Орешкиным и соавторами [30], показывает, что конкурентоспособного качества прогноза можно достичь без рекуррентных соединений, свёрточных операций и механизма внимания.

Строительный блок сети – полносвязные слои. Каждый блок обрабатывает ту часть входного сигнала, которая не была объяснена предыдущими блоками, и раскладывает свой вклад в прогноз по набору базисных функций – это двойной механизм остаточных подключений, ключевой для всей архитектуры.

Архитектура. Входом модели служит вектор $x = (y_{T-L+1}, \dots, y_T) \in R^L$ – последние L значений ряда (lookback window). Модель состоит из B блоков, организованных в стеки. Каждый блок принимает на вход вектор $x_b \in R^L$ и генерирует два выхода: backcast $\hat{x}_b \in R^L$ (реконструкция входа) и forecast $\hat{y}_b \in R^H$ (прогноз на горизонт H). Блок реализован как полносвязная сеть с несколькими скрытыми слоями:

$$\theta_b = FC_b(x_b), \quad (1.57)$$

$$\hat{x}_b = V_b^{back} \cdot \theta_b^{back}, \hat{y}_b = V_b^{fore} \cdot \theta_b^{fore}, \quad (1.58)$$

где FC_b – полносвязная сеть, θ_b – промежуточное представление, разделяемое на θ_b^{back} и θ_b^{fore} , $V_b^{back} \in R^{L \times k}$ и $V_b^{fore} \in R^{H \times k}$ – матрицы базисных функций.

Двойной residual stacking. Блоки связаны residual-соединениями: вход следующего блока равен разности между входом текущего блока и его backcast-выходом:

$$x_{b+1} = x_b - \hat{x}_b. \quad (1.59)$$

Каждый блок, таким образом, моделирует ту часть сигнала, которую не объяснили предыдущие блоки. Итоговый прогноз – сумма forecast-выходов всех блоков:

$$\hat{y} = \sum_{b=1}^B \hat{y}_b = \sum_{b=1}^B V_b^{fore} \cdot \theta_b^{fore}. \quad (1.60)$$

Структура аналогична бустингу (формула 1.43): каждый блок обучается на остатках предыдущего. Отличие – в отсутствии последовательного обучения: все блоки оптимизируются совместно через backpropagation.

Interpretable stacks. В interpretable-варианте матрицы V_b фиксированы и задают заранее определённые базисные функции [30]. Для тренд-стека базис – полиномы степени p :

$$V_{trend}^{fore} = [1, t, t^2, \dots, t^p]^T, t = (1, 2, \dots, H), \quad (1.61)$$

то есть прогноз тренда равен $\hat{y}_{trend} = \theta_0 + \theta_1 t + \theta_2 t^2 + \dots + \theta_p t^p$.

Для сезонного стека базис – тригонометрические функции:

$$V_{seas}^{fore} = \left[\cos\left(\frac{2\pi t}{m}\right), \sin\left(\frac{2\pi t}{m}\right), \cos\left(\frac{4\pi t}{m}\right), \sin\left(\frac{4\pi t}{m}\right), \dots \right]^T, \quad (1.62)$$

что соответствует разложению в ряд Фурье с периодом m . Interpretable-стеки обеспечивают декомпозицию прогноза на интерпретируемые компоненты (тренд + сезонность), аналогично STL или ETS.

Ограничение: в реализации NeuralForecast interpretable stacks требуют $H \geq 2$ для корректного определения полиномиального и тригонометрического базиса. При $H = 1$ (one-step-ahead, как в настоящей работе) полиномы и тригонометрические функции вырождаются в константы, и стеки теряют различимость. Поэтому в эксперименте использованы generic stacks.

Generic stacks. В generic-варианте матрицы V_b – обучаемые параметры, не привязанные к конкретному базису [30]. Сеть самостоятельно определяет оптимальное разложение прогноза на компоненты. Generic stacks обладают бóльшей выразительной способностью, но теряют интерпретируемость: вклад отдельного блока не имеет содержательного смысла (тренд/сезонность).

В настоящей работе использованы 3 generic-стека (`stack_types = ['identity', 'identity', 'identity']`), что порождает модель с 2.4М параметров. При обучающем окне от 60 до 150 наблюдений отношение параметров к данным составляет 16 000–40 000 – на порядки выше допустимого для линейных моделей. Регуляризация осуществляется через ограничение числа шагов обучения (`max_steps = 300`, то есть ранняя остановка) и нормализацию входа

(TemporalNorm, вычитание среднего и деление на стандартное отклонение окна).

Функция потерь и обучение. Параметры всех блоков оптимизируются совместно минимизацией функции потерь (в настоящей работе MAE):

$$L = \left(\frac{1}{H}\right) \cdot \sum_{h=1}^H |y_{T+h} - \hat{y}_{T+h}|, \quad (1.63)$$

через стохастический градиентный спуск (Adam). Backcast-выход регуляризует обучение: если блок хорошо реконструирует вход ($\hat{x}_b \approx x_b$), он «объяснил» данный участок сигнала, и остаток x_{b+1} стремится к нулю.

Связь с другими моделями. N-BEATS при одном тренд-стеке с полиномом степени 0 (константа) и $H = 1$ эквивалентен простому экспоненциальному сглаживанию. При одном тренд-стеке с полиномом степени 1 – линейному дрейфу. Generic stacks с несколькими слоями – универсальный аппроксиматор (теорема Цыбенко), способный приблизить произвольную непрерывную функцию $f: R^L \rightarrow R^H$, но требующий соразмерного объёма обучающих данных.

В вычислительном эксперименте (раздел 3.5) N-BEATS показал MAE = 1.127 п.п. (12-е место из 16). Модель уступила Naïve (0.569) и всем параметрическим моделям, что объясняется избыточной параметризацией на коротком ряде (подраздел 3.5).

1.4.2 N-HiTS: иерархическая интерполяция и мультимасштабное моделирование

N-HiTS (Neural Hierarchical Interpolation for Time Series) [31] – расширение N-BEATS, в котором каждый блок работает на собственном временном масштабе. Идея состоит в том, что различные компоненты ряда (краткосрочные колебания, среднесрочный тренд, долгосрочная динамика) лучше моделируются на соответствующих масштабах, а не на исходном разрешении.

Архитектура. Как и в N-BEATS, модель состоит из В блоков с residual-соединениями (формулы 1.56–1.59). Отличие – в добавлении двух операций: MaxPool на входе и интерполяция на выходе каждого блока [31].

На входе блока b применяется MaxPool с размером ядра k_b , сжимающий входной вектор $x_b \in R^L$ до размерности $\lceil \frac{L}{k_b} \rceil$:

$$x_b^{\text{pool}} = \text{MaxPool}_{k_b}(x_b) \in R^{\lceil \frac{L}{k_b} \rceil}. \quad (1.64)$$

Полносвязная сеть FC_b обрабатывает сжатый вход x_b^{pool} , генерируя коэффициенты θ_b меньшей размерности. Forecast-выход восстанавливается до горизонта H через линейную интерполяцию:

$$\hat{y}_b = \text{Interpolate}(V_b^{\text{fore}} \cdot \theta_b^{\text{fore}}, H). \quad (1.65)$$

Аналогично, backcast-выход интерполируется до размерности L для вычисления остатка $x_{b+1} = x_b - \hat{x}_b$.

Блоки организованы в стеки с возрастающим k_b . Первый стек (малое k_b) работает на исходном разрешении и улавливает краткосрочные колебания. Последний стек (большое k_b) сжимает вход максимально и моделирует долгосрочный тренд. Иерархия масштабов $\{k_1, k_2, \dots, k_S\}$ задаётся как гиперпараметр.

Вычислительная сложность. MaxPool сокращает размерность входа полносвязной сети с L до $\lceil \frac{L}{k_b} \rceil$, что пропорционально уменьшает число операций умножения. Суммарная сложность N-HiTS:

$$O\left(n \cdot L \cdot \frac{H}{\prod_b k_b}\right) \quad (1.66)$$

вместо $O(n \cdot L \cdot H)$ для N-BEATS [31], где n – число обучающих примеров. При $k_b = 2$ для трёх стеков $\prod k_b = 8$, что даёт 8-кратное ускорение.

Ограничения на коротком ряде. Преимущество мультимасштабности реализуется при длинном входном окне ($L \gg k_b$), когда MaxPool производит содержательное сжатие. При $L = 12$ (настоящая работа) MaxPool с $k_b = 2$ сжимает вход до 6 значений, с $k_b = 4$ – до 3. Столь агрессивное сжатие может приводить к потере информации: MaxPool выбирает максимум на окне и отбрасывает остальные значения. Для ключевой ставки, где важна точная величина (а не максимум на окне), это нежелательно.

В вычислительном эксперименте (раздел 3.5) N-HiTS показал MAE = 1.215 п.п., худший среди трёх нейросетей. N-BEATS (1.127) и PatchTST (1.153) превзошли N-HiTS, что согласуется с теоретическим ограничением: при $L = 12$ мультимасштабная архитектура не даёт преимущества перед полномасштабной обработкой.

1.4.3 PatchTST: адаптация механизма внимания к подпоследовательностям ряда

PatchTST (Patch Time Series Transformer) [32] адаптирует архитектуру Transformer encoder для временных рядов через два приёма: разбиение ряда на патчи (подпоследовательности) и независимую обработку каждого ряда (channel independence). Патчинг снижает число токенов и позволяет механизму внимания работать с локальными паттернами, а не с отдельными точками.

Патчинг. Входной вектор $x = (y_{T-L+1}, \dots, y_T) \in R^L$ разбивается на N перекрывающихся патчей длины P с шагом S :

$$x^{(i)} = (y_{T-L+1+(i-1)S}, \dots, y_{T-L+(i-1)S+P}), i = 1, \dots, N, \quad (1.67)$$

где $N = \lfloor \frac{(L-P)}{S} \rfloor + 1$ – число патчей. Каждый патч $x^i \in R^P$ проецируется

в пространство размерности d через обучаемую линейную проекцию:

$$z_i = W_p \cdot x^{(i)} + b_p, W_p \in R^{d \times P}, \quad (1.68)$$

после чего добавляется позиционное кодирование: $z_i \leftarrow z_i + PE_i$, где $PE \in R^{N \times d}$ – обучаемая матрица позиций. Результат – последовательность токенов $z_1, \dots, z_N \in R^d$, подаваемая на вход Transformer encoder.

Патчинг сокращает число токенов с L (отдельные точки) до $N < L$ (патчи), что уменьшает вычислительную сложность self-attention с $O(L^2)$ до $O(N^2)$. При $L = 12$, $P = 4$, $S = 2$ получаем $N = 5$ патчей, и сложность снижается в $(\frac{12}{5})^2 \approx 5.8$ раз. Кроме того, каждый токен содержит P последовательных значений, что позволяет механизму внимания оперировать локальными паттернами (направление изменения, волатильность на окне), а не отдельными значениями ряда.

Transformer encoder. Последовательность токенов $z_1, \dots, z_N$ обрабатывается стеком из E слоёв Transformer encoder [32]. Каждый слой состоит из двух подслоёв: multi-head self-attention и feed-forward network.

Multi-head self-attention. Для каждой из n_h голов (heads) входная матрица $Z \in R^{N \times d}$ проецируется в запросы (queries), ключи (keys) и значения (values):

$$Q = Z \cdot W_Q, K = Z \cdot W_K, V = Z \cdot W_V, W_Q, W_K, W_V \in R^{d \times d_k}, \quad (1.69)$$

где $d_k = \frac{d}{n_h}$ – размерность одной головы. Выход attention:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) \cdot V \in R^{N \times d_k}. \quad (1.70)$$

Матрица $QK^T \in R^{N \times N}$ содержит попарные скалярные произведения между всеми парами патчей. Деление на $\sqrt{d_k}$ предотвращает насыщение softmax при большом d_k . Softmax нормализует каждую строку в распределение вероятностей, определяя, какие патчи наиболее релевантны для данного. Умножение на V агрегирует информацию из релевантных патчей.

Выходы n_h голов конкатенируются и проецируются:

$$\text{MultiHead}(Z) = \text{Concat}(\text{head}_1, \dots, \text{head}_{n_h}) \cdot W_O, W_O \in R^{d \times d}. \quad (1.71)$$

Feed-forward network. После attention применяется двухслойная полносвязная сеть с активацией GELU:

$$\text{FFN}(z) = W_2 \cdot \text{GELU}(W_1 \cdot z + b_1) + b_2. \quad (1.72)$$

Каждый подслой обёрнут в residual-соединение и layer normalization: $\text{output} = \text{LayerNorm}(z + \text{Sublayer}(z))$.

Channel independence. В многомерном случае (несколько временных рядов) PatchTST обрабатывает каждый ряд отдельно через один и тот же Transformer encoder, разделяя веса между рядами [32]. Это снижает число параметров и предотвращает переобучение на кросс-корреляциях, которые могут быть нестабильны. В настоящей работе ряд один (ключевая ставка), и channel independence не влияет на результат.

Прогноз. Выход последнего слоя encoder – обновлённые токены $z'_1, \dots, z'_N \in R^d$. Они конкатенируются (или усредняются) и проецируются в прогноз через линейный слой:

$$\hat{y} = W_{out} \cdot \text{Flatten}(z'_1, \dots, z'_N) + b_{out}, \hat{y} \in R^H. \quad (1.73)$$

Число параметров. Основные источники параметров: проекция патчей W_p ($P \times d$), матрицы внимания W_Q, W_K, W_V, W_O ($4 \times d \times d$ на слой), feed-forward W_1, W_2 ($2 \times d \times d_{ff}$ на слой), выходная проекция W_{out} . При $P = 4$, $d = 32$, $n_h = 4$, $E = 2$ общее число параметров составляет 42.6К, что в 56 раз меньше N-BEATS (2.4М). Отношение параметров к данным: 280–710 (при 60–150 наблюдениях), что ближе к допустимому диапазону, чем у N-BEATS (16 000–40 000).

Вычислительная сложность. Сложность одного прохода: $O(E \cdot (N^2 \cdot d + N \cdot d \cdot d_{ff}))$. При $N = 5$, $d = 32$, $d_{ff} = 128$, $E = 2$ это порядка 10^5 операций – на 2 порядка меньше, чем у N-BEATS с 2.4М параметров. На практике время обучения PatchTST и N-BEATS сопоставимо (~175 с на 91 окно), поскольку bottleneck – число шагов градиентного спуска ($\text{max_steps} \times \text{число окон}$), а не стоимость одного прохода.

В вычислительном эксперименте (раздел 3.5) PatchTST показал MAE = 1.153 п.п. (13-е место). По MAE модель уступает N-BEATS (1.127), но по

RMSE превосходит (2.133 против 2.175): PatchTST допускает меньше крупных промахов при большем числе мелких. Механизм внимания позволяет модели адаптивно взвешивать патчи, что полезно при структурных сломах: патчи, содержащие кризисные эпизоды, получают меньший вес. На коротком ряде (151 наблюдение) это преимущество реализуется лишь частично.

1.5 Foundation Models: предобученные трансформеры для временных рядов

1.5.1 TimeGPT, Chronos-Bolt, TimesFM: архитектура, токенизация и zero-shot прогнозирование

Обзор [3] вводит понятие foundation model применительно к временным рядам: нейросети, предобученные на десятках миллионов рядов из самых разных прикладных областей и способные прогнозировать новый ряд без дополнительной настройки, в режиме zero-shot. Этот подход пришёл из обработки естественного языка, где GPT и BERT показали, что масштаб обучающего корпуса и размер модели формируют общие представления о структуре данных, переносимые на задачи, отсутствовавшие при обучении [33, 34].

Применительно к временным рядам zero-shot означает: модель получает на вход историю ряда $\{y_1, \dots, y_T\}$ (контекст, аналог промпта в языковых моделях) и генерирует прогноз $\{\hat{y}_{T+1}, \dots, \hat{y}_{T+H}\}$ без оценки параметров на этом конкретном ряде. Все параметры зафиксированы на этапе предобучения. Адаптация к конкретному ряду происходит неявно, через механизм внимания (in-context learning), а не через градиентный спуск [3].

Три модели, рассматриваемые в настоящей работе, различаются архитектурой и способом токенизации.

TimeGPT. Модель архитектуры Transformer decoder, разработанная компанией Nixtla [35]. Обучена на более чем 100 миллиардах точек временных рядов из открытых источников (финансы, энергетика, retail, погода,

транспорт). Токенизация выполняется через патчинг: входной ряд разбивается на подпоследовательности фиксированной длины (аналогично PatchTST, подраздел 1.4.3), каждый патч проецируется в пространство эмбедингов и подаётся на вход декодеру. Decoder генерирует прогноз авторегрессионно, аналогично тому, как языковая модель генерирует текст токен за токеном.

TimeGPT доступен через облачный API; вычисления выполняются на серверах Nixtla. Модель поддерживает экзогенные регрессоры (включаются в промпт) и предсказательные интервалы (через конформное предсказание). Архитектура и детали обучения описаны в препринте [35], но точное число параметров и состав обучающей выборки не раскрыты, что ограничивает воспроизводимость.

Chronos-Bolt. Модель архитектуры T5 (encoder-decoder), разработанная Amazon [36]. Принципиальное отличие от TimeGPT – способ токенизации. Chronos квантует непрерывные значения ряда в дискретные бины: значение y_t отображается на ближайший центр бина c_k :

$$\text{token}(y_t) = \underset{k}{\operatorname{argmin}} |y_t - c_k|, k = 1, \dots, K, \quad (1.74)$$

где K – число бинов (словарь), c_k – центры, определяемые по статистикам обучающей выборки. Квантованная последовательность подаётся на вход T5 encoder, а decoder генерирует распределение вероятностей над бинами для каждого будущего шага:

$$P(y_{T+h} \in \text{bin}_k | y_1, \dots, y_T) = \text{softmax}(\text{decoder_output})_k. \quad (1.75)$$

Прогноз вычисляется как медиана (или среднее) этого распределения. Вероятностная природа прогноза позволяет строить предсказательные интервалы без дополнительных предположений. Chronos обучен на комбинации реальных и синтетических рядов (генерируемых из случайных процессов) [36]. Модели доступны в нескольких масштабах: chronos-bolt-tiny (10M параметров), mini (20M), small (46M), base (200M).

Квантование вносит ошибку дискретизации: если ряд принимает значения, попадающие между центрами бинов, точность прогноза ограничена

шириной бина. Для ключевой ставки, изменяющейся шагами 25–150 б.п., квантование может быть как преимуществом (дискретность ряда совпадает с дискретностью токенов), так и ограничением (при несовпадении сетки бинов с шагами ставки).

TimesFM. Decoder-only модель, разработанная Google [37]. Обучена на ~100 миллиардах точек из корпуса Google Trends, Wikipedia pageviews и синтетических рядов. Токенизация – через патчинг (аналогично TimeGPT). Архитектура содержит ~200М параметров. TimesFM работает локально (без API), что обеспечивает воспроизводимость, но требует совместимости зависимостей.

Основное отличие TimesFM от TimeGPT – стратегия обучения. TimesFM обучен на рядах фиксированной длины и прогнозирует фиксированный горизонт, тогда как TimeGPT поддерживает произвольные длины контекста и горизонта через позиционное кодирование [37, 3].

Общая формализация. Все три модели реализуют одну и ту же математическую схему. Пусть θ^* – параметры, зафиксированные после предобучения на корпусе $D = \{y^{(1)}, y^{(2)}, \dots, y^{(M)}\}$ из M рядов. Прогноз для нового ряда $y = \{y_1, \dots, y_T\}$:

$$\hat{y}_{T+h} = f_{\theta^*}(y_1, \dots, y_T), h = 1, \dots, H, \quad (1.76)$$

где f_{θ^*} – нейросетевая функция с фиксированными весами. Обучение θ^* выполняется минимизацией суммарной функции потерь по всем рядам корпуса:

$$\theta^* = \operatorname{argmin}_{\theta} \sum_{m=1}^M \sum_t L\left(y_t^{(m)}, f_{\theta}\left(y_1^{(m)}, \dots, y_{t-1}^{(m)}\right)\right). \quad (1.77)$$

Масштаб корпуса ($M = 10^6$ – 10^8 рядов, $\sum T_m = 10^{10}$ – 10^{11} точек) отличает foundation models от обычных нейросетей (N-BEATS, PatchTST), обучаемых на одном ряде.

1.5.2 Проблема интерпретируемости и применимость моделей «чёрного ящика»

Foundation models порождают два вопроса, отсутствующих у параметрических моделей.

Интерпретируемость. ARIMA-прогноз объясним через коэффициенты φ_i, θ_j и порядок дифференцирования d . ETS-прогноз декомпозируется на уровень, тренд и сезонность LightGBM допускает интерпретацию через SHAP-значения. (подраздел 3.4.2). Foundation model с ~200M параметров не допускает аналогичной декомпозиции: невозможно указать, какой «паттерн из обучающего корпуса» определил конкретный прогноз. Для задач, где требуется обоснование прогноза (регуляторные решения, управление рисками), это ограничение может быть критичным.

Применимость к out-of-distribution данным. Foundation models обучены преимущественно на рядах, управляемых рыночными или природными процессами (розничные продажи, потребление энергии, погода, финансовые котировки). Ключевая ставка ЦБ РФ управляется решениями 14 членов Совета директоров – процесс принципиально иной природы. Модель может не располагать «общими знаниями» о дискретно изменяющихся ставках emerging markets, если подобные ряды слабо представлены в обучающем корпусе [3].

Обзор Лян и др. [3] систематизировал результаты сравнения foundation models с классическими методами на стандартных бенчмарках. Foundation models превосходят классику на длинных рядах (> 1000 наблюдений) с выраженной сезонностью, но уступают на коротких рядах и рядах без сезонности.

Цзян и др. [33] систематизируют подходы к применению LLM для анализа временных рядов и выделяют две ключевые трудности: непостоянство статистических свойств данных и сложность адаптации моделей, обученных на тексте, к числовым последовательностям. Этим объясняется ограниченная применимость LLM в задачах прогнозирования ставок.

Цзинь и др. [34] отмечают, что языковые модели (LLM), адаптированные для временных рядов, пока не превосходят специализированные архитектуры (N-BEATS, PatchTST) на большинстве задач.

В вычислительном эксперименте (раздел 3.6) TimeGPT (zero-shot) показал MAE = 0.823 п.п., заняв 8-е место из 16. Модель превзошла все ML-модели и нейросети, обученные на данных ключевой ставки, но уступила параметрическим моделям (AutoTheta 0.582, AutoETS 0.661) и Naive (0.569). Chronos-Bolt и TimesFM не были протестированы из-за конфликтов зависимостей (подраздел 3.6).

1.6 Обзор существующих исследований по прогнозированию процентных ставок

Существующие исследования, релевантные настоящей работе, группируются по трём направлениям: прогнозирование ставок центральных банков, применение ML к макроэкономическим временным рядам и систематические сравнения методов прогнозирования (M-competitions).

Прогнозирование ставок центральных банков. Абдурахманов [2] исследует предсказуемость решений Банка России на данных 2021–2023 гг. с помощью рыночных индикаторов денежного рынка (OIS, FRA): 67% решений рынок угадывает верно, 33% оказываются неожиданными; среди заседаний с фактическим изменением ставки – 45%. Результаты воспроизводят оценки 2015–2018 гг. и говорят о том, что дискреционная компонента в решениях Совета директоров сохраняется. Абдурахманов [4] исследует обратное направление: реакцию рыночных ожиданий на коммуникацию регулятора. Краткосрочные и среднесрочные доходности реагируют сильнее, длинный конец кривой (7–15 лет) – слабее. Оба результата перекликаются с выводами настоящей работы: первенство Naive (подраздел 3.8) подтверждает значимость дискреционной компоненты на коротких горизонтах, асимметрия РТ (подраздел 3.9) воспроизводит неравномерность рыночной реакции.

Пильник и Радионов [5] моделировали процентные ставки в российской банковской системе классическими эконометрическими методами (VAR, VECM). Работа ограничена линейными моделями и не включает ML, нейросети или foundation models. Тампурис и Дрицаки [38] применили скрытые марковские модели (HMM) для прогнозирования ставок центральных банков, моделируя режимы ДКП (ужесточение/смягчение) как скрытые состояния. Подход перспективен для дискретных ставок, но протестирован только на ставках развитых стран (ЕЦБ, ФРС).

Ни одна из перечисленных работ не проводит систематического сравнения моделей различной природы (параметрические, ансамблевые, нейросетевые, предобученные) на единой схеме валидации с формальным статистическим тестированием.

ML для макроэкономического прогнозирования. Гуле Куломб и др. [6] провели обзор применения ML в макропрогнозировании и показали, что нелинейные модели (random forest, gradient boosting, нейросети) превосходят линейные (AR, VAR) на горизонтах $h \geq 4$ квартала, но уступают на коротких горизонтах. Авторы объясняют это компромиссом смещение–дисперсия: на коротких горизонтах линейная аппроксимация достаточна, а дополнительная гибкость ML приводит к переобучению. Вывод согласуется с результатами настоящей работы при $h = 1$ (параметрические модели лучше ML, подраздел 3.7.2).

Джункеев [39] применил gradient boosting и нейросети для прогнозирования инфляции в России и показал, что ML превосходит классические модели при включении большого числа экзогенных переменных (50+). Байбуза [40] и Шибитов с Мамедли [41] получили аналогичные результаты для CPI на данных Банка России: ML-модели выигрывают при большом p (число предикторов) и длинных рядах (> 200 наблюдений), но не на коротких. В настоящей работе длина ряда (151 наблюдение) и число наблюдений для ML (77 шагов валидации) находятся ниже порога, при

котором ML начинает превосходить классику. Это объясняет, почему LightGBM (MAE = 1.081) уступает AutoTheta (MAE = 0.582).

Масини и др. [22] систематизировали условия, при которых ML превосходит классические модели для временных рядов: длинные ряды ($T > 500$), большое число предикторов ($p > 50$), нелинейные зависимости и нестационарность в ковариатах. Для ключевой ставки ЦБ РФ выполняется лишь последнее условие (нестационарность), что ограничивает преимущество ML.

В M4-competition (2020) на 61 методе и 100 000 рядов победила ES-RNN Смыла [7] – гибрид экспоненциального сглаживания и рекуррентной сети. Из 17 методов, превысивших бенчмарк, 12 оказались статистическими или комбинированными; чистые ML-методы им уступили. Макридакис и др. [7] объясняют это компромиссом смещение–дисперсия: на коротких univariate-рядах жёсткие предположения статистических моделей не вредят, тогда как нейросети переобучаются.

M5-competition (2020) на данных розничных продаж Walmart (42 840 рядов) изменила картину: победили модели на основе LightGBM [8]. Ключевое отличие M5 от M4 – наличие экзогенных переменных (цены, промоакции, календарные события) и иерархической структуры (продукт → категория → магазин). В этих условиях градиентный бустинг с feature engineering превосходит univariate-методы. Для настоящей работы результаты M4 и M5 задают контекст: на univariate-задаче с коротким рядом (аналог M4) параметрические методы побеждают; при наличии экзогенных переменных и длинных рядов (аналог M5) ML может выиграть.

Позиционирование настоящей работы. Обзор выявляет три области, не покрытых существующими исследованиями:

- работы по прогнозированию ставки ЦБ РФ [2, 4, 5] ограничены классическими эконометрическими методами и не включают нейросети и foundation models 2024–2025 года;

– работы по ML в макропрогнозировании [38, 39, 40, 6] фокусируются на инфляции и ВВП, а не на процентных ставках;

– M-competitions [7, 8] проводятся на гетерогенных выборках и не учитывают специфику дискретно управляемых процессов вроде ключевой ставки, где решения принимаются регулятором, а не генерируются стохастически. Переносить их выводы напрямую следует с осторожностью.

Настоящая работа: (1) проводит первое сравнение 16 моделей четырёх классов (параметрические, ансамблевые, нейросетевые, предобученные) на задаче прогнозирования ключевой ставки ЦБ РФ; (2) количественно оценивает роль КБД ОФЗ через аксиоматику Шепли (пять методов оценки важности, ablation study); (3) применяет формальное статистическое тестирование (DM-тест, 78 пар) для разделения моделей на группы статистически неразличимых.

Модели четырёх классов сравниваются в следующей главе – там же описаны данные, признаковое пространство и схема валидации.

2 ДАННЫЕ, ПРИЗНАКОВОЕ ПРОСТРАНСТВО И СХЕМА ЭКСПЕРИМЕНТА

2.1 Описание предметной области: ключевая ставка ЦБ РФ как целевой процесс

Целевой переменной настоящего исследования является ключевая ставка Банка России, определяющая минимальную процентную ставку по операциям предоставления ликвидности на срок одна неделя и максимальную ставку по операциям абсорбирования ликвидности на аналогичный срок. Ключевая ставка введена 13 сентября 2013 года взамен ставки рефинансирования. С 1 января 2016 года ставка рефинансирования приравнена к ключевой и самостоятельного значения не имеет; в настоящей работе она не рассматривается.

С точки зрения математического моделирования ключевая ставка обладает рядом свойств, определяющих выбор прогнозных моделей.

Ставка изменяется дискретно. Решения принимаются Советом директоров Банка России на плановых заседаниях, которых проводится восемь в год; в отдельных случаях возможны внеплановые заседания. Между заседаниями значение ставки остаётся постоянным, что порождает кусочно-постоянную траекторию и высокую автокорреляцию с первым лагом. Эта особенность делает модель случайного блуждания (naïve forecast, $\hat{y}_{T+1} = y_T$) естественным бенчмарком. При этом шаг изменения, как правило, составляет 25, 50, 100 или 150 базисных пунктов, то есть ставка принимает значения из ограниченного дискретного множества. Прогнозные модели, работающие в непрерывном пространстве, эту дискретность не учитывают.

Процесс нестационарен и подвержен структурным сдвигам. За рассматриваемый период (сентябрь 2013 – март 2026, 151 месяц) выделяются три эпизода экстремальной волатильности (рисунок 1):

- валютный кризис декабря 2014 года: внеплановое повышение ставки с 10,5% до 17,0% на фоне обвала рубля и оттока капитала;
- пандемия COVID-19, 2020 год: последовательное снижение ставки до исторического минимума 4,25%;
- февраль 2022 года: внеплановое повышение ставки до 20,0% в ответ на введение санкций и угрозу финансовой стабильности.



Рисунок 1 – График динамики ключевой ставки ЦБ РФ за период 09.2013–03.2026

Описательные статистики подтверждают нестационарный характер процесса: среднее значение составляет 10,31% годовых, медиана 8,25%, стандартное отклонение 4,73 п.п., размах от 4,25% до 21,0%. Расхождение среднего и медианы указывает на правостороннюю асимметрию, вызванную кризисными выбросами.

С позиций теории временных рядов ключевая ставка может рассматриваться как нестационарный процесс с экзогенными зависимостями. Связь ставки с макроэкономическими переменными описывается правилом Тейлора [1], согласно которому центральный банк устанавливает номинальную ставку как функцию отклонения инфляции от целевого уровня и разрыва выпуска:

$$i_t = r^* + \pi_t + \alpha(\pi_t - \pi^*) + \beta(y_t - \bar{y}_t), \quad (2.1)$$

где i_t – номинальная ставка, r^* – равновесная реальная ставка, π_t – текущая инфляция, π^* – целевой уровень инфляции, $y_t - \bar{y}_t$ – разрыв выпуска, α и β – параметры реакции. Правило Тейлора не используется в настоящей

работе как прогнозная модель, однако обосновывает включение индекса потребительских цен (CPI), валового внутреннего продукта (ВВП) и индекса промышленного производства (ИПП) в состав экзогенных регрессоров.

Помимо макроэкономических индикаторов, информацию о будущей динамике ставки содержат рыночные инструменты. Кривая бескупонной доходности ОФЗ отражает ожидания участников рынка относительно будущих процентных ставок, а ставки денежного рынка (RUONIA, ROISfix) характеризуют текущие условия ликвидности и рыночный консенсус на различных горизонтах. Эти переменные подробно описаны в подразделах 2.2.2 и 2.2.3.

Перечисленные свойства целевого процесса (нестационарность, дискретность, структурные сломы, экзогенная зависимость) определяют требования к прогнозным моделям и обосновывают необходимость сравнения методов принципиально различной природы.

2.2 Формирование набора данных

2.2.1 Целевая переменная и блок экзогенных регрессоров

Набор данных сформирован из восьми открытых источников и охватывает период с сентября 2013 по март 2026 года (151 месяц, 32 переменных). Целевая переменная – значение ключевой ставки ЦБ РФ на конец месяца (% годовых). Экзогенные регрессоры разделены на три блока: макроэкономические индикаторы, рыночные переменные и показатели долгового рынка.

Состав набора данных приведён в таблице 1.

Таблица 1 – Набор данных с описанием

Переменная	Описание	Источник	Частота исходных данных	Покрытие (%)
key_rate	ключевая ставка ЦБ РФ	cbr.ru	8 заседаний/год	100%
cpi_mom	ИПЦ к предыдущему месяцу	Росстат	месяц	99.3%
m2	денежный агрегат М2, млрд руб.	ЦБ РФ	месяц	100%
gdp	ВВП, млрд руб.	Росстат	квартал→месяц	94.7%
ipp_yoy	индекс промпроизводства, % г/г	Росстат	месяц	88.1%
usd_rub	курс USD/RUB	ЦБ РФ	день→месяц	100%
brent	Brent crude, USD/барр.	investing.com	день→месяц	100%
zscyc_0.25y–zscyc_30y	КБД ОФЗ, 12 точек	Московская Биржа	день→месяц	98.0%
spread_10y_1y, spread_10y_3m, spread_5y_1y	спреды доходностей	расчётные	-	98.0%
ruonia	RUONIA	ЦБ РФ	день→месяц	100%
spread_ruonia_keyrate	спред RUONIA минус ключевая ставка	расчётный	-	100%
roisfix_1w–roisfix_2y	ROISfix, 8 сроков	НФА/ЦБ РФ	день→месяц	покрытие варьируется

Приведение частот выполнялось следующим образом. Дневные данные (USD/RUB, Brent, КБД, RUONIA, ROISfix) агрегированы до месячной частоты как среднее арифметическое рабочих дней месяца. Квартальные данные (ВВП) интерполированы до месячной частоты кубическим сплайном с ограничением, обеспечивающим совпадение квартальных сумм с исходными данными. Ключевая ставка агрегирована как значение на последний день месяца (end-of-month), что отражает действующий уровень ставки.

2.2.2 Кривая бескупонной доходности ОФЗ

Кривая бескупонной доходности (КБД) государственных облигаций (облигаций федерального займа) рассчитывается ПАО Московская Биржа и задаёт временную структуру процентных ставок на рынке безрискового рублёвого долга [43]. По определению, КБД – это зависимость бескупонной доходности от срока до погашения дисконтной облигации для однородных долговых обязательств.

В основе расчёта лежит параметрическая модель Нельсона-Сигеля [42] с корректирующими добавками. В форме непрерывно начисляемой процентной ставки модель записывается как:

$$g(\tau) = \beta_0 + \beta_1 \cdot \left(\frac{\left(1 - \exp\left(-\frac{\tau}{\tau_1}\right)\right)}{\frac{\tau}{\tau_1}} \right) + \beta_2 \cdot \left(\frac{\left(1 - \exp\left(-\frac{\tau}{\tau_1}\right)\right)}{\frac{\tau}{\tau_1}} - \exp\left(-\frac{\tau}{\tau_1}\right) \right) + \sum_k \delta_k(\tau), \quad (2.2)$$

где τ – срок до погашения (в годах), $\beta_0, \beta_1, \beta_2$ – динамические параметры, τ_1 – параметр, определяющий скорость затухания экспоненциальных членов,

$\delta_k(\tau)$ – корректирующие поправки для отдельных выпусков. Параметр β_0 интерпретируется как долгосрочный уровень доходности, β_1 характеризует наклон кривой, β_2 – кривизну (горб). Бескупонная доходность в форме спот-ставки с годовой капитализацией связана с непрерывно начисляемой доходностью соотношением:

$$G(\tau) = 10000 \cdot \left(\exp\left(\frac{g(\tau)}{10000}\right) - 1 \right). \quad (2.3)$$

Московская Биржа пересчитывает динамические параметры при каждой сделке или изменении заявок в режиме основных торгов, а база расчёта пересматривается ежемесячно с учётом коэффициентов ликвидности по каждому выпуску [43].

В настоящей работе используются 12 точек кривой со сроками 0.25, 0.5, 0.75, 1, 2, 3, 5, 7, 10, 15, 20 и 30 лет, загруженные с сайта ЦБ РФ и агрегированные до месячной частоты. Дополнительно рассчитаны три спреда: $spread_{10y_1y} = zcyc_{10y} - zcyc_{1y}$, $spread_{10y_3m} = zcyc_{10y} - zcyc_{0.25y}$, $spread_{5y_1y} = zcyc_{5y} - zcyc_{1y}$. Спреды характеризуют наклон кривой: положительное значение соответствует нормальной (возрастающей) кривой, отрицательное – инвертированной, то есть рынок закладывает снижение ставок.

Покрытие данных по КБД составляет 98.0% (3 пропуска из 151 наблюдения, приходящиеся на первые месяцы выборки). Корреляция точек КБД с ключевой ставкой убывает с ростом срока: $r(zcyc_{1y}) = +0.959$, $r(zcyc_{5y}) = +0.928$, $r(zcyc_{10y}) = +0.905$. Длинный конец кривой менее чувствителен к текущим решениям ЦБ РФ. Спреды имеют отрицательную корреляцию: $r(spread_{10y_1y}) = -0.772$. При повышении ставки короткий конец растёт быстрее длинного, кривая уплощается или инвертируется, спред сжимается.

2.2.3 RUONIA и ROISfix

RUONIA (Ruble OverNight Index Average) – средневзвешенная ставка необеспеченного рублёвого межбанковского кредитования на условиях овернайт, рассчитываемая Банком России [44]. Расчёт основан на сделках кредитных организаций из списка RUONIA по данным суточной отчётности (форма 0409701). Сделки группируются по уровню ставки r_i , для каждого уровня вычисляется композитный вес:

$$f_i = V_i \cdot C_i, \quad (2.4)$$

где V_i – суммарный объём сделок по ставке r_i , C_i – число участвовавших кредитных организаций. Из суммарного композитного веса $F = \sum f_i$ отсекаются по 10% со стороны минимальных и максимальных ставок, после чего рассчитывается средневзвешенная:

$$RUONIA = \frac{\sum_{j=1}^L r_j \cdot f_j}{\sum_{j=1}^L f_j}, \quad (2.5)$$

где L – количество различных ставок после отсечения. Использование композитного веса (произведение объёма на число участников) обусловлено неоднородностью российского межбанковского рынка: значимость ставки определяется как объёмом сделок, так и числом банков-контрагентов.

RUONIA отслеживает ключевую ставку с корреляцией $r = 0.9964$, а медианный спред колеблется вблизи нуля. Ключевая ставка задаёт нижнюю границу операций репо ЦБ РФ, формируя «пол» для межбанковских ставок овернайт.

ROISfix – индикативная ставка процентного свопа на RUONIA, формируемая СРО НФА на основе двухсторонних котировок контрибьюторов (не менее 6 организаций) [45]. Для каждого контрибьютора вычисляется среднее котировки на покупку и на продажу. При наличии 9 и более котировок отсекаются по 2 крайние, при 6–8 – по 1 крайней, при 4–5 среднее считается без отсечения. Расчёт производится ежедневно в 12:30 мск. Индикатор публикуется на сроки 1 неделя, 2 недели, 1, 2, 3, 6 месяцев, 1 и 2 года.

ROISfix на конкретный срок отражает рыночный консенсус относительно средней ставки RUONIA (и, следовательно, ключевой ставки) на соответствующем горизонте. Иначе говоря, *roisfix_3m* содержит ожидания рынка на 3 месяца вперёд, что делает его прямым предиктором будущей ставки. Корреляция с ключевой ставкой высока по всем срокам (*roisfix_1w*: $r = 0.996$, *roisfix_3m*: $r = 0.989$) и монотонно убывает с увеличением горизонта.

2.2.4 Предобработка

Пропуски в данных распределены неравномерно. Ключевая ставка, USD/RUB, Brent и M2 не содержат пропусков. Индекс промышленного производства имеет 18 пропусков (11.9%), приходящихся на период до 2015 года. ВВП содержит 8 пропусков (5.3%), связанных с квартальной публикацией. КБД и RUONIA – по 3 пропуска (2.0%). Пропуски не заполнялись. Модели, допускающие пропуски (StatsForecast, NeuralForecast), обрабатывают их внутренне; модели, требующие полных данных (LightGBM, XGBoost), используют подмножество признаков без пропусков на соответствующем временном окне.

Нормализация не применялась для моделей на основе деревьев решений (LightGBM, XGBoost), инвариантных к монотонным преобразованиям признаков. Для нейросетевых моделей (N-BEATS, N-HiTS, PatchTST) нормализация выполняется автоматически внутри библиотеки NeuralForecast.

2.3 Разведочный анализ временных рядов

2.3.1 Тестирование стационарности: ADF, KPSS

Стационарность – одно из центральных предположений при построении моделей класса ARIMA. Если ряд нестационарен, модель применяется не к уровням, а к разностям порядка d . Для определения порядка дифференцирования использованы два теста с противоположными нулевыми

гипотезами: расширенный тест Дики-Фуллера (ADF) [14] и тест Квятковского-Филлипса-Шмидта-Шина (KPSS) [16].

Тест ADF основан на оценке вспомогательной регрессии:

$$\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + \sum_{i=1}^p \delta_i \Delta y_{t-i} + \varepsilon_t, \quad (2.6)$$

где $\Delta y_t = y_t - y_{t-1}$, p – число лагов (выбирается по информационному критерию AIC). Гипотезы формулируются как:

$H_0: \gamma = 0$ (ряд содержит единичный корень, нестационарен),

$H_1: \gamma < 0$ (ряд стационарен).

Тестовая статистика $ADF = \hat{\gamma} / SE(\hat{\gamma})$ имеет нестандартное распределение, табулированное Дики и Фуллером [14]. Нулевая гипотеза отвергается при $p\text{-value} < 0.05$.

Тест KPSS проверяет противоположную гипотезу:

H_0 : ряд стационарен (вокруг детерминированного тренда),

H_1 : ряд нестационарен.

Тестовая статистика KPSS основана на кумулятивных суммах остатков регрессии y_t на константу и тренд. Нулевая гипотеза отвергается при $p\text{-value} < 0.05$.

Совместное применение двух тестов повышает надёжность выводов. Возможны четыре исхода: (1) ADF отвергает H_0 , KPSS не отвергает H_0 – ряд стационарен; (2) ADF не отвергает H_0 , KPSS отвергает H_0 – ряд нестационарен, требуется дифференцирование ($d = 1$); (3) оба теста отвергают H_0 – ряд тренд-стационарен; (4) ни один тест не отвергает H_0 – результат неопределённый, требуется дополнительный анализ.

Результаты тестирования для целевой переменной и экзогенных регрессоров приведены в таблице 2.

Таблица 2 – Результаты тестов стационарности

Переменная	ADF-статистика	ADF p-value	ADF H_0 отвергнута	KPSS-статистика	KPSS p-value	KPSS H_0 отвергнута	Вывод
key_rate	-2.291	0.175	Нет	0.294	0.010	Да	Нестационарный → d=1
cpi_mom	-7.697	0.000	Да	0.124	0.091	Нет	Стационарный
m2	0.024	0.961	Нет	0.430	0.010	Да	Нестационарный → d=1
gdp	-0.277	0.929	Нет	0.084	0.100	Нет	Неопределённо
ipp_yoy	-3.075	0.029	Да	0.046	0.100	Нет	Стационарный
usd_rub	-2.383	0.147	Нет	0.068	0.100	Нет	Неопределённо
brent	-2.659	0.082	Нет	0.164	0.035	Да	Нестационарный → d=1
zcyc_1y	-1.803	0.379	Нет	0.302	0.010	Да	Нестационарный → d=1
zcyc_5y	-1.450	0.558	Нет	0.340	0.010	Да	Нестационарный → d=1
zcyc_10y	-0.875	0.796	Нет	0.363	0.010	Да	Нестационарный → d=1
spread_10y_1y	-2.940	0.041	Да	0.139	0.063	Нет	Стационарный
spread_10y_3m	-2.775	0.062	Нет	0.130	0.080	Нет	Неопределённо
spread_5y_1y	-2.826	0.055	Нет	0.122	0.095	Нет	Неопределённо

Ключевая ставка нестационарна в уровнях: ADF не отвергает гипотезу единичного корня ($p = 0.175$), KPSS отвергает гипотезу стационарности ($p = 0.010$). Для моделей класса ARIMA необходимо дифференцирование первого порядка ($d = 1$). Аналогичный результат получен для M2, Brent и всех точек

КБД ($zсус_1y$, $zсус_5y$, $zсус_10y$). Стационарны по обоим тестам три переменные: ИПЦ ($сpi_mоt$), индекс промпроизводства ($ipp_уоу$) и спред 10Y–1Y ($spread_10y_1y$). Для ВВП, USD/RUB и двух спредов ($spread_10y_3m$, $spread_5y_1y$) результат неопределённый: ни один из тестов не отвергает свою нулевую гипотезу на уровне 5%.

Стационарность спреда $spread_10y_1y$ при нестационарности отдельных компонент ($zсус_10y$ и $zсус_1y$) указывает на возможное коинтеграционное соотношение между длинным и коротким концами кривой доходности.

2.3.2 Автокорреляционная структура

Автокорреляционная функция (ACF) и частичная автокорреляционная функция (PACF) – основные инструменты идентификации порядков p и q модели ARIMA(p,d,q) [13]. ACF определяется как

$$ACF(k) = \text{Corr}(X_t, X_{t-k}), \quad (2.7)$$

а PACF(k) – как корреляция X_t и X_{t-k} за вычетом линейного влияния промежуточных наблюдений $X_{t-1}, \dots, X_{t-k+1}$ [9]:

$$PACF(k) = \text{Corr}(X_t, X_{t-k} | X_{t-1}, \dots, X_{t-k+1}). \quad (2.8)$$

Правила идентификации: если PACF обрывается после лага p (значения становятся статистически незначимыми), а ACF затухает постепенно, процесс описывается моделью AR(p). Если ACF обрывается после лага q , а PACF затухает, подходит модель MA(q). Медленное затухание ACF без обрыва указывает на нестационарность [13].

ACF ключевой ставки в уровнях затухает медленно: $ACF(1) = 0.950$, $ACF(12)$ всё ещё статистически значима, что согласуется с нестационарностью, установленной в подразделе 2.3.1. После дифференцирования первого порядка $ACF(1)$ падает до 0.203, а последующие лаги находятся вблизи границ доверительного интервала (рисунок 2). Такая структура указывает на модель ARIMA($p,1,q$) с малыми p и q . AutoARIMA

(раздел 3.2) на большинстве окон валидации выбирает спецификацию $ARIMA(0,1,1)$.




Рисунок 2 – ACF и PACF ключевой ставки в уровнях (верхний ряд) и в первых разностях (нижний ряд), 24 лага, с границами 95%-го доверительного интервала

Корреляционный анализ экзогенных переменных проведён в двух формах: матрица одновременных корреляций Пирсона (рисунок 3) и кросс-корреляционная функция с лагами.




Рисунок 3 — Тепловая карта матрицы корреляций Пирсона для целевой переменной и 12 экзогенных переменных

Наибольшие одновременные корреляции с ключевой ставкой имеют точки КБД: $r(zcyc_1y) = +0.959$, $r(zcyc_5y) = +0.928$, $r(zcyc_10y) = +0.905$. Спреды доходностей коррелированы отрицательно: $r(spread_10y_1y) = -0.772$, $r(spread_10y_3m) = -0.768$, $r(spread_5y_1y) = -0.714$. Среди макропеременных выделяются M2 ($r = +0.643$) и USD/RUB ($r = +0.539$). Корреляция с ИПЦ умеренная ($r = +0.349$), с Brent – слабая ($r = +0.094$).

Кросс-корреляционная функция $CCF(k) = \text{Corr}(Y_t, X_{t-k})$ показывает связь текущего значения целевой переменной Y со значениями экзогенной переменной X с лагом k месяцев. Положительный лаг означает, что X опережает Y . Значения функции для экзогенных переменных – на рисунке 4.




Рисунок 4 — Кросс-корреляционные функции с лагами от –12 до +12

Результаты кросс-корреляционного анализа приведены в таблице 3.

Таблица 3 – Кросс-корреляция экзогенных переменных с ключевой ставкой

Переменная	Лаг наибольшей CCF (по модулю)	CCF при лучшем лаге	CCF при лаге 0	Интерпретация
zсус_1у	0	+0.959	+0.959	синхронная связь

Продолжение таблицы 3

zсус_10у	1	+0.907	+0.905	zсус_10у опережает на 1 мес.
spread_10у_ 1у	0	-0.772	-0.772	синхронная связь
m2	0	+0.643	+0.643	синхронная связь
usd_rub	1	+0.552	+0.539	USD/RUB опережает на 1 мес.
brent	12	+0.388	+0.094	слабая связь с лагом 12 мес.
cpi_mom	0	+0.349	+0.349	синхронная связь

Короткий конец КБД (*zсус_1у*) максимально коррелирован при лаге 0: доходность однолетних ОФЗ непосредственно определяется текущим уровнем ключевой ставки. Длинный конец (*zсус_10у*) достигает максимума при лаге 1, что может отражать опережающий характер ожиданий, заложенных в длинные облигации. Корреляция Brent с ключевой ставкой при лаге 0 минимальна ($r = +0.094$), но возрастает до $r = +0.388$ при лаге 12 месяцев. Нефтяные цены влияют на ставку опосредованно, через бюджетные доходы, инфляцию и валютный курс, с задержкой порядка года.

2.3.3 STL-декомпозиция

Для анализа компонентной структуры ряда применена декомпозиция STL (Seasonal and Trend decomposition using LOESS) [46], разлагающая ряд на три аддитивных компоненты:

$$Y_t = T_t + S_t + R_t, \quad (2.9)$$

где T_t – тренд, S_t – сезонная компонента, R_t – остаток. Тренд и сезонная компонента оцениваются итеративно с помощью локальной полиномиальной регрессии (LOESS). Период сезонности задан равным 12 месяцам, использована робастная версия алгоритма, снижающая влияние выбросов на оценку тренда (рисунок 5).




Рисунок 5 – STL-декомпозиция ключевой ставки

Доля дисперсии, приходящаяся на каждую компоненту, оценена как отношение дисперсии компоненты к дисперсии исходного ряда. Тренд объясняет 64.3% дисперсии, остаток – 25.6%, сезонная компонента – 0.9%. Вклад сезонности пренебрежимо мал: решения Совета директоров ЦБ РФ определяются экономическими условиями, а не календарным циклом. На этом

основании при настройке моделей StatsForecast (раздел 3.2) задан параметр $season_length = 1$, то есть сезонная компонента не моделируется.

Остаточная компонента (25.6% дисперсии) сосредоточена в трёх кризисных эпизодах, описанных в подразделе 2.1. Вне кризисных периодов остаток колеблется вблизи нуля с малой амплитудой. Это обосновывает выбор робастных методов (robust STL, метод Theta), устойчивых к выбросам.

2.4 Метрики качества прогнозов и схема валидации

2.4.1 MAE, RMSE, MAPE: математические свойства

Выбор функции потерь определяет, какую характеристику условного распределения прогнозируемой величины оптимизирует модель. Рассмотрим три метрики, используемые в настоящей работе.

Средняя абсолютная ошибка (MAE) определяется как

$$MAE = \left(\frac{1}{T}\right) \cdot \sum_{t=1}^T |y_t - \hat{y}_t|. \quad (2.10)$$

MAE оптимизирует условную медиану распределения [11]. Доказательство следует из субградиента абсолютной функции потерь $L(y, \hat{y}) = |y - \hat{y}|$. Субградиент по $\hat{y}$ равен $-sign(y - \hat{y})$, и условие оптимальности $E[sign(y - \hat{y})] = 0$ выполняется тогда и только тогда, когда $\hat{y}$ совпадает с медианой условного распределения y [11]. MAE устойчива к выбросам, поскольку отклонения входят линейно, а не квадратично.

Среднеквадратичная ошибка (RMSE) определяется как

$$RMSE = \sqrt{\left(\frac{1}{T}\right) \cdot \sum_{t=1}^T (y_t - \hat{y}_t)^2}. \quad (2.11)$$

Минимизация $MSE = \left(\frac{1}{T}\right) \cdot \sum (y_t - \hat{y}_t)^2$ эквивалентна оптимизации условного среднего [12]. Градиент квадратичной функции потерь $L(y, \hat{y}) = (y - \hat{y})^2$ по $\hat{y}$ равен $-2(y - \hat{y})$, и условие $E[y - \hat{y}] = 0$ даёт $\hat{y} = E[y]$. RMSE

сильнее штрафует крупные ошибки: если распределение ошибок несимметрично или содержит выбросы, MAE и RMSE могут давать разные ранжирования моделей. В настоящей работе основной метрикой является MAE; RMSE используется при анализе расхождений (раздел 3.7).

Средняя абсолютная процентная ошибка (MAPE) определяется как

$$\text{MAPE} = \left(\frac{100}{T} \right) \cdot \frac{\sum_{t=1}^T |y_t - \hat{y}_t|}{|y_t|}. \quad (2.12)$$

MAPE имеет два ограничения [12]. Она не определена при $y_t = 0$ и несимметрична: занижение прогноза штрафуются слабее, чем завышение. Для ключевой ставки, принимающей значения от 4.25% до 21.0%, деление на y_t приводит к тому, что одинаковая по абсолютной величине ошибка в 1 п.п. даёт MAPE = 23.5% при $y_t = 4.25$ и MAPE = 4.8% при $y_t = 21.0$. Это делает MAPE менее информативной для данной задачи по сравнению с MAE и RMSE.

2.4.2 Временная кросс-валидация: expanding window

Стандартная k-fold кросс-валидация неприменима к временным рядам: случайное разбиение нарушает каузальную структуру, и модель обучается на будущих данных [47]. Корректная процедура – временная кросс-валидация (time series cross-validation), при которой обучающая выборка всегда предшествует тестовой.

В настоящей работе используется схема expanding window [48]. На шаге t модель обучается на наблюдениях $\{y_1, \dots, y_t\}$ и прогнозирует значение y_{t+h} , где h – горизонт прогнозирования. На следующем шаге обучающая выборка расширяется на одно наблюдение: $\{y_1, \dots, y_{t+1}\}$, и прогнозируется y_{t+1+h} . Формально:

$$\text{train}_t = \{y_1, \dots, y_t\}, \text{test}_t = y_{t+h}, t = t_0, t_0 + 1, \dots, T - h, \quad (2.13)$$

где t_0 – размер начального обучающего окна. Альтернативная схема sliding window (скользящее окно фиксированной длины) отбрасывает ранние

наблюдения. Expanding window предпочтительнее для коротких рядов, поскольку сохраняет всю доступную информацию.

Параметры валидации: начальное окно $t_0 = 60$ месяцев (5 лет), горизонт $h = 1$ месяц, шаг сдвига = 1 месяц. Число шагов валидации зависит от модели: 91 шаг для StatsForecast и baseline (обучение начинается с 60-го наблюдения), 88 для Prophet (требуется дополнительных наблюдений на начальную подгонку), 77 для LightGBM и XGBoost (требуется достаточная глубина лагов). Различие в числе шагов учитывается при попарном сравнении: тест Diebold-Mariano (подраздел 2.4.3) вычисляется только на пересечении дат, общих для обеих сравниваемых моделей.

Предотвращение data leakage обеспечивается на двух уровнях. На уровне целевой переменной: модель на шаге t не имеет доступа к значениям $y_{t+1}, \dots, y_T$. На уровне экзогенных признаков: лагированные переменные ($lag_1, lag_3, \dots$) вычисляются до разбиения, но при прогнозировании y_{t+1} используются только значения, доступные на момент t . Скользящие статистики ($rolling_mean_3, rolling_std_6$) вычисляются внутри обучающего окна и не включают тестовую точку.

2.4.3 Тест Diebold-Mariano

Сравнение метрик MAE или RMSE показывает, какая модель точнее в среднем, но не отвечает на вопрос, значимо ли это различие. Тест Diebold-Mariano (DM) [49] формализует попарное сравнение прогнозной способности двух моделей как задачу проверки статистической гипотезы.

Пусть $e_{1t} = y_t - \hat{y}_{1t}$ и $e_{2t} = y_t - \hat{y}_{2t}$ – ошибки прогнозов моделей 1 и 2 на шаге t . Определим разность потерь:

$$d_t = L(e_{1t}) - L(e_{2t}), \quad (2.14)$$

где $L(\cdot)$ – функция потерь (в настоящей работе $L(e) = |e|$, что соответствует MAE). Гипотезы:

$H_0: E[d_t] = 0$ (модели имеют одинаковую прогнозную способность),

$H_1: E[d_t] \neq 0$ (прогнозная способность различается).

Статистика теста:

$$DM = \frac{\bar{d}}{\sqrt{\hat{V}(\bar{d})}}, \quad (2.15)$$

где $\bar{d} = \left(\frac{1}{T}\right) \cdot \sum_{t=1}^T d_t$ – среднее разности потерь. Основная сложность – оценка дисперсии $\hat{V}(\bar{d})$. Ошибки прогнозов для горизонта $h \geq 1$ автокоррелированы (прогнозы на перекрывающихся окнах зависимы), поэтому стандартная оценка $V(\bar{d}) = \frac{\gamma_0}{T}$ несостоятельна. Диболд и Мариано [49] используют НАС-оценку (heteroskedasticity and autocorrelation consistent), предложенную Ньюи и Вестом [50]:

$$\hat{V}(\bar{d}) = \left(\frac{1}{T}\right) \cdot \left(\hat{\gamma}_0 + 2 \cdot \sum_{k=1}^K \left(1 - \frac{k}{K+1}\right) \cdot \hat{\gamma}_k\right), \quad (2.16)$$

где $\hat{\gamma}_k = \left(\frac{1}{T}\right) \cdot \sum_{t=k+1}^T (d_t - \bar{d})(d_{t-k} - \bar{d})$ – оценка автоковариации порядка k , а множитель $\left(1 - \frac{k}{K+1}\right)$ – ядро Бартлетта, гарантирующее положительную определённую оценку. Параметр усечения K определяет число учитываемых лагов автоковариации. Стандартная рекомендация [49]: $K = \left\lceil T^{\frac{1}{3}} \right\rceil$. При $T = 91$ получаем $K = 4$.

При выполнении регулярных условий статистика DM асимптотически нормальна:

$$DM \xrightarrow{d} N(0, 1), T \rightarrow \infty. \quad (2.17)$$

P -value вычисляется как $p = 2 \cdot (1 - \Phi(|DM|))$, где $\Phi(\cdot)$ – функция стандартного нормального распределения.

Для малых выборок Харви, Лейборн и Ньюболд [51] предложили модификацию с распределением Стьюдента с $(T - 1)$ степенями свободы. В

настоящей работе при $T = 77-91$ использована асимптотическая версия: различие между $N(0,1)$ и $t(76+)$ пренебрежимо мало.

Интерпретация знака: $DM < 0$ означает, что модель 1 точнее ($\bar{d} < 0$, потери модели 1 в среднем меньше); $DM > 0$ – точнее модель 2. Уровень значимости: $p < 0.05$.

DM-тест применён ко всем $C_{13}^2 = 78$ парам из 13 моделей (после исключения трёх моделей с недостаточным числом общих наблюдений). Из 78 пар 40 показали значимое различие на уровне 5%. Результаты и их интерпретация приведены в разделе 3.7.2.

2.5 Описание моделей, гиперпараметров и программного инструментария

В таблице 4 приведён полный перечень 16 моделей, сгруппированных по классам, с указанием числа оцениваемых параметров, используемой библиотеки и способа настройки гиперпараметров.

Таблица 4 – Сводная таблица моделей

№	Модель	Класс	Экзогенные	Библиотека	Настройка гиперпараметров	Число параметров
1	Naive	Baseline	Нет	statsforecast	-	0
2	Drift	Baseline	Нет	statsforecast	-	1
3	ARIMA	Baseline	Нет	pmdarima	auto (AIC)	~5
4	Decomp+Trend	Baseline	Нет	statsmodels	-	~3
5	AutoARIMA	Параметрическая	Нет	statsforecast	auto (AIC)	~5
6	AutoETS	Параметрическая	Нет	statsforecast	auto (AIC)	2–5
7	CES	Параметрическая	Нет	statsforecast	auto	2
8	AutoTheta	Параметрическая	Нет	statsforecast	auto	2–3
9	Prophet-base	Аддитивная	Нет	prophet	по умолчанию	~15
10	Prophet-exog	Аддитивная	Да (8 регрессоров)	prophet	по умолчанию	~21

Продолжение таблицы 4

11	LightGBM	Ансамблевая (бустинг)	Да (40+)	lightgbm + mlforecast	ручная	~200 деревьев
12	XGBoost	Ансамблевая (бустинг)	Да (40+)	xgboost + mlforecast	ручная	~200 деревьев
13	N-BEATS	Нейросетевая	Нет	neuralforecast	ручная	2.4М
14	N-HiTS	Нейросетевая	Нет	neuralforecast	ручная	~1.2М
15	PatchTST	Нейросетевая	Нет	neuralforecast	ручная	42.6К

Модели расположены в порядке возрастания сложности. Параметрические модели (строки 5–8) автоматически подбирают спецификацию по информационному критерию AIC на каждом шаге expanding window. Ансамблевые модели (строки 11–12) используют фиксированные гиперпараметры: 200 деревьев, *max_depth* = 5, *learning_rate* = 0.5, *min_child_samples* = 5. Подбор на сетке не проводился: при 77 шагах валидации вложенная кросс-валидация привела бы к обучающим окнам недостаточной длины. Нейросетевые модели (строки 13–15) адаптированы для короткого ряда: *input_size* = 12, *max_steps* = 300 (N-BEATS, N-HiTS), *patch_len* = 4, *stride* = 2, *hidden_size* = 32, *n_heads* = 4, *encoder_layers* = 2 (PatchTST). TimeGPT (строка 16) использован в режиме zero-shot без дообучения.

Все эксперименты выполнены на одной вычислительной платформе: ОС Windows 11, процессор AMD Ryzen (6 ядер, 12 потоков), 16 Гб оперативной памяти, без GPU. Нейросетевые модели обучались на CPU (PyTorch 2.11.0+cpu), что увеличивает время обучения, но не влияет на результат прогнозирования. TimeGPT использует удалённый сервер Nixtla через API.

Программный инструментарий построен на Python 3.13 (Anaconda). Основные библиотеки и их роль в эксперименте перечислены в таблице 5.

Таблица 5 – Программный инструментарий

Библиотека	Версия	Назначение
statsforecast	2.0.3	AutoARIMA, AutoETS, CES, AutoTheta, Naive, Drift [52]

Продолжение таблицы 5

neuralforecast	1.7.4	N-BEATS, N-HiTS, PatchTST [53]
prophet	1.3.0	Prophet-base, Prophet-exog
pmdarima	-	ARIMA (baseline) [54]
lightgbm	4.6.0	Градиентный бустинг (leaf-wise)
xgboost	3.1.3	Градиентный бустинг (level-wise)
nixtla	0.7.3	TimeGPT (API-клиент)
shap	0.51.0	SHAP-значения для интерпретации
torch	2.11.0+cpu	Backend для neuralforecast
pandas	2.3.3	Обработка данных
numpy	2.4.4	Численные вычисления
scipy	1.17.1	DM-тест, статистические функции
statsmodels	0.14.6	ADF/KPSS, ACF/PACF, STL, baseline ARIMA
scikit-learn	1.8.0	Метрики, permutation importance
matplotlib	3.10.8	Визуализация

Библиотеки StatsForecast [52] и NeuralForecast [53] разработаны компанией Nixtla и реализуют единый интерфейс для статистических и нейросетевых моделей соответственно. Обе поддерживают expanding window кросс-валидацию через метод *cross_validation()*, что позволяет применять одну и ту же схему валидации ко всем классам моделей. Тест Diebold-Mariano реализован вручную (раздел 2.4.3), поскольку стандартные библиотеки Python не содержат реализации с НАС-оценкой дисперсии Ньюи-Веста.

Полный код эксперимента и исходный датасет опубликованы на диске (Приложение А). Каждый этап оформлен в виде отдельного скрипта, результаты промежуточных этапов сохраняются в формате CSV.

В главе 3 все 16 моделей тестируются на едином наборе данных и сравниваются формально, с помощью теста Диболда–Мариано.

3 ВЫЧИСЛИТЕЛЬНЫЙ ЭКСПЕРИМЕНТ

3.1 Базовые модели (baseline)

Базовые модели устанавливают нижнюю границу точности: если модель более высокой сложности не превосходит baseline, её усложнение не оправдано. В качестве baseline рассмотрены четыре метода возрастающей сложности.

Naïve (случайное блуждание). Прогноз равен последнему наблюденному значению:

$$\hat{y}_{T+1} = y_T. \quad (3.1)$$

Naïve является оптимальным прогнозом для процесса случайного блуждания $y_t = y_{t-1} + \varepsilon_t$, где ε_t – белый шум [10]. Для ключевой ставки эта модель содержательно обоснована: ставка изменяется шесть–восемь раз в год (по числу заседаний Совета директоров ЦБ РФ), а между заседаниями остаётся постоянной. При месячной частоте данных ставка не меняется в большинстве наблюдений, что делает Naïve сильным бенчмарком.

Drift (случайное блуждание с дрифтом). Прогноз экстраполирует среднее изменение ряда за весь период обучения:

$$\hat{y}_{T+h} = y_T + h \cdot \frac{(y_T - y_1)}{(T - 1)}. \quad (3.2)$$

Drift улавливает линейный тренд, но не реагирует на локальные изменения направления. При $h = 1$ и медленно меняющемся ряде прогноз Drift близок к Naïve.

ARIMA (автоматический подбор параметров). На каждом шаге expanding window модель ARIMA(p,d,q) переобучается с автоматическим подбором порядков (p, d, q) по критерию AIC (библиотека pmdarima). Пространство поиска ограничено: $p \in \{0, \dots, 5\}$, $q \in \{0, \dots, 5\}$, $d \in \{0, 1, 2\}$, сезонная компонента отключена (обосновано результатами STL-

декомпозиции в подразделе 2.3.3). Используется пошаговый алгоритм (*stepwise = True*), сокращающий перебор до $O(p_{max}q_{max})$ оценок вместо полного $O(p_{max} \cdot q_{max})$.

Анализ выбранных спецификаций на 91 шаге валидации показал, что AutoARIMA чаще всего выбирает ARIMA(0,1,1) (26 раз, 29%), ARIMA(1,0,3) (19 раз, 21%) и ARIMA(1,0,1) (17 раз, 19%). Преобладание спецификации (0,1,1) согласуется с результатами ACF/PACF (подраздел 2.3.2): после дифференцирования первого порядка ACF обрывается после лага 1, что соответствует MA(1)-компоненте. Нестабильность выбранной спецификации (три порядка покрывают лишь 69% шагов) указывает на чувствительность автоматического подбора к расширению обучающего окна.

Decomp + Trend (декомпозиция с экстраполяцией тренда). На каждом шаге выполняется STL-декомпозиция, после чего тренд экстраполируется линейной регрессией по последним 12 точкам. Прогноз равен экстраполированному значению тренда. Поскольку сезонная компонента пренебрежимо мала (0.9% дисперсии), прогноз сводится к локальной линейной экстраполяции.

Прогнозы четырёх baseline-моделей на фоне фактической динамики ключевой ставки за период валидации (09.2018–03.2026) показаны на рисунке 6.




Рисунок 6 – Прогнозы базовых моделей baseline и фактическое значение ключевой ставки на периоде валидации (09.2018–03.2026)

Naive показывает лучший результат по всем трём метрикам: MAE = 0.569 п.п., RMSE = 1.563 п.п., MAPE = 4.78%. Drift незначительно уступает (MAE = 0.601), ARIMA проигрывает обоим (MAE = 0.735). Decomp+Trend занимает последнее место (MAE = 2.123): линейная экстраполяция тренда систематически запаздывает при резких разворотах ставки.

Результаты валидации (expanding window, $t_0 = 60$, $h = 1$, 91 шаг) приведены в таблице 6.

Таблица 6 – Метрики базовых моделей

Модель	MAE (п.п.)	RMSE (п.п.)	MAPE (%)
Naive	0.5687	1.5634	4.78
Drift	0.6013	1.5690	5.05
ARIMA	0.7354	1.5995	6.11
Decomp+Trend	2.1230	3.2601	19.10

Ранжирование по MAE и по RMSE совпадает для трёх лучших моделей (RMSE: 1.563, 1.569, 1.600), но разрыв резко увеличивается для Decomp+Trend (RMSE = 3.260). Decomp+Trend допускает не только большие средние ошибки, но и крупные выбросы (рисунок 7).




Рисунок 7 — Ошибки прогнозов по времени для базовых моделей

Анализ ошибок по времени выявляет два паттерна. Крупнейшие ошибки всех моделей приходятся на кризисные эпизоды (декабрь 2014, февраль 2022): резкие внеплановые изменения ставки непредсказуемы для любой авторегрессионной модели. В периоды стабильной ставки (большая часть выборки) Naive и Drift имеют ошибки, близкие к нулю, тогда как ARIMA генерирует ненулевые отклонения из-за оцениваемых AR- и MA-коэффициентов.

Превосходство Naive над ARIMA (MAE 0.569 против 0.735) закономерно для дискретно изменяющихся ставок центральных банков. ARIMA оценивает AR- и MA-коэффициенты, которые вносят дополнительную дисперсию в прогноз. Когда ставка не меняется (большинство месяцев), любое отклонение прогноза от y_T является чистой ошибкой. Naive таких отклонений не допускает по определению.

Метрики Naive (MAE = 0.569 п.п.) используются далее как планка, относительно которой оцениваются все остальные модели. Модель считается

успешной, если она значимо превосходит Naïve по тесту Diebold-Mariano (раздел 3.7.2).

3.2 Статистические модели: StatsForecast

Четыре параметрические модели реализованы через библиотеку StatsForecast [52] с единой схемой валидации (*expanding window*, $t_0 = 60$, $h = 1$, 91 шаг). Для всех моделей задан параметр *season_length* = 1, то есть сезонная компонента не моделируется. Это решение обосновано результатами STL-декомпозиции (подраздел 2.3.3): сезонная компонента объясняет 0.9% дисперсии ключевой ставки.

AutoARIMA. Модель ARIMA(p,d,q) с автоматическим подбором порядков по критерию AIC на каждом шаге валидации. Реализация StatsForecast использует алгоритм Хайндмана-Хандакара [10], аналогичный *pmdarima*, но оптимизированный по скорости. Результат: MAE = 0.717 п.п. Спецификация AutoARIMA из StatsForecast отличается от baseline ARIMA (*pmdarima*, MAE = 0.735) деталями реализации: различия в стратегии пошагового перебора и начальных значениях оптимизации. Разница в MAE (0.717 против 0.735) статистически незначима по тесту Diebold-Mariano (раздел 3.7.2).

AutoETS. Модель пространства состояний с автоматическим выбором типа ошибки, тренда и сезонности (режим ZZZ). Рекуррентные уравнения для аддитивной модели без сезонности (AAN):

$$l_t = l_{t-1} + b_{t-1} + \alpha \cdot \varepsilon_t, \quad (3.3)$$

$$b_t = b_{t-1} + \beta \cdot \varepsilon_t, \quad (3.4)$$

где l_t – уровень, b_t – тренд, α и β – параметры сглаживания, ε_t – ошибка прогноза. Выбор между 15 спецификациями (комбинации A/M/N для каждого компонента) выполняется по AIC [17]. При *season_length* = 1 сезонный компонент отключён, и пространство поиска сокращается до 5 моделей. Результат: MAE = 0.661 п.п.

CES (Complex Exponential Smoothing). Метод Светункова [18], моделирующий динамику ряда через комплекснозначное рекуррентное соотношение:

$$\tilde{y}_t = (\alpha_0 + i\alpha_1) \cdot \tilde{y}_{t-1} + (1 - \alpha_0 - i\alpha_1) \cdot y_t, \quad (3.5)$$

где $i = \sqrt{-1}$, α_0 и α_1 – параметры сглаживания. Вещественная часть $\tilde{y}_t$ даёт прогноз, мнимая часть моделирует фазовый сдвиг, связанный с сезонностью. Для ряда без выраженной сезонности преимущество CES перед классическим ETS не проявляется. Результат: MAE = 0.728 п.п., худший среди четырёх моделей.

AutoTheta. Метод θ -линий [19] декомпозирует ряд на компоненты с различной кривизной:

$$Z_\theta(t) = \theta \cdot y_t + (1 - \theta) \cdot L_t, \quad (3.6)$$

где L_t – линейный тренд, θ – параметр, управляющий степенью кривизны. При $\theta = 0$ получаем линейный тренд, при $\theta = 2$ – усиленную локальную кривизну. Прогноз строится как комбинация прогнозов θ -линий. Метод Theta победил в соревновании M3-competition [20] на коротких рядах с трендом.

Результат: MAE = 0.582 п.п., лучший среди параметрических моделей и ближайший к Naïve.

Результаты четырёх моделей в сопоставлении с baseline приведены в таблице 7.

Таблица 7 – Метрики статистических и базовых моделей

Ранг	Модель	Класс	MAE (п.п.)	RMSE (п.п.)	MAPE (%)
1	Naïve	baseline	0.5687	1.5634	4.78
2	AutoTheta	StatsForecast	0.5824	1.5683	4.90
3	Drift	baseline	0.6013	1.5690	5.05
4	AutoETS	StatsForecast	0.6610	1.6655	5.73
5	AutoARIMA	StatsForecast	0.7174	1.6376	5.87
6	CES	StatsForecast	0.7284	1.6764	6.30
7	ARIMA	baseline	0.7354	1.5995	6.11

Продолжение таблицы 7

8	Decomp+Trend	baseline	2.1230	3.2601	19.10
---	--------------	----------	--------	--------	-------

Прогнозы четырёх моделей StatsForecast на фоне фактической динамики ключевой ставки показаны на рисунке 8.




Рисунок 8 – Прогнозы статистических моделей и фактическое значение ключевой ставки

Ни одна из параметрических моделей не превзошла Naïve. AutoTheta ближе всех (MAE 0.582 против 0.569), но разница в 0.014 п.п. статистически значима по тесту Diebold-Mariano ($p = 0.0005$, раздел 3.7.2). Ранжирование по RMSE отличается от ранжирования по MAE: AutoARIMA (RMSE = 1.638) опережает AutoETS (RMSE = 1.666), хотя по MAE AutoETS лучше (0.661 против 0.717). Причина – различная чувствительность метрик к крупным ошибкам (подраздел 2.4.1): RMSE сильнее штрафует выбросы, и AutoARIMA допускает меньше крупных промахов, чем AutoETS, при большем числе мелких.

Интервальные оценки. StatsForecast генерирует предсказательные интервалы (prediction intervals) на основе распределения ошибок прогноза. Для уровня доверия $(1 - \alpha)$ интервал определяется как:

$$PI_{1-\alpha} = \left[\hat{y} - z_{\frac{\alpha}{2}} \cdot \hat{\sigma}, \hat{y} + z_{\frac{\alpha}{2}} \cdot \hat{\sigma} \right], \quad (3.7)$$

где $\hat{\sigma}$ – оценка стандартного отклонения ошибки прогноза, $Z_{\frac{\alpha}{2}}$ – квантиль стандартного нормального распределения. Качество интервальных оценок измеряется покрытием (coverage) – долей фактических значений, попавших в интервал:

$$\text{Coverage} = \left(\frac{1}{n}\right) \cdot \sum_{t=1}^n I(y_t \in \text{PI}_t), \quad (3.8)$$

где $I(\cdot)$ – характеристическая функция. $I_A(x) = \begin{cases} 1, & \text{если } x \in A \\ 0, & \text{если } x \notin A \end{cases}$

Идеальное покрытие для 95%-интервала равно 0.95. Если coverage < 0.95, интервалы слишком узкие (модель «самоуверенна»); если coverage > 0.95, интервалы избыточно широкие (модель «осторожна»).

Результаты оценки покрытия приведены в таблице 8.

Таблица 8 – Покрытие интервальных оценок статистических моделей

Модель	Coverage 90% CI	Coverage 95% CI
AutoARIMA	92.3%	94.5%
AutoETS	96.7%	96.7%
CES	95.6%	96.7%
AutoTheta	95.6%	95.6%

Совпадение покрытия 90%- и 95%-интервалов у ряда моделей объясняется ступенчатым характером ключевой ставки. Ряд не содержит наблюдений, попадающих строго между границами двух интервалов: в кризисные эпизоды фактические значения многократно превышают верхнюю границу даже 95%-го интервала, тогда как в стабильные периоды они с запасом укладываются в более узкий 90%-й. Расширение доверительного уровня с 90% до 95% не захватывает ни одного дополнительного наблюдения – эмпирическое покрытие не меняется.




Рисунок 9 – Прогнозы статистических моделей с 95% доверительными интервалами

Прогнозы четырёх моделей StatsForecast с 95%-ными доверительными интервалами, 4 панели, с указанием coverage и средней ширины CI показаны на рисунке 9.

Покрытие всех четырёх моделей близко к номинальному. AutoARIMA имеет coverage 94.5% при номинальных 95%, то есть интервалы чуть занижены. AutoETS и CES показывают 96.7% – интервалы несколько шире необходимого. AutoTheta с coverage 95.6% ближе всего к номиналу. Диапазон 94.5–96.7% указывает на корректную калибровку параметрических моделей на данном ряде. Prophet и LightGBM (разделы 3.3 и 3.4) покажут покрытие 79–89% и 67.5% соответственно.

3.3 Prophet с экзогенными регрессорами

Prophet [29] моделирует временной ряд как сумму компонент:

$$y(t) = g(t) + s(t) + \sum_j \beta_j \cdot x_{j(t)} + \varepsilon(t), \quad (3.9)$$

где $g(t)$ – кусочно-линейный тренд с автоматически определяемыми точками излома (changepoints), $s(t)$ – сезонная компонента (ряды Фурье), $x_j(t)$ – экзогенные регрессоры с коэффициентами β_j , $\varepsilon(t)$ – ошибка. Параметры оцениваются методом MAP (максимум апостериорной вероятности) через Stan.

Тренд $g(t)$ задаётся как:

$$g(t) = (k + a(t)^T \delta) \cdot t + (m + a(t)^T \gamma), \quad (3.10)$$

где k – начальный наклон, δ – вектор изменений наклона в точках излома, $a(t)$ – вектор индикаторов ($a_j(t) = 1$ при $t \geq s_j$), γ – вектор поправок на непрерывность. Точки излома s_j определяются автоматически из данных с регуляризацией через лапласово априорное распределение $\delta_j \sim \text{Laplace}(0, \tau)$, где τ управляет гибкостью тренда.

В настоящей работе сравниваются две конфигурации: Prophet-base (без регрессоров) и Prophet-exog (с экзогенными регрессорами). Для Prophet-exog использованы 8 регрессоров с лагом 1: *zcys_1y_lag1*, *spread_10y_1y_lag1*, *cpi_mom_lag1*, *brent_lag1*, *usd_rub_lag1*, *m2_lag1*, *ruonia_lag1*, *spread_ruonia_keyrate_lag1*. Лагирование на 1 месяц обеспечивает доступность значений регрессоров на момент прогнозирования и предотвращает data leakage. Сезонная компонента отключена (*yearly_seasonality = False*, *weekly_seasonality = False*, *daily_seasonality = False*), что согласуется с результатами STL-декомпозиции (подраздел 2.3.3).

Валидация выполнена по схеме expanding window ($t_0 = 60$, $h = 1$, 88 шагов). Число шагов меньше, чем у StatsForecast (91), поскольку лагированные регрессоры сокращают доступный период на 3 наблюдения.

Результаты приведены в таблице 9.

Таблица 9 – Метрики модели Prophet

Модель	MAE (п.п.)	RMSE (п.п.)	MAPE (%)	N
Prophet-base	2.7265	4.1295	21.37	88

Продолжение таблицы 9

Prophet-exog	0.9045	1.6418	8.41	88
--------------	--------	--------	------	----

Прогнозы Prophet-base и Prophet-exog на фоне фактической динамики ключевой ставки показаны на рисунке 10




Рисунок 10 – Прогнозы модели Prophet и фактическое значение ключевой ставки

Prophet-base показал худший результат среди всех 16 моделей: MAE = 2.727 п.п. Причина – кусочно-линейный тренд систематически запаздывает при разворотах ставки. Prophet аппроксимирует ряд линейными сегментами между changepoints, и при резком изменении направления (например, переход от снижения к повышению в 2021–2022 гг.) новый changepoint определяется только после накопления достаточного числа наблюдений. До этого момента прогноз продолжает экстраполировать старый тренд.

Добавление экзогенных регрессоров сократило MAE с 2.727 до 0.905 п.п., то есть на 67%. Регрессоры компенсируют запаздывание тренда: когда *zсус_1у_lag1* или *ruonia_lag1* сигнализируют об изменении рыночных условий, модель корректирует прогноз через коэффициенты β_j ещё до того, как тренд $g(t)$ успеет отреагировать. При этом Prophet-exog (MAE = 0.905) всё

равно уступает Naive ($MAE = 0.569$): линейная зависимость y от x_j недостаточна для полного описания связи ставки с рыночными индикаторами.

Разрыв между Prophet-base и Prophet-exog показывает, что экзогенные переменные содержат информацию, не заложенную в историю самого ряда. Без внешних данных Prophet работает хуже Decomп+Trend (MAE 2.727 против 2.123); с ними – на уровне ансамблевых моделей (LightGBM $MAE = 1.081$, раздел 3.4).

Интервальные оценки. Prophet генерирует предсказательные интервалы через симуляцию из апостериорного распределения параметров. Coverage оценена на 88 шагах валидации (рисунок 11).




Рисунок 11 — Прогнозы модели Prophet с 95% доверительными интервалами

Prophet-base имеет coverage 79.5% при номинальных 95%, что указывает на систематическое занижение неопределённости. Ширина интервала (9.32 п.п.) велика в абсолютном выражении, но недостаточна для покрытия крупных ошибок тренда. Модель «уверена» в своём тренде, который при этом систематически ошибается.

Prophet-exog показывает coverage 92.0% при ширине 3.84 п.п. Интервалы калиброваны лучше, хотя остаются чуть ниже номинала. По сравнению со StatsForecast (coverage 94.5–96.7%, раздел 3.2) Prophet-exog менее консервативен. Различие объясняется методом построения интервалов: StatsForecast использует аналитическую формулу (3.7), а Prophet – Монте-

Карло симуляцию, которая при ограниченном числе итераций может недооценивать хвосты распределения.

Результаты оценки покрытия приведены в таблице 10.

Таблица 10 – Покрытие интервальных оценок модели «Prophet»

Модель	Coverage 95% CI	Средняя ширина CI (п.п.)
Prophet-base	79.5%	9.32
Prophet-exog	92.0%	3.84

3.4 Ансамблевые модели: LightGBM и XGBoost

3.4.1 Конструирование признаков

Переход от временного ряда к задаче регрессии требует конструирования признакового пространства вручную [10]. На вход модели подаётся вектор признаков x_t , на выход – значение ключевой ставки y_{t+1} . Признаки сгруппированы в пять блоков.

Лаги целевой переменной (5 признаков): lag_1 , lag_2 , lag_3 , lag_6 , lag_12 . Значение $lag_k = y_{t-k}$, то есть ставка k месяцев назад. Лаг 1 содержит максимум информации ($r = 0.953$ с целевой переменной), лаги 6 и 12 улавливают долгосрочную динамику.

Скользящие статистики (6 признаков): $rolling_mean_W$ и $rolling_std_W$ для $W \in \{3, 6, 12\}$. Скользящее среднее характеризует текущий «режим» ставки (высокий/низкий уровень), стандартное отклонение – волатильность. Все статистики вычислены со сдвигом на 1 ($shift(1)$), чтобы не включать текущее значение y_t .

Разности (3 признака): $diff_1 = y_{t-1} - y_{t-2}$, $diff_3 = y_{t-1} - y_{t-4}$, $diff_6 = y_{t-1} - y_{t-7}$. Разности показывают направление и скорость изменения ставки на разных горизонтах.

Лагированные экзогенные переменные (18 признаков): для каждой из 9 экзогенных переменных (cpi_tom , $m2$, usd_rub , $brent$, $zcys_1y$, $zcys_5y$,

zсус_10y, *spread_10y_1y*, *spread_5y_1y*) вычислены лаги 1 и 3. Лаг 1 обеспечивает доступность значения на момент прогнозирования, лаг 3 позволяет уловить запаздывающие зависимости. RUONIA и *spread_ruonia_keyrate* также включены с лагами 1 и 3.

Календарные признаки (2 признака): *month* и *quarter*. Хотя STL-декомпозиция не выявила сезонности в самой ставке (подраздел 2.3.3), заседания Совета директоров ЦБ РФ проводятся по фиксированному графику, и календарные признаки могут уловить эту структуру.

Итого сконструировано 34 признака. После удаления строк с пропусками (из-за лагов 12 месяцев) осталось 137 наблюдений за период сентябрь 2014 – январь 2026.

Гиперпараметры LightGBM и XGBoost зафиксированы: 200 деревьев, *max_depth* = 5, *learning_rate* = 0.05, *subsample* = 0.8, *colsample_bytree* = 0.8, *L1* = *L2* = 0.1. Подбор на сетке не проводился (обоснование – подраздел 2.5). Валидация: *expanding window*, $t_0 = 60$, $h = 1$, 77 шагов.

Результаты ML моделей приведены в таблице 11.

Таблица 11 – Метрики ML моделей

Модель	MAE (п.п.)	RMSE (п.п.)	MAPE (%)
XGBoost	1.0525	1.9132	8.73
LightGBM	1.1088	2.0102	9.22

Результаты: LightGBM MAE = 1.109 п.п., XGBoost MAE = 1.053 п.п. Обе модели уступают Naïve (0.569) и параметрическим моделям (AutoTheta 0.582, AutoETS 0.661). LightGBM и XGBoost находятся на уровне Prophet-exog (0.905), занимая 8–10 позиции из 16 в общем ранжировании.

Прогнозы LightGBM и XGBoost на фоне фактической динамики ключевой ставки показаны на рисунке 12.




Рисунок 12 – Прогнозы ML-моделей и фактическое значение ключевой ставки

3.4.2 Комплексная оценка информативности признаков

Для оценки вклада отдельных признаков в прогноз применены пять методов, различающихся математическим аппаратом и допущениями.

Built-in importance (gain). LightGBM подсчитывает суммарное снижение функции потерь по всем разбиениям, использующим данный признак. Метод быстр, но может завышать важность коррелированных признаков: если два признака несут одинаковую информацию, разбиения распределяются между ними произвольно.

SHAP-значения. Метод основан на разложении Шепли из теории кооперативных игр [28]. Каждый признак рассматривается как «игрок» в коалиционной игре, где «выигрыш» – значение прогноза. SHAP-значение признака j определяется как его средний маргинальный вклад по всем возможным коалициям остальных признаков [27]:

$$\varphi_j = \sum_{S \subseteq N \setminus \{j\}} \frac{(|S|! \cdot (|N| - |S| - 1)!)}{|N|!} \cdot [f(S \cup \{j\}) - f(S)], \quad (3.11)$$

где N – множество всех признаков, S – подмножество (коалиция), $f(S)$ – прогноз модели, использующей только признаки из S . Разложение Шепли

удовлетворяет четырём аксиомам: эффективность ($\sum \varphi_j = f(x) - E[f(x)]$), симметрия, аддитивность и null player ($\varphi_j = 0$ для неинформативного признака) [28]. Для деревьев решений SHAP-значения вычисляются за полиномиальное время через алгоритм TreeSHAP [27]. Точечная диаграмма SHAP-значений для TOP-20 признаков, цвет точки соответствует значению признака (красный – высокое, синий – низкое) показана на рисунке 13.




Рисунок 13 – Диаграмма SHAP-значений для признаков

ТОР-3 признака по среднему $|SHAP|$: *zcyc_5y_lag1* (1.357), *zcyc_1y_lag1* (1.219), *lag_1* (0.710). SHAP-значения КБД-переменных в 1.5–2 раза превышают значения лагов целевой переменной: изменение бескупонной доходности на 1 п.п. смещает прогноз ставки сильнее, чем аналогичное изменение самой ставки месяцем ранее.

Корреляции Пирсона, Спирмена и Кендалла. Три меры корреляции оценивают связь каждого признака с целевой переменной: Пирсон измеряет линейную зависимость, Спирмен – монотонную (ранговую), Кендалл – согласованность пар наблюдений [9]. Кендалл наиболее робастен для коротких рядов с выбросами. Все три меры дают согласованное ранжирование: *zcyc_1y_lag1* занимает первое место по Пирсону ($r = +0.955$) и Спирмену ($\rho = +0.972$), *lag_1* – первое по Кендаллу ($\tau = +0.917$).

Сравнение трёх мер корреляции для ТОП-15 признаков показано на горизонтальной диаграмме корреляций (рисунок 14).




Рисунок 14 – Диаграмма корреляций для признаков

Permutation importance (перестановочная важность). Для каждого признака x_j его значения перемешиваются случайным образом, после чего вычисляется ухудшение MAE [26, 55]:

$$PI(j) = MAE(\text{модель с перемешанным } x_j) - MAE(\text{исходная модель}). \quad (3.12)$$

Если $PI(j) > 0$, признак полезен; если $PI(j) \approx 0$, признак не несёт информации. Процедура повторяется 10 раз для устойчивости оценки. TOP-3: *zcyc_1y_lag1* ($PI = 1.263$), *zcyc_5y_lag1* ($PI = 1.213$), *lag_1* ($PI = 1.046$).

Permutation importance для TOP-20 признаков с доверительными интервалами показано на рисунке 15.




Рисунок 15 – Диаграмма перестановочной важности признаков

Сводная таблица рангов – таблица 12. Для каждого из 34 признаков вычислен ранг по каждому из пяти методов (1 = самый важный). Средний ранг агрегирует оценки.

Таблица 12 – Сводная таблица рангов лучших 10 признаков

Признак	Built-in	SHAP	Пирсон	Спирмен	Permutation	Средний ранг
zcyc_1y_lag1	4	2	1	1	1	1.8
lag_1	8	3	2	2	3	3.6
zcyc_5y_lag1	11	1	3	6	2	4.6
zcyc_10y_lag1	17	4	5	9	4	7.8
spread_10y_1y_lag1	2	6	13	13	6	8.0
lag_2	22	8	7	5	7	9.8
usd_rub_lag1	1	5	20	25	5	11.2
zcyc_1y_lag3	23	11	6	4	13	11.4
zcyc_5y_lag3	16	16	8	7	12	11.8
spread_10y_1y_lag3	12	13	16	14	11	13.2

Сводная визуализация рангов в виде горизонтальной диаграммы по 5 методам для ТОП-15 признаков показана на рисунке 16.




Рисунок 16 – Сводная диаграмма рангов по методам для признаков

Среди TOP-10 по среднему рангу 7 признаков относятся к КБД ОФЗ (*zcysc_1y_lag1*, *zcysc_5y_lag1*, *zcysc_10y_lag1*, *spread_10y_1y_lag1*, *zcysc_1y_lag3*, *zcysc_5y_lag3*, *spread_10y_1y_lag3*) и 3 – к другим источникам (*lag_1*, *lag_2*, *usd_rub_lag1*). КБД занимает верхние позиции по всем пяти методам. Расхождение между методами наиболее заметно для *usd_rub_lag1*: built-in importance ставит его на 1-е место (high gain), а корреляция Пирсона – на 20-е ($r = +0.539$). Причина – нелинейность связи: USD/RUB влияет на ставку через пороговые эффекты, которые деревья решений улавливают, а линейная корреляция – нет.

3.4.3 Ablation study: вклад КБД в точность прогноза

Ablation study – прямой способ оценить вклад группы признаков: модель обучается без них, и сравнивается итоговая метрика. LightGBM обучен на 24 признаках (без 10 КБД-переменных: *zcysc_lag1*, *zcyclag3*, *spreadlag1*, *spread_lag3*) по той же схеме expanding window.

Результат: MAE без КБД = 1.073 п.п., MAE с КБД = 1.109 п.п. Удаление КБД не ухудшило, а улучшило MAE на 0.035 п.п. (3.2%).

На рисунке 17 изображено исследование абляции – левая панель: прогнозы с КБД и без КБД на фоне факта; правая панель: диаграмма MAE двух конфигураций.




Рисунок 17 – Прогнозы с КБД и без КБД, вклад КБД в точность прогнозов

Этот результат не противоречит высоким SHAP-значениям КБД-переменных, а объясняется мультиколлинеарностью. При горизонте $h = 1$ бескупонные доходности почти полностью дублируют информацию, содержащуюся в лаге целевой переменной: $r(\text{key_rate}, \text{zcys_1y}) = 0.959$, $r(\text{lag_1}, \text{zcys_1y_lag1}) > 0.95$. Когда КБД-признаки удаляются, модель компенсирует потерю через lag_1 и скользящие статистики. Добавление 10 избыточных переменных увеличивает дисперсию модели без снижения смещения, что и приводит к незначительному росту MAE.

На горизонтах $h = 3$ и $h = 6$ (раздел 3.7.4) лаговая информация теряет актуальность (lag_1 отстаёт от реальности на 3–6 месяцев), КБД в составе признаков LightGBM частично отыгрывает отставание от моделей, работающих только на истории самого ряда. Этот вопрос исследуется отдельно.

3.4.4 Интервальные оценки LightGBM

Деревья решений дают точечный прогноз и не имеют встроенного механизма построения предсказательных интервалов. Для получения интервальных оценок применена квантильная регрессия [21]: обучены две дополнительные модели LightGBM с целевыми квантилями $\alpha = 0.025$ и $\alpha = 0.975$ (objective = quantile). Каждая модель минимизирует pinball loss:

$$L_{\alpha}(y, \hat{y}) = \alpha \cdot \max(y - \hat{y}, 0) + (1 - \alpha) \cdot \max(\hat{y} - y, 0) \quad (3.13)$$

При $\alpha = 0.025$ модель обучается занижать прогноз так, чтобы лишь 2.5% наблюдений были ниже границы; при $\alpha = 0.975$ – завышать. Пара $[q_{0.025}, q_{0.975}]$ образует 95%-ный предсказательный интервал. В отличие от параметрических интервалов (формула 3.7), квантильные интервалы не предполагают нормальности остатков и допускают асимметрию.

Результат: coverage = 67.5% при номинальных 95%, средняя ширина интервала = 8.45 п.п. Покрывтие значительно ниже номинала и хуже, чем у параметрических моделей (94.5–96.7%) и Prophet (79.5–92.0%).

Причина низкого покрытия – переобучение квантильных моделей на коротком ряде. На каждом шаге валидации обучающая выборка содержит от 60 до 136 наблюдений, из которых лишь единицы попадают в хвосты распределения (экстремальные значения ставки). Модель не видит достаточно примеров из хвостов и занижает ширину интервала. Параметрические модели оценивают σ аналитически из всех остатков, что даёт более устойчивые оценки хвостов при малом числе наблюдений.

3.5 Нейросетевые модели: N-BEATS, N-HiTS, PatchTST

Архитектуры N-BEATS, N-HiTS и PatchTST валидировались на бенчмарках M3, M4 и ETT, где длина одного ряда составляет от нескольких тысяч до сотен тысяч точек. В настоящей работе те же модели применяются к ряду из 151 наблюдения при обучающих окнах 60–150 точек. Это режим, в котором у данных архитектур нет преимущества перед классическими методами: по итогам M4-конкурса [7] эмпирическая граница, за которой нейросети начинают превосходить статистические модели, лежит на уровне нескольких сотен наблюдений на ряд при выраженной сезонности. Низкое место нейросетей в сводном сравнении (раздел 3.7) объясняется не свойствами конкретных архитектур, а ограничением длины ряда: число обучаемых параметров у любой из рассматриваемых моделей превышает число наблюдений на 2–5 порядков, и оценки весов оказываются статистически несостоятельными. Результаты по каждой архитектуре приведены ниже, причины проигрыша обсуждаются в конце раздела.

Три нейросетевые архитектуры реализованы через библиотеку NeuralForecast [53]. Все модели обучены на CPU (PyTorch 2.11.0) с параметрами, адаптированными для короткого ряда: *input_size* = 12 месяцев, *max_steps* = 300, *batch_size* = 32, *scaler_type* = standard. Валидация: expanding

window, $t_0 = 60$, $h = 1$, 91 шаг. На каждом шаге модель переобучается заново на расширенном окне.

N-BEATS. Архитектура [30] построена на полносвязных сетях с двойным residual stacking. Входной вектор (последние 12 значений ряда) проходит через стек блоков, каждый из которых генерирует два выхода: backcast и forecast (прогноз). Residual-связи передают необъяснённый остаток следующему блоку. Итоговый прогноз – сумма forecast-выходов всех блоков:

$$\hat{y} = \sum_{b=1}^B V_b \cdot \theta_b^f, \quad (3.14)$$

где θ_b^f – вектор коэффициентов блока b , V_b – матрица базисных функций.

В interpretable-варианте базисные функции фиксированы: полиномы для тренда ($\hat{y}_{trend} = \sum \theta_i \cdot t^i$) и тригонометрические функции для сезонности ($\hat{y}_{seas} = \sum \left(a_k \cdot \cos\left(\frac{2\pi kt}{m}\right) + b_k \cdot \sin\left(\frac{2\pi kt}{m}\right) \right)$). Однако interpretable stacks в NeuralForecast требуют $h \geq 2$, поэтому при $h = 1$ использованы generic stacks (stack_types = ['identity', 'identity', 'identity']), где V_b – обучаемые матрицы без заданной структуры.

Модель содержит 2.4М параметров. При обучающем окне от 60 до 150 наблюдений отношение «параметры/данные» составляет 16 000–40 000. Регуляризация осуществляется через раннюю остановку (max_steps = 300) и нормализацию входа (TemporalNorm).

Результат: MAE = 1.127 п.п., RMSE = 2.175 п.п.

N-HiTS. Расширение N-BEATS с иерархической интерполяцией [31]. Каждый блок работает на своём временном масштабе: входной ряд сжимается через MaxPool с различными размерами ядра, а выход блока восстанавливается интерполяцией до исходного разрешения. Мультимасштабная структура снижает вычислительную сложность с $O(n \cdot L \cdot H)$ (N-BEATS) до $O(n \cdot L \cdot H \cdot \sum k_i)$, где k_i – коэффициенты сжатия.

На ряде длиной 151 наблюдение преимущества мультимасштабной декомпозиции не проявляются. Иерархическая интерполяция в N-HiTS рассчитана на длинные ряды с сосуществующими сезонами разной частоты —

часовыми, суточными, недельными [31]; у ключевой ставки сезонная компонента не превышает 1% дисперсии, декомпозиция на тренд и сезонность здесь работают вхолостую. Полученный MAE = 1.215 (худший из трёх) отражает именно это несоответствие архитектуры и задачи, тогда как на других классах рядов та же модель показывает результаты, существенно превосходящие классические методы [31].

PatchTST. Трансформер с channel-independent patching [32]. Входной ряд делится на перекрывающиеся патчи (подпоследовательности) длины $P = 4$ с шагом $S = 2$. Каждый патч проецируется в пространство размерности $d = 32$ и подаётся как токен в Transformer encoder (2 слоя, 4 головы внимания). Механизм self-attention вычисляет попарные зависимости между патчами:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) \cdot V, \quad (3.15)$$

где Q, K, V – матрицы запросов, ключей и значений, $d_k = \frac{d}{n_{heads}} = 8$.

Channel-independent означает, что каждый временной ряд обрабатывается отдельно (в нашем случае ряд один).

PatchTST содержит 42.6 тыс. параметров, в 56 раз меньше, чем N-BEATS. Отношение «параметры/данные» составляет 280–710 — ближе к допустимому диапазону, чем у двух других сетей. Метрики: MAE = 1.153 п.п., RMSE = 2.133 п.п. По RMSE модель опережает N-BEATS (2.133 против 2.175), по MAE незначительно уступает (1.153 против 1.127); крупных промахов у неё меньше, мелких — больше.

Этот результат косвенно подтверждает гипотезу о том, что главное ограничение задаёт длина ряда. Сокращение числа параметров на два порядка пропорционального улучшения точности не принесло. Будь узким местом избыточная параметризация, такое сжатие имело бы заметный эффект; раз эффекта нет, ограничителем выступает не размер модели, а число точек, на которых её веса оцениваются, — независимо от того, сколько этих весов.

Результаты трёх нейросетей приведены в таблице 13.

Таблица 13 – Метрики нейросетевых моделей

Модель	Параметры	MAE (п.п.)	RMSE (п.п.)	MAPE (%)	Время обучения (91 окно)
N-BEATS	2.4M	1.1266	2.1753	9.12	~175 с
N-HiTS	~1.2M	1.2152	2.4259	9.42	~175 с
PatchTST	42.6K	1.1528	2.1331	9.75	~175 с

Прогнозы трёх нейросетей на фоне фактической динамики ключевой ставки показаны на рисунке 18.




Рисунок 18 – Прогнозы нейросетей и фактическое значение ключевой ставки

Все три нейросети уступают Naive (MAE 0.569), параметрическим моделям (AutoTheta 0.582) и Prophet-exog (0.905). Их MAE (1.13–1.22) находится на уровне LightGBM (1.109) и XGBoost (1.053). Это не означает, что архитектуры N-BEATS, N-HiTS или PatchTST слабы: все три входят в число state-of-the-art для прогнозирования временных рядов на бенчмарках длиной 10^3 – 10^6 точек. Низкие метрики в настоящем эксперименте объясняются длиной ряда; архитектура и состав признаков влияют на результат во вторую очередь.

Главная причина — несостоятельность оценок весов на 151 наблюдении. У рассмотренных архитектур число обучаемых параметров варьируется от

$4 \cdot 10^4$ (PatchTST) до $2.4 \cdot 10^6$ (N-BEATS); на обучающем окне 60–150 точек оно превышает число наблюдений на 2–5 порядков. В таком режиме функция потерь имеет множество локальных минимумов, близких по значению на обучающей выборке, и Adam с ранней остановкой не способен выбрать между ними по статистическому критерию: данных для этого недостаточно. Ранняя остановка и нормализация входа эффект смягчают, но не устраняют. По итогам M4-конкурса [7] разрыв между нейросетями и статистическими моделями нарастает по мере сокращения длины ряда, и короткие месячные ряды — тот режим, в котором классические методы статистически выигрывают. Полученное на 151 наблюдении соотношение $\text{Naive} \approx \text{AutoTheta} \ll \text{нейросети}$ согласуется с этим выводом.

Вторичные факторы. Во-первых, в реализации NeuralForecast не задействованы экзогенные переменные. Все три нейросети использовали только историю самого ряда (univariate), тогда как Prophet-exog и LightGBM с экзогенными регрессорами достигли сопоставимого MAE (0.905–1.109) при значительно меньшем числе параметров. Подключение КБД и ROISfix могло бы повысить точность, но основного ограничения по длине ряда не сняло бы. Во-вторых, целевой класс задач не соответствует архитектурному предназначению моделей. N-BEATS и N-HiTS спроектированы для рядов с выраженной сезонной структурой (retail, energy, web traffic); у ключевой ставки сезонная компонента составляет 0.9% дисперсии, и декомпозиция на тренд и сезонность здесь работает вхолостую. PatchTST в этом отношении нейтральнее, что отчасти объясняет его лучший RMSE.

Контрфактическая оценка. Если бы целевой ряд имел длину порядка 10^3 наблюдений (например, дневная или недельная частота за тот же период), отношение «параметры/данные» опустилось бы до значений, при которых нейросети показывают преимущество в опубликованных результатах [30, 31, 32]. На месячных данных за 12.5 лет добиться такого преимущества нельзя ни выбором архитектуры, ни настройкой гиперпараметров. Это согласуется с результатом главы 4: на ряде НБРК (127 месяцев) первенство Naive над всеми

параметрическими альтернативами сохраняется. Тестирование нейросетей в Казахстане заведомо дало бы тот же результат: ряд там короче, отношение «параметры/данные» только ухудшается.

Ошибки прогнозов трёх нейросетей во времени показаны на рисунке 19.




Рисунок 19 – Диаграммы ошибок прогнозов нейросетей

Анализ ошибок во времени показывает, что нейросети, как и все остальные модели, допускают крупнейшие промахи в кризисные периоды (декабрь 2014, февраль 2022). В периоды стабильности ошибки нейросетей в среднем больше, чем у Naive и AutoTheta: модели генерируют ненулевые отклонения от y_T из-за обучаемых весов, аналогично ARIMA (подраздел 3.1).

Время обучения составило ~175 секунд на 91 окно валидации (CPU), что в 3 раза больше, чем у StatsForecast (128 с) и в 45 раз больше, чем у LightGBM (4 с). Использование GPU сократило бы время обучения в 5–10 раз, на точность прогноза это бы не повлияло: ограничение исходит от длины ряда, а не от вычислительного ресурса. То же касается подбора гиперпараметров — входного окна, числа слоёв, learning rate. На рядах такой длины тонкая настройка способна сместить MAE в пределах ± 0.05 – 0.10 п.п., но разрыв порядка 0.5 п.п. между нейросетями и Naive она перекрыть не в состоянии: разрыв возникает из статистической неразличимости моделей на 151 наблюдении и качеством оптимизации не определяется.

3.6 Foundation Models: TimeGPT (zero-shot)

Foundation models для временных рядов – предобученные трансформеры, обученные на миллионах рядов из различных доменов и способные прогнозировать новый ряд без дополнительного обучения (zero-shot) [3]. В настоящей работе протестирована модель TimeGPT [35]; Chronos-Bolt [36] и TimesFM [37] не удалось запустить из-за конфликтов зависимостей (несовместимость версий PyTorch и chronos-forecasting).

TimeGPT. Модель архитектуры Transformer decoder, обученная на более чем 100 миллиардах точек временных рядов из открытых источников [35]. Входной ряд рассматривается как «промт»: значения разбиваются на патчи, проецируются в пространство эмбедингов и подаются на вход декодеру, который генерирует продолжение ряда. Токенизация выполняется через пэтчинг (аналогично PatchTST, подраздел 3.5), а не через квантование (как в Chronos). Модель доступна через API Nixtla; вычисления выполняются на удалённом сервере.

Ключевое отличие от моделей разделов 3.1–3.5: TimeGPT не видит обучающих данных ключевой ставки в процессе предобучения (модель обучена преимущественно на рядах из доменов retail, energy, weather, finance развитых стран). Прогнозирование ставки ЦБ РФ – задача out-of-distribution: процесс управляется решениями регулятора, а не рыночными или природными закономерностями, составляющими основу обучающей выборки TimeGPT.

Валидация выполнена по стандартной схеме (expanding window, $t_0 = 60$, $h = 1$, 91 шаг). На каждом шаге TimeGPT получает через API историю $\{y_1, \dots, y_t\}$ и возвращает прогноз $\hat{y}_{t+1}$. Экзогенные переменные не использовались (API поддерживает их, но для чистоты сравнения с нейросетевыми моделями, также работающими в univariate-режиме, регрессоры исключены). Время выполнения 91 шага составило 92 секунды, включая сетевые задержки.

Результат: MAE = 0.823 п.п., RMSE = 1.707 п.п., MAPE = 6.66%.

Прогноз TimeGPT (zero-shot) на фоне фактической динамики ключевой ставки за период валидации показан на рисунке 20.




Рисунок 20 — Прогнозы предобученных моделей и фактическое значение ключевой ставки

TimeGPT занимает 8-е место из 16 по MAE, между CES (0.728) и Prophet-exog (0.905). Модель превосходит все ML-модели (LightGBM 1.109, XGBoost 1.053) и все нейросети (N-BEATS 1.127, PatchTST 1.153, N-HiTS 1.215), несмотря на отсутствие доступа к экзогенным переменным и специфической настройки. При этом TimeGPT уступает Naïve (0.569) и всем параметрическим моделям StatsForecast (0.582–0.728): «общие знания» о временных рядах не компенсируют отсутствие адаптации к конкретному процессу.

Позиция TimeGPT в ранжировании объяснима. Модель обучена на рядах, где «завтра похоже на сегодня» — лишь один из многих паттернов. TimeGPT пытается обнаружить тренд, сезонность и циклическую структуру, которые для ключевой ставки вторичны (сезонность 0.9%, тренд нестабилен). Параметрические модели, настроенные на конкретный ряд (*season_length* = 1, автоматический подбор *d*), избегают этих ложных паттернов. Однако ML-модели и нейросети, также настроенные на конкретный ряд, проигрывают TimeGPT — вероятно, из-за переобучения на коротком ряде, от которого предобученная модель застрахована по определению.

Сопоставление TimeGPT с LightGBM и Prophet-exog выявляет компромисс между адаптацией и обобщением. LightGBM и Prophet-exog используют экзогенные переменные и обучаются на данных ключевой ставки, но переобучаются. В настоящем эксперименте TimeGPT запускался в univariate-режиме, без экзогенных регрессоров — чтобы сравнение с нейросетевыми моделями было корректным. Архитектурно TimeGPT экзогенные переменные поддерживает, и их подключение — естественное направление дальнейших исследований.

Chronos-Bolt и TimesFM. Chronos-Bolt [36] — модель архитектуры T5 (encoder-decoder), токенизирующая временной ряд через квантование: непрерывные значения отображаются на дискретные бины, и прогноз строится как распределение вероятностей над бинами. TimesFM [37] — decoder-only модель Google, обученная на 100 миллиардах точек. Обе модели запускаются локально (без API), но не были протестированы из-за конфликта зависимостей: chronos-forecasting требует версию PyTorch, несовместимую с NeuralForecast 1.7.4 в одном окружении. Создание отдельного виртуального окружения также не решило проблему (ошибка инициализации ChronosConfig). В тексте работы Chronos и TimesFM описаны в главе 1 (подраздел 1.5.1) на уровне архитектуры; их практическое тестирование отнесено к направлениям дальнейших исследований.

Общий вывод по foundation models: zero-shot прогнозирование дискретно изменяющейся ставки центрального банка даёт результат лучше обученных ML-моделей и нейросетей, но хуже простых параметрических моделей. Этот вывод относится к режиму без экзогенных регрессоров. TimeGPT API позволяет их подключать, и с экзогенными переменными позиция модели в ранжировании может оказаться иной. Сравнение TimeGPT-exog с Prophet-exog и LightGBM на экзогенных регрессорах в настоящей работе не проводится — оно требует отдельного методологического протокола. Ограничение transfer learning на данной задаче обусловлено не архитектурой модели, а природой целевого процесса: ставка определяется

решениями 14 членов Совета директоров ЦБ РФ, а не статистическими закономерностями, заложенными в обучающую выборку предобученных трансформеров.

3.7 Сводное сравнение моделей

3.7.1 Таблица метрик и интервальные оценки

Полные результаты 16 моделей на единой схеме валидации (expanding window, $h = 1$) приведены в таблице 14.

Таблица 14 – Сводная таблица используемых моделей

Ранг	Модель	Класс	MAE (п.п.)	RMSE (п.п.)	MAPE (%)	N
1	Naive	baseline	0.569	1.563	4.78	91
2	AutoTheta	параметрическая	0.582	1.568	4.90	91
3	Drift	baseline	0.601	1.569	5.05	91
4	AutoETS	параметрическая	0.661	1.666	5.73	91
5	AutoARIMA	параметрическая	0.717	1.638	5.87	91
6	CES	параметрическая	0.728	1.676	6.30	91
7	ARIMA	baseline	0.735	1.600	6.11	91
8	TimeGPT	foundation	0.823	1.707	6.66	91
9	Prophet-exog	аддитивная	0.905	1.642	8.41	88
10	XGBoost	бустинг	1.053	1.913	8.73	77
11	LightGBM	бустинг	1.109	2.010	9.22	77
12	N-BEATS	нейросетевая	1.127	2.175	9.12	91
13	PatchTST	нейросетевая	1.153	2.133	9.75	91
14	N-HiTS	нейросетевая	1.215	2.426	9.42	91
15	Decomp+Trend	baseline	2.123	3.260	19.10	91
16	Prophet-base	аддитивная	2.727	4.130	21.37	88

Горизонтальная диаграмма MAE всех 16 моделей, разделение по цвет по классу показана на рисунке 21.




Рисунок 21 – Диаграмма MAE всех моделей

Ранжирование выявляет чёткую иерархию по классам. Первые семь позиций занимают модели без экзогенных переменных (baseline и параметрические), работающие только с историей самого ряда. На 8-м месте – TimeGPT (zero-shot). Позиции 9–14 делят модели с экзогенными переменными (Prophet-exog, LightGBM, XGBoost) и нейросети. Две последние позиции – модели с систематическим запаздыванием тренда (Decomp+Trend, Prophet-base).

Ранжирование по RMSE частично расходится с ранжированием по MAE. Наиболее заметное расхождение – ARIMA: 7-е место по MAE (0.735), но 3-е по RMSE (1.600), что ниже AutoTheta (1.568) и Drift (1.569). ARIMA допускает больше мелких ошибок, но меньше крупных промахов. Аналогично, PatchTST (13-е по MAE) опережает N-BEATS (12-е по MAE) по RMSE: 2.133 против 2.175.

Анализ соотношения MAE и RMSE по классам подтверждает тезис подраздела 2.4.1: выбор метрики влияет на итоговое ранжирование. MAE оптимизирует медиану, RMSE – среднее; при наличии выбросов (кризисные эпизоды) эти характеристики могут давать разный порядок.

Интервальные оценки, полученные в разделах 3.2–3.4, сведены в таблице 15.

Таблица 15 – Покрывание интервальных оценок

Модель/Класс	Coverage 95% CI	Средняя ширина CI (п.п.)	Метод построения CI
AutoARIMA	94.5%	–	аналитический
AutoETS	96.7%	–	аналитический
CES	96.7%	–	аналитический
AutoTheta	95.6%	–	аналитический
Prophet-base	79.5%	9.32	Монте-Карло
Prophet-exog	92.0%	3.84	Монте-Карло
LightGBM	67.5%	8.45	квантильная регрессия

Калибровка интервалов убывает с ростом сложности модели. Параметрические модели (coverage 94.5–96.7%) наиболее точно соответствуют номинальному уровню 95%: аналитический расчёт $\hat{\sigma}$ из всех остатков даёт устойчивую оценку даже на коротком ряде. Prophet (79.5–92.0%) занижает неопределённость: Монте-Карло симуляция при ограниченном числе итераций не полностью охватывает хвосты. LightGBM (67.5%) переобучается на хвостах: квантильная модель не видит достаточно экстремальных наблюдений для корректной оценки границ.

3.7.2 Тест Diebold-Mariano

Попарное сравнение 13 моделей (исключены Decomp+Trend, Prophet-base – проигрыш более 1,4 п.п. MAE, и CES – как архитектурный вариант ETS,

дублирующий AutoETS по содержанию) даёт $C_{13}^2 = 78$ пар. Из них 40 показали значимое различие на уровне 5%, 38 – незначимое.

На рисунке 22 показана матрица p-values теста Diebold-Mariano, 13×13, зелёный цвет означает, что различия незначимы, красный – значимы.




Рисунок 22 – Матрица p-values теста Диболда-Мариано

Результаты DM-теста позволяют разбить модели на три группы.

Группа лидеров: Naive. Naive значимо лучше всех 12 остальных моделей ($p < 0.05$ для всех пар). Ближайший конкурент – AutoTheta (DM = −3.475, $p = 0.0005$): разница в MAE всего 0.014 п.п., но статистически значима. Единственная пара, где Naive не достигает уровня 1%, – Naive vs N-HiTS ($p = 0.046$), что объясняется высокой дисперсией ошибок нейросети.

Группа середины: AutoTheta, Drift, AutoETS, AutoARIMA, ARIMA, TimeGPT. Внутри этой группы большинство пар статистически неразличимы. AutoETS vs AutoARIMA: $p = 0.486$. AutoARIMA vs ARIMA: $p = 0.326$. ARIMA vs TimeGPT: $p = 0.317$. AutoETS vs TimeGPT: $p = 0.144$. Модели этой группы

значимо лучше группы аутсайдеров: AutoETS vs Prophet-exog ($p = 0.021$), AutoETS vs XGBoost ($p = 0.009$), AutoARIMA vs LightGBM ($p = 0.005$).

Группа аутсайдеров: Prophet-exog, LightGBM, XGBoost, N-BEATS, N-HiTS, PatchTST. Внутри этой группы ни одна пара не показывает значимого различия. Prophet-exog vs LightGBM: $p = 0.511$. LightGBM vs XGBoost: $p = 0.398$. N-BEATS vs PatchTST: $p = 0.748$. N-HiTS vs PatchTST: $p = 0.668$. Все шесть моделей статистически эквивалентны при $\alpha = 0.05$.

TimeGPT находится на границе средней группы. Модель неразличима с AutoETS ($p = 0.144$), AutoARIMA ($p = 0.222$), ARIMA ($p = 0.317$), но также неразличима с Prophet-exog ($p = 0.151$) и LightGBM ($p = 0.200$). TimeGPT занимает промежуточную позицию между параметрическими моделями и ML/нейросетями.

Группировка имеет содержательное объяснение. Модели-лидеры (Naive) и середина (параметрические) работают с историей самого ряда и не добавляют лишних параметров. Аутсайдеры – модели с экзогенными переменными (Prophet-exog, LightGBM, XGBoost) и нейросети – переобучаются на коротком ряде, что увеличивает MAE, но не даёт преимущества в прогнозировании дискретно изменяющейся ставки при $h = 1$.

3.7.3 Анализ вычислительной сложности

Сравнение моделей по вычислительным затратам дополняет сравнение по точности. В таблице 16 приведены теоретическая сложность, число параметров и время выполнения 91 шага expanding window на CPU (AMD Ryzen, 6 ядер, 12 потоков, 16 ГБ RAM).

Таблица 16 – Вычислительная сложность моделей

Модель	Теоретическая сложность	Число параметров	Время (с) на 91 шаг
Naive	$O(1)$	0	<1
Drift	$O(n)$	2	<1

Продолжение таблицы 16

AutoARIMA	$O(n \cdot p \cdot q)$	~5	55
AutoETS	$O(n \cdot m)$	~10	55
AutoTheta	$O(n)$	~3	55
CES	$O(n)$	~4	55
Prophet	$O(n \cdot k)$	~50	16
LightGBM	$O(n \cdot d \cdot T)$	~3000	5
XGBoost	$O(n \cdot d \cdot T \cdot \log n)$	~3000	5
N-BEATS	$O(n \cdot L \cdot H)$	2.4M	171
N-HiTS	$O(n \cdot L \cdot H / \Pi k)$	~1.2M	171
PatchTST	$O(n \cdot P^2 \cdot d)$	42.6K	171
TimeGPT	$O(\text{API})$	~100M	84

Здесь n – длина ряда, p, q – порядки ARIMA, m – период сезонности, k – число changepoints (Prophet), d – глубина дерева, T – число деревьев, L – число слоёв нейросети, H – размер скрытого слоя, P – число патчей.

Naïve выполняется за $O(1)$ – копирование одного значения. StatsForecast (4 модели совместно) занимает 55 секунд на 91 шаг; основное время уходит на повторную оптимизацию функции правдоподобия. LightGBM при 200 деревьях и 34 признаках работает за 5 секунд – быстрее StatsForecast в 11 раз, несмотря на большее число параметров (3000 против 5–10). Это объясняется эффективностью гистограммной аппроксимации и отсутствием необходимости в повторной оптимизации непрерывных параметров.

Нейросети (171 с) – самый медленный класс на CPU. N-BEATS с 2.4M параметров и PatchTST с 42.6K параметров занимают одинаковое время, поскольку bottleneck – не число параметров, а число шагов градиентного спуска ($\text{max_steps} = 300 \times 91 \text{ окно} = 27\,300$ итераций). TimeGPT (84 с) быстрее нейросетей благодаря серверному GPU, но медленнее LightGBM из-за сетевых задержек.

Соотношение «точность/время» наиболее выгодно у Naïve (MAE 0.569, <1 с) и AutoTheta (MAE 0.582, ~14 с на одну модель). Наименее выгодно – у

N-HITS (MAE 1.215, 171 с): в 2.1 раза хуже Naive по точности и в 171 раз медленнее.

3.7.4 Прогнозирование на горизонтах $h = 3$ и $h = 6$

На горизонте $h = 1$ лаг целевой переменной (lag_1) содержит почти всю необходимую информацию ($r = 0.953$), что делает экзогенные переменные избыточными (подраздел 3.4.3). При увеличении горизонта lag_1 отстаёт от реальности на h месяцев, и ценность экзогенных данных возрастает. Для количественной оценки этого эффекта проведён эксперимент с пятью сценариями прогнозирования на $h = 3$ и $h = 6$ месяцев:

- сценарий A (Naive): $\hat{y}_{T+h} = y_T$;
- сценарий B (LightGBM, лаги): модель использует только лаги целевой переменной и скользящие статистики, сдвинутые на h месяцев;
- сценарий C (LightGBM, oracle): модель использует истинные будущие значения экзогенных переменных – верхняя граница точности, недостижимая на практике;
- сценарий D (LightGBM, 2-stage): экзогенные переменные на горизонте h прогнозируются через AutoETS, затем подставляются в LightGBM;
- сценарий E (LightGBM, ROISfix): вместо прогнозирования экзогенных используются значения ROISfix, доступные на момент прогноза и содержащие рыночные ожидания будущей ставки.

Результаты приведены в таблице 17.

Таблица 17 – Прогнозирование на горизонтах $h=3$ и $h=6$

Сценарий	MAE $h=3$	RMSE $h=3$	MAE $h=6$	RMSE $h=6$
A. Naive	0.816	1.964	0.816	1.964
B. LightGBM лаги	1.973	2.936	2.459	3.551
C. LightGBM oracle	0.999	1.900	0.968	1.857

Продолжение таблицы 17

D. LightGBM 2-stage	2.037	3.428	3.150	4.376
E. LightGBM ROISfix	1.059	2.003	1.150	2.152

На рисунке 23 показаны прогнозы пяти сценариев на горизонте в 3 месяца на фоне реального значения ключевой ставки




Рисунок 23 – Прогноз на горизонте 3 месяцев на фоне факта

На рисунке 24 показаны метрики абсолютной и среднеквадратичной ошибки для прогнозов на горизонте в 3 месяца.




Рисунок 24 – MAE и RMSE для прогнозов для h=3

Цена ошибки прогноза экзогенных. Разница между oracle и 2-stage показывает, сколько теряется из-за неточного прогнозирования регрессоров: 1.04 п.п. на $h = 3$ и 2.18 п.п. на $h = 6$. Ошибка прогноза экзогенных растёт с горизонтом и на $h = 6$ делает 2-stage хуже Naive (3.150 против 0.816). Двухстадийный подход не оправдан при горизонте более 3 месяцев.

ROISfix вдвое лучше 2-stage. На $h = 3$ ROISfix (MAE 1.059) почти вдвое точнее 2-stage (MAE 2.037), поскольку рыночные ожидания (ROISfix 3M) содержат агрегированную информацию десятков участников рынка и не требуют прогнозирования. На $h = 6$ разрыв увеличивается: 1.150 против 3.150. ROISfix является более надёжным источником информации о будущей ставке, чем эконометрический прогноз макропеременных.

Oracle RMSE лучше Naive. При идеальном знании экзогенных переменных LightGBM обходит Naive по RMSE: на $h = 3$ RMSE oracle = 1.900 против Naive RMSE = 1.964 (улучшение на 3.3%), на $h = 6$ улучшение составляет 5.4%. Oracle уступает Naive по MAE (0.999 против 0.816 на $h = 3$), но превосходит по RMSE, то есть допускает меньше крупных промахов. Экзогенные переменные наиболее полезны для снижения экстремальных ошибок, а не средних.

Naive остаётся сильным бенчмарком. Даже при $h = 6$ Naive (MAE 0.816) превосходит все сценарии, кроме oracle. Дискретная природа ставки (ставка не меняется в большинстве месяцев) обеспечивает Naive низкую MAE на любом горизонте, пока вероятность изменения ставки за h месяцев остаётся ниже 50%.

3.8 Интерпретация результатов в контексте предметной области

Результаты вычислительного эксперимента допускают интерпретацию на трёх уровнях: природа целевого процесса, роль экзогенной информации и влияние выбора метрики на выводы.

Почему Naive побеждает. Ключевая ставка ЦБ РФ изменяется решениями Совета директоров на 8 плановых заседаниях в год. В

рассматриваемом периоде (сентябрь 2013 – март 2026, 151 месяц) ставка изменялась примерно 60 раз, то есть оставалась неизменной в 60% месяцев. Прогноз $\hat{y}_{T+1} = y_T$ (формула 3.1) в каждом таком месяце даёт нулевую ошибку. Любая модель с оцениваемыми параметрами (ARIMA, ETS, LightGBM, N-BEATS) генерирует ненулевое отклонение от y_T даже в стабильные периоды. Эти отклонения накапливаются в MAE и делают параметрическую модель хуже Naive.

Этот эффект усиливается тем, что решения об изменении ставки остаются непредсказуемыми и по рыночным индикаторам: 45% таких решений рынок не угадывает [2]. В момент разворота ДКП любая модель – статистическая, ансамблевая или нейросетевая – работает без полного информационного преимущества: значительная часть сигнала не отражена ни в макроданных, ни в ставках. В стабильные периоды альтернативные модели проигрывают Naive, генерируя лишний шум; в периоды изменений высокая остаточная непредсказуемость сокращает их преимущество до нуля.

Формально: пусть $P(y_{T+1} = y_T) = p$ – вероятность того, что ставка не изменится. Тогда $MAE(Naive) = (1 - p) \cdot E[|\Delta y| \mid \Delta y \neq 0]$, а MAE параметрической модели складывается из двух компонент: ошибки в стабильные периоды ($p \cdot \varepsilon_{\text{стаб}}$) и ошибки в периоды изменений ($(1 - p) \cdot \varepsilon_{\text{изм}}$). При $p \approx 0.6$ и $\varepsilon_{\text{стаб}} > 0$ (что неизбежно для модели с оцениваемыми параметрами) Naive выигрывает, если $\varepsilon_{\text{стаб}} \cdot p > (MAE_{Naive} - (1 - p) \cdot \varepsilon_{\text{изм}})$. Этот эффект усиливается на коротких горизонтах ($h = 1$), где p максимально.

Результат устойчив: проверка на базовой ставке НБРК (глава 4) подтвердила первенство Naive ($MAE = 0.209$). Для дискретно управляемых ставок центральных банков emerging markets случайное блуждание – сильный бенчмарк при $h = 1$.

Почему экзогенные переменные помогают, но не побеждают. Добавление экзогенных регрессоров улучшает Prophet на 67% (MAE с 2.727 до 0.905), но не позволяет превзойти Naive (0.569).

Экзогенные переменные, в первую очередь КБД ОФЗ (7 из 10 TOP-признаков по среднему рангу, подраздел 3.4.2), содержат информацию об ожиданиях участников рынка. Однако при $h = 1$ эта информация дублируется лагом целевой переменной: $r(\text{key_rate}, \text{zcyc_1y}) = 0.959$, $r(\text{lag_1}, \text{zcyc_1y_lag1}) > 0.95$. Ablation study (подраздел 3.4.3) подтвердил, что удаление 10 КБД-признаков не ухудшает MAE LightGBM. Мультиколлинеарность обесценивает экзогенные данные при коротком горизонте.

При $h = 3$ и $h = 6$ ситуация меняется. Лаг целевой переменной отстаёт от реальности на 3–6 месяцев, и ценность рыночных индикаторов растёт. ROISfix 3М (рыночные ожидания на 3 месяца вперёд) позволяет LightGBM достичь MAE = 1.059 на $h = 3$, тогда как модель с лагами даёт MAE = 1.973. Oracle-сценарий (MAE = 0.999, RMSE = 1.900) показывает, что при идеальном знании экзогенных LightGBM обходит Naïve по RMSE на 3.3%, хотя уступает по MAE. Экзогенные переменные ценны не столько для снижения средней ошибки, сколько для уменьшения экстремальных промахов.

Почему Prophet-base проигрывает. Prophet без регрессоров (MAE = 2.727) – худшая модель эксперимента. Причина – несоответствие между механизмом тренда Prophet и динамикой ключевой ставки. Кусочно-линейный тренд $g(t)$ (формула 3.10) определяет changepoints по историческим данным и экстраполирует текущий сегмент. При развороте ставки (например, переход от снижения к повышению в 2021–2022 гг.) модель продолжает экстраполировать старый тренд, пока не накопится достаточно наблюдений для нового changepoint. Лапласова регуляризация $\delta_j \sim \text{Laplace}(0, \tau)$ дополнительно сдерживает изменения наклона, усиливая запаздывание.

Prophet-exog (MAE = 0.905) компенсирует этот эффект через коэффициенты β_j при экзогенных регрессорах. Когда *zcyc_1y_lag1* или *ruonia_lag1* сигнализируют об изменении рыночных условий, модель корректирует прогноз до того, как тренд $g(t)$ успеет отреагировать. Однако связь y от x_j в Prophet линейна, что ограничивает точность. LightGBM моделирует пороговые эффекты (например, «если инфляция > 8% и

доходность $1Y > 12\%$, ставка вырастет»), но при $h = 1$ это не даёт преимущества из-за мультиколлинеарности с lag_1 .

MAE vs RMSE: выбор метрики определяет вывод. Ранжирование 16 моделей по MAE и RMSE совпадает для первых двух позиций (Naive, AutoTheta), но расходится далее. ARIMA занимает 7-е место по MAE (0.735) и 3-е по RMSE (1.600). PatchTST (13-е по MAE) опережает N-BEATS (12-е по MAE) по RMSE.

Расхождение объясняется математическими свойствами метрик [12]. $\text{MAE} = E[|e|]$ оптимизирует условную медиану; $\text{RMSE} = \sqrt{E[e^2]}$ оптимизирует условное среднее (подраздел 2.4.1). Если распределение ошибок содержит тяжёлые хвосты (кризисные эпизоды), модель с малым числом крупных ошибок и большим числом мелких покажет лучший RMSE, но худший MAE, чем модель с равномерно распределёнными ошибками среднего размера.

Для практических приложений выбор метрики зависит от задачи. Если цена ошибки пропорциональна её величине (линейная функция потерь), релевантна MAE. Если крупные ошибки непропорционально дороги (квадратичные потери, например при оценке портфеля облигаций), предпочтительнее RMSE. В настоящей работе MAE выбрана основной метрикой, поскольку ключевая ставка изменяется фиксированными шагами (25, 50, 100, 150 б.п.), и ошибка прогноза имеет симметричные последствия: завышение и занижение одинаково вредны для принятия решений.

Выводы получены на данных ЦБ РФ. Глава 4 проверяет, сохраняются ли они на данных другого центрального банка с сопоставимым режимом денежно-кредитной политики – НБРК.

3.9 Обратная задача: прогнозирование реакции рынка на ставку ЦБ РФ

Прямая задача (подразделы 3.1–3.8) решалась с позиции участника рынка: прогнозирование ключевой ставки по рыночным индикаторам.

Обратная задача ставится с позиции регулятора: оценка реакции рыночных ставок на изменение ключевой ставки. Количественной мерой этой реакции служит РТ:

$$RT = \frac{\Delta(RUONIA)}{\Delta(key_rate)}, \quad (3.16)$$

показывающий, на сколько процентных пунктов изменяется рыночная ставка при изменении ключевой на 1 п.п. При $RT = 1$ передача полная, при $RT < 1$ – частичная (часть решения «поглощается» рынком), при $RT > 1$ – сверхреакция. РТ – стандартная мера эффективности трансмиссионного механизма денежно-кредитной политики.

В качестве целевых переменных обратной задачи выбраны RUONIA (ставка овернайт, первая ступень трансмиссии) и ROISfix 3М (ставка свопа на 3 месяца, отражающая среднесрочные ожидания). Набор предикторов: лаги целевой переменной, ключевая ставка (управляющая переменная) и макроконтекст (CPI, M2, USD/RUB, Brent).

Прогнозная часть. Для каждой целевой обучены пять моделей (Naive, AutoARIMA, AutoETS, AutoTheta, LightGBM) по схеме expanding window. Результаты при $h = 1$ приведены в таблице 18.

Таблица 18 – Метрики обратной задачи ($h = 1$)

Модель	MAE RUONIA	Coverage RUONIA	MAE ROISfix 3М	Coverage ROISfix 3М
AutoTheta	0.711	95.6%	0.730	96.7%
Naive	0.733	–	0.770	–
AutoARIMA	0.737	96.7%	0.870	96.7%
AutoETS	0.742	94.5%	0.741	95.6%
LightGBM	0.936	69.0%	1.092	65.5%

AutoTheta побеждает на обеих целевых (MAE = 0.711 для RUONIA, 0.730 для ROISfix 3М). Ранжирование воспроизводит картину прямой задачи: параметрические модели превосходят ML, а калибровка их интервалов (94.5–96.7%) значительно лучше, чем у LightGBM (65–69%). Naive занимает второе

место, подтверждая, что рыночные ставки, как и ключевая, изменяются дискретно.

Сценарный анализ. Для оценки РТ зафиксированы все переменные, кроме ключевой ставки, на значениях последнего наблюдения (15.0%). Модель LightGBM, обученная на полной выборке, прогнозирует RUONIA и ROISfix 3М для сценариев $\text{key_rate} \in \{10\%, 12\%, 14\%, 15\%, 16\%, 18\%, 20\%, 21\}$. Кривые реакции RUONIA и ROISfix 3М на изменение ключевой ставки при $h = 1$ (с 95%-ными доверительными интервалами) показаны на рисунке 25




Рисунок 25 – Сценарный анализ на горизонте $h = 1$

Результаты сценарного анализа на трёх горизонтах приведены в таблице 19.

Таблица 19 – РТ по временным горизонтам

Горизонт	РТ RUONIA	РТ ROISfix 3М
h=1	0.50	0.52
h=3	0.38	0.10
h=6	0.09	≈ 0.00

При $h = 1$ средний PT RUONIA составляет 0.50: повышение ключевой ставки на 1 п.п. приводит к росту RUONIA на 0.50 п.п. Частичная передача ($PT < 1$) объясняется тем, что RUONIA формируется не только ключевой ставкой, но и ликвидностью банковского сектора, структурой спроса на межбанковском рынке и ожиданиями участников. ROISfix 3М при $h = 1$ показывает аналогичный $PT = 0.52$.

С ростом горизонта передача затухает. При $h = 3$ PT RUONIA снижается до 0.38, PT ROISfix 3М – до 0.10. При $h = 6$ PT RUONIA падает до 0.09, а ROISfix 3М – практически до нуля. Затухание означает, что эффект однократного изменения ключевой ставки на рыночные индикаторы краткосрочен. Для устойчивого влияния на рыночные ставки необходимо удержание нового уровня ключевой ставки на протяжении нескольких месяцев. Аналогичная закономерность зафиксирована в мета-анализе PT для emerging markets [56].

Асимметрия PT . Сценарный анализ при $h = 1$ выявил асимметрию реакции рынка на повышение и снижение ставки. При повышении ключевой ставки с 15% до 16% PT RUONIA составляет 0.78, при снижении с 15% до 10% – 0.29. Рынок быстрее реагирует на ужесточение денежно-кредитной политики, чем на смягчение. Для ROISfix 3М асимметрия ещё выраженнее: при повышении 15% $\rightarrow$ 16% $PT = 1.17$ (сверхреакция), при снижении 15% $\rightarrow$ 10% – 0.20.

Сверхреакция ROISfix ($PT > 1$) при повышении ставки означает, что рынок свопов закладывает дальнейшее ужесточение: участники ожидают, что за первым повышением последуют дополнительные. Этот вывод согласуется с результатами Абдурахманова [4]: монетарные неожиданности при повышении ставки влияют на всю кривую доходности, то есть неожиданное ужесточение запускает пересмотр ожиданий на всех горизонтах и порождает самоподкрепляющуюся реакцию рынка.

Ширина 95%-ных доверительных интервалов для сценарного анализа составляет 7–11 п.п., что отражает высокую неопределённость при

экстраполяции за пределы наблюдавшихся значений ключевой ставки. Интервалы расширяются для экстремальных сценариев ($\text{key_rate} = 21\%$: ширина 11.5 п.п.) и сужаются вблизи текущего уровня ($\text{key_rate} = 15\%$: ширина 8.9 п.п.).

На рисунках 26 и 27 показаны прогнозные траектории и РТ при различных сценариях изменения ключевой ставки на горизонте $h = 1$.




Рисунок 26 – Сценарный прогноз и оценка РТ для RUONIA




Рисунок 27 – Сценарный прогноз и оценка РТ для ROISfix_3m

Обратная задача дополняет прямую. Прямая задача отвечает на вопрос «какой будет ставка?», обратная – «как рынок отреагирует на решение ЦБ

РФ?». Количественные оценки РТ (0.50 при $h = 1$, затухание до 0.09 при $h = 6$) и выявленная асимметрия (ужесточение передаётся быстрее смягчения) могут использоваться при моделировании влияния решений ЦБ РФ на стоимость фондирования банковского сектора.

4 ПРОВЕРКА РОБАСТНОСТИ: ТЕСТИРОВАНИЕ НА ДАННЫХ КАЗАХСТАНА

4.1 Описание данных: базовая ставка НБРК

Проверка робастности отвечает на вопрос: насколько устойчивы выводы главы 3 к смене генеральной совокупности (distribution shift)? Если Naïve побеждает только на ключевой ставке ЦБ РФ, результат может быть артефактом конкретного ряда. Если закономерность воспроизводится на ставке другого центрального банка с аналогичным механизмом принятия решений, вывод приобретает большую общность.

В качестве объекта проверки выбрана базовая ставка Национального Банка Республики Казахстан (НБРК) [57]. НБРК, как и ЦБ РФ, относится к центральным банкам *emerging markets* с аналогичным механизмом: ставка устанавливается на плановых заседаниях и изменяется дискретно. При этом макроэкономический контекст отличается: Казахстан – экспортёр нефти с меньшим масштабом экономики, иной валютной политикой и другой траекторией инфляции.

Базовая ставка НБРК введена 2 сентября 2015 года как основной инструмент денежно-кредитной политики [57]. До этого НБРК использовал ставку рефинансирования, которая выполняла преимущественно индикативную функцию. Переход к базовой ставке сопровождался внедрением инфляционного таргетирования и коридора процентных ставок.

Данные охватывают период с сентября 2015 по март 2026 года (127 месяцев). Ставка принимала значения от 9.0% до 18.0% (медиана 12.0%, среднее 12.4%, стандартное отклонение 2.3 п.п.). Для сравнения: ключевая ставка ЦБ РФ за тот же период варьировалась от 4.25% до 21.0% (медиана 7.5%, стандартное отклонение 4.7 п.п.). Волатильность ставки НБРК вдвое ниже, что связано с отсутствием экстремальных эпизодов масштаба декабря 2014 или февраля 2022 года.

Как и ключевая ставка ЦБ РФ, базовая ставка НБРК изменяется дискретно на заседаниях (8 плановых заседаний в год) и остаётся постоянной между ними. Шаг изменения, как правило, составляет 25 или 50 базисных пунктов. Доля месяцев без изменения ставки выше, чем для ЦБ РФ, что усиливает позицию Naïve как бенчмарка.

Признаковое пространство главы 2 — кривая бескупонной доходности ОФЗ, RUONIA, ROISfix и 33 макроиндикатора — построено на российской методологии: КБД рассчитывается Московской биржей по утверждённой методике [43], RUONIA публикуется Банком России [44], ROISfix — СРО НФА [45], макроиндексы — Росстатом по собственной системе классификаторов. Прямой перенос этих признаков на Казахстан невозможен, а построение методологических аналогов сопряжено с риском несопоставимости. Рынок государственных облигаций МЕККАМ/МЕОКАМ заметно меньше российского рынка ОФЗ по объёму, и реконструированная по нему кривая доходности будет отличаться от ОФЗ по плотности торгов, шаговой структуре и шумовой компоненте. Индикативная ставка TONIA казахстанского денежного рынка методологически близка к RUONIA, но рынок процентных свопов в KZT существенно менее развит, чем рынок RUB-свопов; регулярного индикатора того же типа, что ROISfix, в публичном доступе нет. Макроиндикаторы Казахстана публикуются Бюро национальной статистики РК и НБРК по собственным методологиям; они расходятся с методологиями Росстата и Банка России по составу корзин и базе индексации. Есть и временное ограничение: инфляционное таргетирование введено в Казахстане в 2015 году одновременно с базовой ставкой, в августе того же года тенге перешёл в режим свободного плавания, так что однородный макроэкономический режим продолжается лишь с конца 2015 года.

Поэтому Казахстан тестируется в univariate-режиме — только история базовой ставки, без экзогенных регрессоров, при тех же гиперпараметрах, что и в главе 3 (`season_length = 1`, `expanding window`, `t0 = 60`, `h = 1`). Такая постановка изолирует один фактор, смену генеральной совокупности, и

обеспечивает чистоту теста робастности: проверяется устойчивость ранжирования моделей, а не их абсолютная точность на новых данных. Если бы в тест были включены казахстанские макропеременные, методологически отличные от использованных в главе 3, признаковое пространство изменилось бы, и причину расхождения метрик было бы невозможно отделить от смены страны.

4.2 Прогон моделей без переобучения

Пять моделей (Naive, AutoARIMA, AutoETS, CES, AutoTheta) запущены на базовой ставке НБРК. Число шагов валидации — 67 (127 – 60). Гиперпараметры не подбирались заново; модели StatsForecast автоматически выбирают спецификацию (порядки ARIMA, тип ETS) по AIC на каждом шаге. На рисунке 28 показаны процентные ставки РФ и Казахстана.



Рисунок 28 – Динамика базовой ставки НБРК и ключевой ставки ЦБ РФ

Результаты прогнозирования приведены в таблице 20.

Таблица 20 – Сравнение метрик моделей на данных Казахстана и РФ

Ранг	Модель	MAE (п.п.)	K3	RMSE (п.п.)	K3	MAE РФ (п.п.)	Разница (%)
1	Naive	0.209		0.548		0.569	-63.2%
2	AutoETS	0.263		0.545		0.661	-60.3%
3	AutoTheta	0.266		0.578		0.582	-54.3%

Продолжение таблицы 20

4	CES	0.286	0.567	0.728	-60.7%
5	AutoARIMA	0.292	0.552	0.717	-59.3%

Naïve побеждает и на данных Казахстана (MAE = 0.209 п.п.), опережая все параметрические модели. Абсолютные MAE в Казахстане в 2.2–2.7 раза ниже, чем в России (средняя разница –59.6%). Причина – меньшая волатильность ставки НБРК: стандартное отклонение 2.3 п.п. против 4.7 п.п. у ЦБ РФ, отсутствие экстремальных скачков. Naïve ratio (MAE КЗ / MAE РФ) = 0.37, что близко к отношению стандартных отклонений ($2.3 / 4.7 = 0.49$). Остаточное расхождение объясняется тем, что ставка НБРК изменяется реже и меньшими шагами (25–50 б.п. против 25–650 б.п. у ЦБ РФ). На рисунке 29 показаны абсолютные ошибки для ключевой ставки ЦБ РФ и ставки НБРК для тех же моделей и параметров.




Рисунок 29 – Диаграмма MAE для ключевой ставки и ставки НБРК

4.3 Анализ устойчивости

Ранжирование моделей частично сохранилось при переходе от РФ к Казахстану. Naïve занимает первое место в обоих случаях. AutoETS и AutoTheta делят 2–3 позиции: в России AutoTheta (0.582) опережает AutoETS (0.661), в Казахстане наоборот – AutoETS (0.263) опережает AutoTheta (0.266). Разница между ними в Казахстане составляет 0.003 п.п. и статистически незначима. CES и AutoARIMA занимают 4–5 позиции в обоих случаях, хотя их порядок меняется.

Ранжирование по RMSE расходится с ранжированием по MAE для Казахстана. По RMSE AutoETS (0.545) опережает Naïve (0.548), тогда как по MAE Naïve лидирует (0.209 против 0.263). Это повторяет закономерность, выявленную в подразделе 3.8: MAE и RMSE оптимизируют разные характеристики распределения ошибок и могут давать разный порядок моделей.

Naïve — устойчивый бенчмарк для дискретно изменяющихся ставок центральных банков emerging markets при $h = 1$ в univariate-постановке. Распространять этот вывод на multivariate-сценарии для других стран преждевременно: для такого обобщения нужно построить сопоставимое признаковое пространство, что выходит за рамки настоящей работы. В пределах же univariate-постановки первенство Naïve сохраняется при смене страны и длины ряда — то есть проверяется именно на тех осях, по которым данные настоящего исследования различаются.

Абсолютные значения MAE при этом несопоставимы между странами: они зависят от волатильности конкретного ряда и от частоты дискретных шагов. Поэтому опираться следует на ранг и относительные показатели (отношение MAE модели к MAE Naïve можно получить из таблицы 20), а не на абсолютные значения ошибки.

ЗАКЛЮЧЕНИЕ

В настоящей работе проведено систематическое сравнение 16 моделей прогнозирования ключевой ставки ЦБ РФ четырёх классов: параметрические (ARIMA, ETS, CES, Theta), ансамблевые (LightGBM, XGBoost, Prophet), нейросетевые (N-BEATS, N-HiTS, PatchTST) и предобученные (TimeGPT). Все модели оценены на единой схеме валидации (expanding window, $t_0 = 60$, $h = 1$, до 91 шага) с формальным статистическим тестированием (тест Diebold-Mariano, 78 пар). Датасет: 151 месяц (сентябрь 2013 – март 2026), 32 переменных, включая 12 точек кривой бескупонной доходности ОФЗ, RUONIA, ROISfix и макроэкономические индикаторы.

1. Naive (случайное блуждание) – лучшая модель при $h = 1$. Наивный прогноз $\hat{y}_{T+1} = y_T$ показал MAE = 0.569 п.п. и значимо превзошёл все 15 альтернатив по тесту Diebold-Mariano ($p < 0.05$ для всех пар, включая ближайшего конкурента AutoTheta: $p = 0.0005$). Результат обусловлен дискретной природой ключевой ставки: решения принимаются 8 раз в год, и в 60% месяцев ставка не меняется. Любая модель с оцениваемыми параметрами генерирует ненулевые отклонения от y_T в стабильные периоды, что увеличивает MAE. DM-тест разделил 13 моделей на три группы: лидер (Naive), середина (AutoTheta, Drift, AutoETS, AutoARIMA, ARIMA, TimeGPT, статистически неразличимы, MAE 0.58–0.82) и аутсайдеры (Prophet-exog, LightGBM, XGBoost, N-BEATS, PatchTST, N-HiTS, статистически неразличимы, MAE 1.08–1.22). Проверка робастности для группы лидеров (Naive + 4 параметрических модели) в univariate-постановке на базовой ставке НБРК (Казахстан, 127 месяцев) подтвердила первенство Naive (MAE = 0.209 п.п.) и частичное сохранение ранжирования моделей.

2. КБД ОФЗ попадает в TOP-10 по всем пяти методам оценки важности (7 из 10 случаев), однако при $h = 1$ его сигнал статистически дублируется лагом целевой переменной ($r = 0,959$). Ablation study это подтверждает: MAE без КБД

– 1,073, с КБД – 1,109. На горизонте одного шага признак избыточен; при $h = 3$ и $h = 6$ его вклад растёт (раздел 3.7.4).

3. ROISfix вдвое лучше двухстадийного подхода на $h = 3$ и $h = 6$. При увеличении горизонта прогнозирования лаговая информация теряет актуальность, и ценность экзогенных данных возрастает. На $h = 3$ пять сценариев LightGBM дали: Naive MAE = 0.816, oracle MAE = 0.999, ROISfix MAE = 1.059, 2-stage MAE = 2.037. Цена ошибки прогноза экзогенных переменных (разница между oracle и 2-stage) составила 1.04 п.п. на $h = 3$ и 2.18 п.п. на $h = 6$. ROISfix (рыночные ожидания) почти вдвое точнее двухстадийного прогноза, поскольку содержит агрегированную информацию десятков участников рынка и не требует прогнозирования. Oracle по RMSE превзошёл Naive на 3.3% ($h = 3$) и 5.4% ($h = 6$): экзогенные переменные наиболее полезны для снижения экстремальных ошибок.

4. TimeGPT zero-shot лучше всех ML и нейросетей (в режиме univariate без экзогенных регрессоров). TimeGPT (MAE = 0.823, 8-е место) без доступа к экзогенным переменным и без обучения на данных ключевой ставки превзошёл LightGBM (1.081), XGBoost (1.121), N-BEATS (1.127), PatchTST (1.153) и N-HiTS (1.215). Предобучение на 100+ млрд точек из других доменов оказалось эффективнее обучения на 60–150 наблюдениях конкретного ряда: foundation model застрахован от переобучения по определению. При этом TimeGPT уступил параметрическим моделям (AutoTheta 0.582, AutoETS 0.661), которые адаптируются к конкретному ряду без избыточной параметризации.

5. Рынок реагирует на решения ЦБ РФ асимметрично и с затуханием. Коэффициент трансмиссии ключевой ставки в RUONIA составляет 0,50 при $h = 1$ и снижается до 0,09 при $h = 6$; для ROISfix 3М картина аналогична. Сценарный анализ LightGBM показал, что при повышении ставки на 1 п.п. (сценарий 15% → 16%) PT RUONIA равен 0,78, при снижении на 5 п.п. (сценарий 15% → 10%) – лишь 0,29. Для ROISfix 3М при повышении зафиксирована сверхреакция (PT = 1,17): рынок свопов закладывает ожидания

дальнейшего ужесточения. Однократное повышение ставки передаётся рынку быстрее и сильнее, чем симметричное смягчение, – это согласуется с результатами Абдурахманова [4] о неравномерной реакции кривой доходности на монетарные неожиданности.

Дополнительные результаты. Интервальные оценки: параметрические модели показали покрытие 94.5–96.7% (близко к номинальным 95%), Prophet – 79.5–92.0%, LightGBM (квантильная регрессия) – 67.5%. Калибровка интервалов ухудшается с ростом сложности модели. Обратная задача: РТ ключевой ставки в RUONIA составляет 0.50 при $h = 1$, затухает до 0.09 при $h = 6$. Выявлена асимметрия: рынок быстрее реагирует на ужесточение (РТ = 0.78) при повышении ставки, чем на смягчение (РТ = 0.29) при снижении. ROISfix при повышении 15% → 16% показал сверхреакцию (РТ = 1.17): рынок свопов закладывает дальнейшее ужесточение.

Направления дальнейших исследований:

- Ablation study и эксперимент с ROISfix показали, что ценность экзогенных переменных растёт с горизонтом. На $h = 12$ месяцев КБД и ROISfix могут стать незаменимыми предикторами, а Naïve – потерять преимущество.

- Квантильная регрессия LightGBM показала coverage 67.5% при номинальных 95%. Конформное предсказание (conformal prediction) гарантирует номинальное покрытие при минимальных предположениях о распределении данных и может улучшить калибровку ML-моделей.

- Пресс-релизы ЦБ РФ по итогам заседаний содержат информацию о намерениях регулятора, не отражённую в числовых индикаторах. NLP-обработка этих текстов способна снизить долю неожиданных решений, прежде всего на подвыборке заседаний с изменением ставки – именно там информация пресс-релизов наиболее ценна, тогда как в стабильные периоды ставка воспроизводится наивным прогнозом без обращения к тексту.

- В настоящей работе использована месячная частота, однако решения принимаются на конкретных заседаниях (8 в год). Переход к событийной

шкале с использованием ставок IRS на даты заседаний может повысить точность.

– Проверка на Казахстане подтвердила устойчивость основных выводов. Тестирование на ставках Турции, Бразилии и других стран с дискретным механизмом принятия решений позволит оценить общность результата о превосходстве Naïve.

– TimeGPT протестирован в режиме zero-shot. Дообучение (fine-tuning) на данных ключевой ставки с включением экзогенных регрессоров может сочетать преимущества предобучения (устойчивость к переобучению) и адаптации (учёт специфики ряда). Сравнение TimeGPT в режимах zero-shot+exog, fine-tuned univariate и fine-tuned+exog позволит разделить вклад трёх факторов в точность прогноза: предобучения, адаптации к ряду и экзогенной информации.

– Тестирование альтернативных foundation models Chronos-Bolt (Amazon, 2024) и TimesFM (Google, 2024) в данной работе не тестировались из-за конфликтов зависимостей среды выполнения [36, 37]. Оба – предобученные трансформеры, обученные на корпусах, сопоставимых с TimeGPT (свыше 100 млрд точек), и в режиме zero-shot они могут превзойти последний. Сравнение всех трёх моделей на задаче прогнозирования ключевой ставки остаётся открытым вопросом для отдельного исследования.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Taylor J. B. Discretion versus policy rules in practice / J. B. Taylor // Carnegie-Rochester Conference Series on Public Policy. – 1993. – Vol. 39. – P. 195–214. – DOI: [https://doi.org/10.1016/0167-2231\(93\)90009-L](https://doi.org/10.1016/0167-2231(93)90009-L)
2. Абдурахманов М. И. Оценка предсказуемости решений Банка России по ключевой ставке и информационного преимущества в её прогнозировании / М. И. Абдурахманов // Вопросы экономики. – 2024. – № 4. – С. 70–91. – DOI: <https://doi.org/10.32609/0042-8736-2024-4-70-91>
3. Liang Y. Foundation models for time series analysis: A tutorial and survey / Y. Liang, H. Wen, Y. Nie [и др.] // Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. – New York : ACM, 2024. – P. 6915–6925. – DOI: <https://doi.org/10.1145/3637528.3671451>
4. Абдурахманов М. И. Моделирование влияния прогнозов ключевой ставки Банка России на ожидания участников рынка / М. И. Абдурахманов // Деньги и кредит. – 2023. – № 2. – С. 3–20.
5. Пильник Н. П. Прогнозирование процентных ставок и показателей срочности в российской банковской системе / Н. П. Пильник, С. А. Радионов // Проблемы прогнозирования. – 2022. – №3 (192). – С. 149–159.
6. Goulet Coulombe P. How is machine learning useful for macroeconomic forecasting? / P. Goulet Coulombe, M. Leroux, D. Stevanovic, S. Surprenant // Journal of Applied Econometrics. – 2022. – Vol. 37, N 5. – P. 920–964. – DOI: <https://doi.org/10.1002/jae.2910>
7. Makridakis S. The M4 competition: 100,000 time series and 61 forecasting methods / S. Makridakis, E. Spiliotis, V. Assimakopoulos // International Journal of Forecasting. – 2020. – Vol. 36, N 1. – P. 54–74. – DOI: <https://doi.org/10.1016/j.ijforecast.2019.04.014>
8. Makridakis S. The M5 accuracy competition: Results, findings, and conclusions / S. Makridakis, E. Spiliotis, V. Assimakopoulos // International Journal of Forecasting. – 2022. – Vol. 38, N 4. – P. 1346–1364. – DOI: <https://doi.org/10.1016/j.ijforecast.2021.11.013>
9. Hamilton J. D. Time series analysis / J. D. Hamilton. – Princeton : Princeton University Press, 1994. – 799 p.

10. Hyndman R. J. Forecasting: principles and practice / R. J. Hyndman, G. Athanasopoulos. – 3rd ed. – Melbourne : OTexts [Электронный ресурс]. – 2021. – URL: <https://otexts.com/fpp3/> (дата обращения: 23.03.2026).
11. Kolassa S. Why the "best" point forecast depends on the error or accuracy measure / S. Kolassa // International Journal of Forecasting. – 2020. – Vol. 36, N 1. – P. 208–211. – DOI: <https://doi.org/10.1016/j.ijforecast.2019.02.017>
12. Hyndman R. J. Another look at measures of forecast accuracy / R. J. Hyndman, A. B. Koehler // International Journal of Forecasting. – 2006. – Vol. 22, N 4. – P. 679–688. – DOI: <https://doi.org/10.1016/j.ijforecast.2006.03.001>
13. Box G. E. P. Time series analysis: forecasting and control / G. E. P. Box, G. M. Jenkins. – San Francisco : Holden-Day, 1970. – 553 p.
14. Dickey D. A. Distribution of the estimators for autoregressive time series with a unit root / D. A. Dickey, W. A. Fuller // Journal of the American Statistical Association. – 1979. – Vol. 74, N 366. – P. 427–431. – DOI: <https://doi.org/10.2307/2286348>
15. Akaike H. A new look at the statistical model identification / H. Akaike // IEEE Transactions on Automatic Control. – 1974. – Vol. 19, N 6. – P. 716–723. – DOI: <https://doi.org/10.1109/TAC.1974.1100705>
16. Kwiatkowski D. Testing the null hypothesis of stationarity against the alternative of a unit root / D. Kwiatkowski, P. C. B. Phillips, P. Schmidt, Y. Shin // Journal of Econometrics. – 1992. – Vol. 54, N 1–3. – P. 159–178. – DOI: [https://doi.org/10.1016/0304-4076\(92\)90104-Y](https://doi.org/10.1016/0304-4076(92)90104-Y)
17. Hyndman R. J. Forecasting with exponential smoothing: the state space approach / R. J. Hyndman, A. B. Koehler, J. K. Ord, R. D. Snyder. – Berlin : Springer, 2008. – 362 p.
18. Svetunkov I. Complex exponential smoothing / I. Svetunkov, N. Kourentzes, J. K. Ord // Naval Research Logistics. – 2022. – Vol. 69, N 8. – P. 1108–1123. – DOI: <https://doi.org/10.1002/nav.22074>
19. Assimakopoulos V. The theta model: A decomposition approach to forecasting / V. Assimakopoulos, K. Nikolopoulos // International Journal of Forecasting. – 2000. – Vol. 16, N 4. – P. 521–530. – DOI: [https://doi.org/10.1016/S0169-2070\(00\)00066-2](https://doi.org/10.1016/S0169-2070(00)00066-2)
20. Makridakis S. The M3-competition: Results, conclusions and implications / S. Makridakis, M. Hibon // International Journal of Forecasting. – 2000. – Vol. 16, N 4. – P. 451–476. – DOI: [https://doi.org/10.1016/S0169-2070\(00\)00057-1](https://doi.org/10.1016/S0169-2070(00)00057-1)
21. Koenker R. Regression quantiles / R. Koenker, G. Bassett // Econometrica. – 1978. – Vol. 46, N 1. – P. 33–50. – DOI: <https://doi.org/10.2307/1913643>

22. Masini R. P. Machine learning advances for time series forecasting / R. P. Masini, M. C. Medeiros, E. F. Mendes // *Journal of Economic Surveys*. – 2023. – Vol. 37, N 1. – P. 76–111. – DOI: <https://doi.org/10.1111/joes.12429>
23. Friedman J. H. Greedy function approximation: A gradient boosting machine / J. H. Friedman // *Annals of Statistics*. – 2001. – Vol. 29, N 5. – P. 1189–1232. – DOI: <https://doi.org/10.1214/aos/1013203451>
24. Chen T. XGBoost: A scalable tree boosting system / T. Chen, C. Guestrin // *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. – New York : ACM, 2016. – P. 785–794. – DOI: <https://doi.org/10.1145/2939672.2939785>
25. Ke G. LightGBM: A highly efficient gradient boosting decision tree / G. Ke, Q. Meng, T. Finley [и др.] // *Advances in Neural Information Processing Systems*. – 2017. – Vol. 30. – P. 3146–3154.
26. Breiman L. Random forests / L. Breiman // *Machine Learning*. – 2001. – Vol. 45, N 1. – P. 5–32. – DOI: <https://doi.org/10.1023/A:1010933404324>
27. Lundberg S. M. A unified approach to interpreting model predictions / S. M. Lundberg, S.-I. Lee // *Advances in Neural Information Processing Systems*. – 2017. – Vol. 30. – P. 4765–4774.
28. Shapley L. S. A value for n-person games / L. S. Shapley // *Contributions to the theory of games* / ed. by H. W. Kuhn, A. W. Tucker. – Princeton: Princeton University Press, 1953. – Vol. 2. – P. 307–317.
29. Taylor S. J. Forecasting at scale / S. J. Taylor, B. Letham // *The American Statistician*. – 2018. – Vol. 72, N 1. – P. 37–45. – DOI: <https://doi.org/10.1080/00031305.2017.1380080>
30. Oreshkin B. N. N-BEATS: Neural basis expansion analysis for interpretable time series forecasting / B. N. Oreshkin, D. Carпов, N. Chapados, Y. Bengio // *International Conference on Learning Representations (ICLR 2020)* [Электронный ресурс]. – 2020. – URL: <https://openreview.net/forum?id=r1ecqn4YwB> (дата обращения: 23.03.2026).
31. Challu C. N-HiTS: Neural hierarchical interpolation for time series forecasting / C. Challu, K. G. Olivares, B. N. Oreshkin [и др.] // *Proceedings of the AAAI Conference on Artificial Intelligence*. – 2023. – Vol. 37, N 6. – P. 6989–6997. – DOI: <https://doi.org/10.1609/aaai.v37i6.25854>
32. Nie Y. A time series is worth 64 words: Long-term forecasting with transformers / Y. Nie, N. H. Nguyen, P. Sinthong, J. Kalagnanam // *International Conference on Learning Representations (ICLR 2023)* [Электронный ресурс]. – 2023. – URL: <https://openreview.net/forum?id=Jbdc0vTOcol> (дата обращения: 23.03.2026).

33. Jiang Y. Empowering time series analysis with large language models: a survey / Y. Jiang, Z. Pan, X. Zhang, S. Garg, A. Schneider, Y. Nevmyvaka, D. Song // Proceedings of the 33rd International Joint Conference on Artificial Intelligence (IJCAI-24). – 2024. – P. 8095–8103. – DOI: <https://doi.org/10.24963/ijcai.2024/895>
34. Jin M. Large models for time series and spatio-temporal data: A survey and outlook / M. Jin, Q. Wen, Y. Liang [и др.] // arXiv preprint [Электронный ресурс]. – 2023. – arXiv: 2310.10196. – URL: <https://arxiv.org/abs/2310.10196> (дата обращения: 23.03.2026).
35. Garza A. TimeGPT-1 / A. Garza, M. Mergenthaler-Canseco // arXiv preprint [Электронный ресурс]. – 2024. – arXiv: 2310.03589. – URL: <https://arxiv.org/abs/2310.03589> (дата обращения: 23.03.2026).
36. Ansari A. F. Chronos: Learning the language of time series / A. F. Ansari, L. Stella, C. Turkmen [и др.] // Transactions on Machine Learning Research [Электронный ресурс]. – 2024. – URL: <https://openreview.net/forum?id=gerNCVqqtR> (дата обращения: 23.03.2026).
37. Das A. A decoder-only foundation model for time-series forecasting / A. Das, W. Kong, A. Leber [и др.] // Proceedings of the 41st International Conference on Machine Learning (ICML 2024). – 2024. – P. 10148–10167.
38. Tampouris A. Unveiling Market Regimes: A Hidden Markov Model Application for Central Bank Interest Rate Prediction / A. Tampouris, C. Dritsaki // Advances in Applied Macroeconomics. – Cham : Springer, 2025. – P. 283–297.
39. Джункеев У. Прогнозирование инфляции в России на основе градиентного бустинга и нейронных сетей / У. Джункеев. // Деньги и кредит. – 2024. – URL: <https://rjmf.econs.online/2024/1/forecasting-inflation-in-russia-using-gradient-boosting-and-neural-networks/> (дата обращения: 23.03.2026).
40. Baybuza I. Inflation forecasting using machine learning methods / I. Baybuza // Bank of Russia Working Paper Series. – 2018. – N 37. – URL: https://cbr.ru/Content/Document/File/87595/wp_37_e.pdf (дата обращения: 23.03.2026).
41. Shibitov R. Forecasting inflation with machine learning models / R. Shibitov, M. Mamedli // Bank of Russia Working Paper Series. – 2021. – N 79. – URL: https://www.cbr.ru/Content/Document/File/126938/wp_79_e.pdf (дата обращения: 23.03.2026).
42. Nelson C. R. Parsimonious modeling of yield curves / C. R. Nelson, A. F. Siegel // The Journal of Business. – 1987. – Vol. 60, N 4. – P. 473–489. – DOI: <https://doi.org/10.1086/296409>
43. ПАО Московская Биржа. Методика определения кривой бескупонной доходности государственных облигаций (облигаций федеральных займов) [Электронный ресурс] / ПАО Московская Биржа. – Утверждена протоколом Правления ПАО Московская

Биржа № 41 от 24.05.2024. – URL: <https://www.moex.com/a2920> (дата обращения: 23.03.2026).

44. Банк России. Методология формирования и публикации ставки однодневного межбанковского кредитования в российских рублях RUONIA [Электронный ресурс] / Банк России. – Утверждена приказом Банка России от 01.12.2020 № ОД-1992 с изменениями от 29.11.2021 № ОД-2339. – URL: https://cbr.ru/hd_base/ruonia/ (дата обращения: 23.03.2026).

45. СРО «Национальная финансовая ассоциация». Методика формирования и расчёта финансового индикатора ROISfix [Электронный ресурс] / СРО НФА. – Утверждена приказом от 27.12.2019 № 132. – URL: <https://nfa.ru/roisfix/> (дата обращения: 23.03.2026).

46. Cleveland R. B. STL: A seasonal-trend decomposition procedure based on Loess / R. B. Cleveland, W. S. Cleveland, J. E. McRae, I. Terpenning // Journal of Official Statistics. – 1990. – Vol. 6, N 1. – P. 3–73.

47. Tashman L. J. Out-of-sample tests of forecasting accuracy: An analysis and review / L. J. Tashman // International Journal of Forecasting. – 2000. – Vol. 16, N 4. – P. 437–450. – DOI: [https://doi.org/10.1016/S0169-2070\(00\)00065-0](https://doi.org/10.1016/S0169-2070(00)00065-0)

48. Bergmeir C. On the use of cross-validation for time series predictor evaluation / C. Bergmeir, J. M. Benítez // Information Sciences. – 2012. – Vol. 191. – P. 192–213. – DOI: <https://doi.org/10.1016/j.ins.2011.12.028>

49. Diebold F. X. Comparing predictive accuracy / F. X. Diebold, R. S. Mariano // Journal of Business & Economic Statistics. – 1995. – Vol. 13, N 3. – P. 253–263. – DOI: <https://doi.org/10.1080/07350015.1995.10524599>

50. Newey W. K. A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix / W. K. Newey, K. D. West // Econometrica. – 1987. – Vol. 55, N 3. – P. 703–708. – DOI: <https://doi.org/10.2307/1913610>

51. Harvey D. Testing the equality of prediction mean squared errors / D. Harvey, S. Leybourne, P. Newbold // International Journal of Forecasting. – 1997. – Vol. 13, N 2. – P. 281–291. – DOI: [https://doi.org/10.1016/S0169-2070\(96\)00719-4](https://doi.org/10.1016/S0169-2070(96)00719-4)

52. Garza F. StatsForecast: Lightning fast forecasting with statistical and econometric models [Электронный ресурс] / F. Garza, M. Mergenthaler-Canseco, C. Challú. – 2022. – URL: <https://github.com/Nixtla/statsforecast> (дата обращения: 23.03.2026).

53. Olivares K. G. NeuralForecast: User friendly state-of-the-art neural forecasting models [Электронный ресурс] / K. G. Olivares, C. Challú, F. Garza, M. Mergenthaler-Canseco. – 2022. – URL: <https://github.com/Nixtla/neuralforecast> (дата обращения: 23.03.2026).

54. Smith T. G. pmdarima: ARIMA estimators for Python [Электронный ресурс] / T. G. Smith [и др.]. – 2017. – URL: <http://alkaline-ml.com/pmdarima> (дата обращения: 23.03.2026).

55. Fisher A. All models are wrong, but many are useful: Learning a variable's importance by studying an entire class of prediction models simultaneously / A. Fisher, C. Rudin, F. Dominici // Journal of Machine Learning Research. – 2019. – Vol. 20, N 177. – P. 1–81.

56. Bank for International Settlements. Transmission and effectiveness of monetary policy in Asia [Электронный ресурс] / BIS. – Basel : BIS, 2008. – (BIS Papers ; N 35). – URL: <https://www.bis.org/publ/bppdf/bispap35.pdf> (дата обращения: 23.03.2026).

57. Национальный банк Республики Казахстан. Базовая ставка [Электронный ресурс] / Национальный банк Республики Казахстан. – URL: <https://nationalbank.kz/ru/news/bazovaya-stavka> (дата обращения: 23.03.2026).

ПРИЛОЖЕНИЕ А

Папка на диске с полным текстом программ, датасетом, графиками

Состав:

- 01_data_collection.py – сбор и предобработка данных
- 02_eda.py – разведочный анализ
- 03_baseline.py – базовые модели
- 04_statistical.py – статистические модели
- 05_prophet.py – модель Prophet с экзогенными регрессорами и без них
- 06_mlforecast.py – ансамблевые модели
- 07_two_stage_h3.py – двухстадийный прогноз на горизонтах $h = 3$ и $h = 6$ с прогнозом экзогенных переменных
- 08_neuralforecast.py – нейросетевые модели NeuralForecast: N-BEATS, N-HiTS, PatchTST
- 09_foundation.py – предобученная модель TimeGPT (zero-shot, API Nixtla)
- 10_comparison.py – финальное сравнение всех 16 моделей: тест Диболда–Мариано (78 пар), HAC-оценка дисперсии Ньюи–Веста, сводные таблицы метрик
- 11_reversed.py – обратная задача: оценка коэффициента РТ ключевой ставки в RUONIA и ROISfix 3M, сценарный анализ (раздел 3.9)
- 12_kazakhstan.py – проверка робастности на данных базовой ставки НБРК (Казахстан, 127 месяцев)
- dataset_monthly.csv – итоговый датасет в формате CSV
- figures/ – все графики и промежуточные CSV файлы

Ссылка – https://disk.yandex.ru/d/8tLux8MKYGF_Kw